



เรื่อง

การเปรียบเทียบวิธีพยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซีย-ยูเครน

Comparison of Forecasting Methods for Gold Prices under the
Russia-Ukraine War

โดย

กลุ่ม N9

นายกฤต ขติมานัง เลขทะเบียน 6509612690

นายณวพ ลิ้มสกุล เลขทะเบียน 6509612930

นายรัชพล สม่่าหลี เลขทะเบียน 6509613128

รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา ส.495 โครงการพิเศษ 2

ตามหลักสูตรวิทยาศาสตรบัณฑิต

สาขาสถิติ สาขาวิชาคณิตศาสตร์และสถิติ

คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยธรรมศาสตร์

ปีการศึกษา 2568

การเปรียบเทียบวิธีพยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซีย-ยูเครน

โดย

นายกฤต ขติมานัง

นายณวพ ลิมสกุล

นายรัชพล สม่าหลี

รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา ส.495 โครงการพิเศษ 2

ตามหลักสูตรวิทยาศาสตรบัณฑิต

สาขาสถิติ สาขาวิชาคณิตศาสตร์และสถิติ

คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยธรรมศาสตร์

ปีการศึกษา 2568

Comparison of Forecasting Methods for Gold Prices under the
Russia-Ukraine War

BY

Krit Katichanang

Navaphop Limsakul

Ratchapol Samalee

A SPECIAL PROBLEM SUBMITTED IN PARTIAL FULFILLMENT OF THE
REQUIREMENTS FOR THE DEGREE OF BACHELOR OF SCIENCE
(STATISTICS)

DEPARTMENT OF MATHEMATICS AND STATISTICS

FACULTY OF SCIENCE AND TECHNOLOGY

THAMMASAT UNIVERSITY

ACADEMIC YEAR 2024

หัวข้อปัญหาพิเศษ	การเปรียบเทียบวิธีพยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซีย-ยูเครน	
ชื่อผู้เขียน	นายกฤต ขติมานัง	เลขทะเบียน 6509612690
	นายณวพ ลิ้มสกุล	เลขทะเบียน 6509612930
	นายรัชพล สม่าหลี	เลขทะเบียน 6509613128
ชื่อปริญญา	วิทยาศาสตร์บัณฑิต (สถิติ)	
สาขาวิชา	สาขาวิชาคณิตศาสตร์และสถิติ	
คณะ	คณะวิทยาศาสตร์และเทคโนโลยี	
มหาวิทยาลัย	มหาวิทยาลัยธรรมศาสตร์	
อาจารย์ที่ปรึกษา	ผศ.สุรเมศวร์ ฮาซิม	

บทคัดย่อ

งานวิจัยนี้มีวัตถุประสงค์เพื่อศึกษาเปรียบเทียบวิธีการพยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซีย-ยูเครน โดยใช้วิธีอนุกรมเวลา ได้แก่ Exponential Smoothing และ Box-Jenkins เปรียบเทียบกับวิธีการเรียนรู้ของเครื่อง ได้แก่ โครงข่ายประสาทเทียม LSTM และ XGBoost ข้อมูลที่นำมาใช้สร้างตัวแบบคือราคาล่าสุดรายวันของอัตราแลกเปลี่ยนทองคำต่อดอลลาร์สหรัฐ ตั้งแต่วันที่ 24 กุมภาพันธ์ พ.ศ. 2565 ถึงวันที่ 10 กรกฎาคม พ.ศ. 2567 ทดสอบประสิทธิภาพตั้งแต่วันที่ 11 กรกฎาคม พ.ศ. 2567 ถึง 14 กุมภาพันธ์ พ.ศ. 2568 โดยใช้เกณฑ์การประเมิน ได้แก่ ค่าเฉลี่ยความคลาดเคลื่อนสัมบูรณ์ (MAD) รากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง (RMSE) และค่าเฉลี่ยร้อยละของความคลาดเคลื่อนสัมบูรณ์ (MAPE) ผลการศึกษาพบว่าวิธีการเรียนรู้ของเครื่องทั้งสองวิธีมีประสิทธิภาพสูงกว่าวิธีอนุกรมเวลา สะท้อนความสามารถของการเรียนรู้ของเครื่องในการพยากรณ์สินทรัพย์ที่มีความผันผวนในระยะสั้น โดยวิธีที่มีประสิทธิภาพสูงสุดคือโครงข่ายประสาทเทียมแบบ XGBoost ให้ความแม่นยำสูงสุดในทุกเกณฑ์ โดยมีค่า MAD เท่ากับ 132.5518 RMSE เท่ากับ 156.4902 และ MAPE เท่ากับ 4.9578%

คำสำคัญ: สงครามรัสเซีย-ยูเครน, ราคาทองคำ, การพยากรณ์อนุกรมเวลา, การเรียนรู้ของเครื่อง

Title	Comparison of Forecasting Methods for Gold Prices under the Russia-Ukraine War	
Authors	Mr. Krit Katichanang	Student ID 6509612690
	Mr. Navaphop Limsakul	Student ID 6509612930
	Mr. Ratchapol Samalee	Student ID 6509613128
Degree	Bachelor of Science (Statistics)	
Department	Mathematics and Statistics	
Faculty	Faculty of Science and Technology	
University	Thammasat University	
Advisor	Asst. Prof. Suramase Hashim	

ABSTRACT

This study compares gold price forecasting under the Russia–Ukraine war using time series methods (Exponential Smoothing and Box–Jenkins) against machine learning methods (LSTM and XGBoost). Daily gold-to-US dollar prices from 24 February 2022 to 10 July 2024 are used for model construction, and forecasting performance is tested from 11 July 2024 to 14 February 2025, evaluated by MAD, RMSE, and MAPE. Results show that machine learning achieves higher performance than time series methods, reflecting the capability of machine learning to forecast highly volatile short-term assets under crisis conditions, with the XGBoost model performing best (MAD 132.5518, RMSE 156.4902, MAPE 4.9578%).

Keywords: Russia-Ukraine war, gold price, time series forecasting, machine learning

กิตติกรรมประกาศ

ปัญหาพิเศษฉบับนี้สำเร็จลุล่วงไปได้ด้วยดีเนื่องมาจากคณะผู้จัดทำได้รับความกรุณาเป็นอย่างยิ่งจากอาจารย์ที่ปรึกษา ผู้ช่วยศาสตราจารย์ สุรเมศวร์ ฮาซิม ที่ได้กรุณาสละเวลาให้คำปรึกษา ชี้แนะแนวทางที่เหมาะสมในทุกขั้นตอนของการดำเนินงาน ติดตามความก้าวหน้าอย่างต่อเนื่อง ตลอดจนการตรวจสอบความถูกต้องของเนื้อหาอย่างละเอียด เพื่อให้ปัญหาพิเศษฉบับนี้สมบูรณ์ คณะผู้จัดทำจึงขอกราบขอบพระคุณไว้ ณ โอกาสนี้

คณะผู้จัดทำขอกราบขอบพระคุณ รองศาสตราจารย์ ดร.มณฑิรา ดวงสาพล และรองศาสตราจารย์ ดร.แสงดาว วงศ์สาย คณะกรรมการสอบปัญหาพิเศษ ที่ได้กรุณาให้คำปรึกษา ข้อเสนอแนะเชิงวิชาการ และแนวคิดต่างๆ ที่เป็นประโยชน์ รวมถึงการตรวจสอบประเด็นต่างๆ ที่ควรปรับปรุงเพิ่มเติมพร้อมแนวทางแก้ไขที่เหมาะสม ทำให้ปัญหาพิเศษฉบับนี้มีความสมบูรณ์มากยิ่งขึ้น

ขอกราบขอบพระคุณคณาจารย์สาขาคณิตศาสตร์และสถิติ คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยธรรมศาสตร์ทุกท่านเป็นอย่างสูง ที่อบรมสั่งสอน ส่งเสริมความรู้ และสนับสนุนในการจัดทำปัญหาพิเศษฉบับนี้จนสำเร็จไปได้ด้วยดี

สุดท้ายนี้ คณะผู้จัดทำขอกราบขอบพระคุณบิดาและมารดาเป็นอย่างสูง ที่ได้มอบความรัก ความห่วงใย และการสนับสนุนในทุกด้าน ทำให้การศึกษาครั้งนี้สำเร็จลุล่วงได้ตามที่ตั้งใจ

กฤต ขติมานัง

นวภพ ถิ่นสกุล

รัชพล สม่าหลี

สารบัญ

หน้า

บทคัดย่อ.....	ก
ABSTRACT	ข
กิตติกรรมประกาศ.....	ค
สารบัญ	ง
สารบัญตาราง.....	ช
สารบัญรูปภาพ.....	ฉ
บทที่ 1 บทนำ	1
1.1 ที่มาและความสำคัญของปัญหา.....	1
1.2 วัตถุประสงค์ของการศึกษา.....	3
1.3 ขอบเขตของการศึกษา.....	3
1.5 ประโยชน์ที่คาดว่าจะได้รับ	4
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง.....	5
2.1 การพยากรณ์.....	5
2.2 การพยากรณ์ด้วยวิธีการทางสถิติ	6
2.2.1 วิธีปรับให้เรียบ (Smoothing method)	7
2.2.2 วิธีของ Box และ Jenkins หรือ Autoregressive Integrated Moving Average	13
2.3 วิธีเทคนิคการเรียนรู้ของเครื่อง (Machine Learning).....	27
2.3.1 Long-Short term memory	30

2.3.2 Extreme Gradient Boosting (XGBoost)	37
2.4 การเปรียบเทียบประสิทธิภาพการพยากรณ์	44
2.5 งานวิจัยที่เกี่ยวข้อง.....	45
บทที่ 3 วิธีดำเนินการวิจัย.....	48
3.1 การเก็บรวบรวมและลักษณะของข้อมูล	48
3.2 เครื่องมือที่ใช้ในการวิจัย	49
3.3 การวิเคราะห์ข้อมูล.....	49
3.3.1 ขั้นตอนการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยวิธีปรับให้เรียบแบบเอ็กซ์โพเนนเชียล	49
3.3.2 ขั้นตอนการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยวิธี ARIMA	49
3.3.3 ขั้นตอนการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยวิธีการเรียนรู้ของเครื่องแบบ LSTM	50
3.3.4 ขั้นตอนการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยวิธีการเรียนรู้ของเครื่องแบบ XGBoost.....	53
3.3.5 การเปรียบเทียบประสิทธิภาพการพยากรณ์โดยใช้สถิติสำหรับการวัดประสิทธิภาพ	55
บทที่ 4 ผลการวิจัยและอภิปรายผล.....	61
4.1 การเตรียมข้อมูลก่อนทำการพยากรณ์	61
4.2 ผลการวิเคราะห์ข้อมูลด้วยวิธีปรับให้เรียบแบบเอ็กซ์โพเนนเชียล	64
4.3 ผลการวิเคราะห์ข้อมูลด้วยวิธีการพยากรณ์ ARIMA.....	65
4.4 ผลการวิเคราะห์ข้อมูลด้วยวิธีการเรียนรู้ของเครื่องแบบ LSTM	73
4.5 ผลการวิเคราะห์ข้อมูลด้วยวิธีการเรียนรู้ของเครื่องแบบ XGBoost.....	75
4.6 เปรียบเทียบประสิทธิภาพการพยากรณ์	78
บทที่ 5 สรุปผลการวิจัยและข้อเสนอแนะ	81

5.1 สรุปผลการวิจัย	81
5.2 ข้อเสนอแนะ	82
5.2.1 ข้อเสนอแนะเพื่อการใช้ประโยชน์	82
5.2.2 ข้อเสนอแนะเพื่อการวิจัย.....	83
บรรณานุกรม.....	84

สารบัญตาราง

ตาราง	หน้า
2.1 แสดงการพิจารณา ACF และ PACF	19
3.1 ลักษณะที่กำหนดทั้ง 5 ชั้นของวิธีการเรียนรู้แบบ LSTM เพื่อสร้างตัวแบบพยากรณ์.....	51
3.2 ค่าที่กำหนดสำหรับหาค่าที่ดีที่สุดของจำนวนข้อมูลนำเข้าและไฮเพอร์พารามิเตอร์.....	52
3.3 ค่าที่กำหนดสำหรับหาค่าที่เหมาะสมของจำนวนข้อมูลนำเข้าและไฮเพอร์พารามิเตอร์	52
3.4 output shape ที่กำหนดเพื่อหาค่าที่เหมาะสมสำหรับจำนวนหน่วยแต่ละ Layer.....	54
3.5 ค่าที่กำหนดสำหรับการหาค่าที่เหมาะสมของไฮเพอร์พารามิเตอร์	54
4.1 ผลลัพธ์จากการทดสอบ Augmented Dickey-Fuller ข้อมูลฝึก	62
4.2 ผลลัพธ์จากการทดสอบ Augmented Dickey-Fuller Test ของข้อมูลฝึกหลังจากหา ผลต่างอันดับที่ 1	63
4.3 ผลลัพธ์จากการคำนวณค่าคงที่ในการทำให้เรียบในแนวระดับ ค่าคงที่ในการทำให้เรียบของ แนวโน้ม ค่าเริ่มต้นในแนวระดับ ค่าเริ่มต้นของความชันของแนวโน้ม	64
4.4 ค่าวัดประสิทธิภาพ MAD RMSE และ MAPE จากการพยากรณ์ด้วยวิธีการปรับให้เรียบ แบบเอ็กซ์โพเนนเชียลของโฮลท์.....	65
4.5 ผลลัพธ์จากการทดสอบ Augmented Dickey-Fuller หลังจากหาผลต่างอันดับที่ 2	67
4.6 การทดสอบความมีนัยสำคัญของพารามิเตอร์ในตัวแบบ ARIMA(0,2,1)	69
4.7 ผลการทดสอบสหสัมพันธ์ของค่าคลาดเคลื่อนด้วย Box-Ljung test.....	70
4.8 ผลการทดสอบการแจกแจงปกติของค่าคลาดเคลื่อนด้วย Kolmogorov-Smirnov test.....	70
4.10 ผลการทดสอบความแปรปรวนคงที่ของค่าคลาดเคลื่อนด้วย Levene's test	71
4.11 ค่าวัดประสิทธิภาพ MAD RMSE และ MAPE จากการพยากรณ์ด้วยวิธี ARIMA(0,2,1).....	72
4.12 ลักษณะของแต่ละชั้นที่กำหนดสำหรับการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องแบบ LSTM	73
4.13 ไฮเพอร์พารามิเตอร์ที่กำหนดสำหรับการเรียนรู้	73
4.14 ค่าวัดประสิทธิภาพ MAD RMSE และ MAPE จากการพยากรณ์ด้วยวิธีการเรียนรู้ของ เครื่องแบบ LSTM.....	75

4.15 ไฮเพอร์พารามิเตอร์ที่กำหนดสำหรับการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องแบบ	
XGBoost.....	76
4.16 ค่าวัดประสิทธิภาพ MAD RMSE และ MAPE จากการพยากรณ์ด้วยวิธีการเรียนรู้ของ	
เครื่องแบบ XGBoost	78
4.17 เปรียบเทียบเทียบค่าวัดประสิทธิภาพการพยากรณ์ด้วยวิธี Holt's Exponential	
Smoothing, ARIMA(0,2,1), XGBoost, และ LSTM	79

สารบัญรูปภาพ

รูปที่	หน้า
1.1 ราคาทองคำหลังจากรัสเซียส่งกองกำลังทหารโจมตียูเครน	2
2.1 ตัวอย่างการเกิดแบบจำลอง AR(1) (นิภาพร, 2552)	20
2.2 ตัวอย่างการเกิดแบบจำลอง MA(1) (นิภาพร, 2552)	20
2.3 ตัวอย่างการเกิดแบบจำลอง ARMA(1,2) (นิภาพร, 2552)	21
2.4 ตัวอย่างการตรวจสอบโมเดลด้วยวิธีการ Rolling Window	29
2.5 ตัวอย่างการสร้างโมเดลจำนวน 3 โมเดลเพื่อพยากรณ์ช่วงเวลาล่วงหน้า 3 ช่วงเวลา	30
2.6 แบบจำลองโครงข่ายประสาททางชีววิทยา	31
2.7 แบบจำลองโครงข่ายประสาทเทียม	31
2.8 แบบจำลองโครงข่ายประสาทเทียมเปรียบเทียบกับระบบประสาทของมนุษย์	32
2.9 แสดงโครงสร้างและลำดับการทำงานของโครงข่ายประสาทเทียมแบบหลายชั้น	32
2.10 การวนซ้ำของ RNN จะมีการเก็บข้อมูลที่จะนำออกจาก Node มาใช้ร่วมกับข้อมูลถัดไป	33
2.11 แผนผังการทำงานของ LSTM	34
2.12 cell gate ที่จะทำหน้าที่ลบข้อมูลที่ควรลืมและนำเข้าข้อมูลที่ควรจดจำ	34
2.13 การดำเนินการในชั้นซิกมอยด์และชั้น tanh ที่จะทำงานร่วมกันเพื่อนำเข้าข้อมูลที่ควรจดจำ ไปยัง cell state	35
2.14 แสดงการนำข้อมูลออกและการเพิ่มข้อมูลเข้า Cell State C_t	36
2.15 แสดงกระบวนการทำงานในขั้นตอนสุดท้ายก่อนจะส่งออกผลลัพธ์ h_t	37
2.16 แสดงการทำงานร่วมกันของโครงข่ายประสาทเทียมแบบ LSTM หลายหน่วย	37
2.17 แสดงตัวอย่างของการตัดสินใจของ Regression Tree สำหรับการทำนายค่าต่อเนื่อง	38
2.18 แสดงโครงสร้างส่วนประกอบของ Decision Tree	39
3.1 ข้อมูลอัตราแลกเปลี่ยนทองคำต่อดอลลาร์สหรัฐในรอบเวลาที่จะนำมาวิเคราะห์ข้อมูล	48
3.2 แผนภาพขั้นตอนการวิจัย	56
3.3 แผนภาพขั้นตอนการพยากรณ์ด้วยวิธีปรับให้เรียบแบบเอกซ์โพเนนเชียล	57
3.4 แผนภาพขั้นตอนการพยากรณ์ด้วยวิธีของ Box และ Jenkins (ตัวแบบ ARIMA)	58
3.5 แผนภาพขั้นตอนการพยากรณ์ด้วยโครงข่ายประสาทเทียมแบบ LSTM	59

3.6 แผนภาพขั้นตอนการพยากรณ์ด้วยการเรียนรู้ของเครื่องแบบ XGBoost.....	60
4.1 ข้อมูลอนุกรมเวลาชุดฝึกที่แบ่งมาจากร้อยละ 80 ช่วงเวลาแรกของข้อมูลทั้งหมด.....	61
4.2 ข้อมูลฝึกหลังทำการหาผลต่างอันดับที่ 1	63
4.3 แสดงผลลัพธ์จากการพยากรณ์ด้วยวิธีการปรับให้เรียบของ Holt.....	65
4.4 คอเรลโลแกรมของสหสัมพันธ์ในตัวเองของราคาทองคำหลังจากหาผลต่างอันดับที่ 1	66
4.5 คอเรลโลแกรมของสหสัมพันธ์ในตัวเองบางส่วนจากราคาทองคำหลังจากหาผลต่างอันดับที่ 1	66
4.6 ข้อมูลฝึกหลังทำการหาผลต่างอันดับที่ 2	67
4.7 คอเรลโลแกรมของสหสัมพันธ์ในตัวเองของราคาทองคำหลังจากหาผลต่างอันดับที่ 2	68
4.8 คอเรลโลแกรมของสหสัมพันธ์ในตัวเองบางส่วนจากราคาทองคำหลังจากหาผลต่างอันดับที่ 2	68
4.9 ผลลัพธ์การพยากรณ์ของข้อมูลชุดฝึกและข้อมูลชุดทดสอบด้วยวิธี ARIMA(0,2,1)	72
4.10 ผลลัพธ์การพยากรณ์ด้วยโครงข่ายประสาทเทียมแบบ LSTM ในรูปผลต่างอันดับที่ 1	74
4.11 ผลลัพธ์การพยากรณ์ด้วยโครงข่ายประสาทเทียมแบบ LSTM หลังแปลงค่ากลับ	75
4.12 ผลลัพธ์การพยากรณ์ด้วย XGBoost ในรูปผลต่างอันดับที่ 1	77
4.13 ผลลัพธ์การพยากรณ์ด้วยวิธี XGBoost หลังแปลงค่ากลับ	77
4.14 ผลลัพธ์การพยากรณ์ทั้ง 4 วิธีบนข้อมูลชุดทดสอบ.....	79

บทที่ 1

บทนำ


1.1 ที่มาและความสำคัญของปัญหา

ทองคำเป็นสินทรัพย์ที่มีมูลค่าในตัวเองและสามารถนำไปใช้แลกเปลี่ยนในสกุลเงินอื่นๆได้ สาเหตุที่ทองคำมีมูลค่าในตัวเองนั้นเพราะว่าทองคำในโลกมีอยู่อย่างจำกัดและทองคำยังเป็นปัจจัยหนึ่งที่ใช้กำหนดการมีเงินทุนสำรอง กำหนดการกู้ยืมเงิน หรือเป็นสินทรัพย์สำรองระหว่างประเทศ การลงทุนในทองคำนั้นมีประโยชน์หลายทาง ได้แก่ โอกาสสร้างผลตอบแทนจากการเพิ่มขึ้นของราคาที่มาจากกลไกตลาด มีสภาพคล่องการซื้อขายสูง มีตลาดรองรับสามารถซื้อขายได้ในทุกประเทศทั่วโลก นอกจากนี้ทองคำยังมีความน่าเชื่อถือ เป็นสินทรัพย์ปลอดภัยเมื่อเกิดความไม่แน่นอนหรือความผันผวนในตลาดการเงิน การลงทุนในทองคำนั้นเป็นหนึ่งในทางเลือกในช่วงเวลาที่เกิดเหตุการณ์สงครามหรือวิกฤตการณ์ทางการเงิน เพื่อทำการสะสมสินทรัพย์หรือการเก็งกำไร (นพัตสรณ์ และคณะ, 2565)

เนื่องด้วยสถานการณ์สงครามระหว่างประเทศรัสเซียและประเทศยูเครนที่เกิดขึ้นตั้งแต่วันที่ 24 กุมภาพันธ์ พ.ศ. 2565 โดยประเทศรัสเซียได้ทำการส่งกองกำลังทหารโจมตีเมืองหลวงของประเทศยูเครนเพื่อตอบสนองต่อการโจมตีของประเทศรัสเซีย พันธมิตรชาติตะวันตกซึ่งนำโดย สหรัฐฯ สหภาพยุโรป (EU) และกลุ่ม G7 ได้ร่วมกันประกาศใช้มาตรการคว่ำบาตรทางเศรษฐกิจที่รุนแรงที่สุดครั้งหนึ่งเท่าที่เคยมีมา โดยหวังที่จะสร้างแรงกดดันต่อเศรษฐกิจรัสเซียอย่างหนักเพื่อกดดันให้รัสเซียยุติการสู้รบ หรือเพื่อใช้เป็นเครื่องมือต่อรองในการเจรจา ทางด้านรัสเซียก็ตอบโต้มาตรการคว่ำบาตรของชาติตะวันตกด้วยการประกาศรายชื่อประเทศที่ไม่เป็นมิตรซึ่งเป็นประเทศที่ร่วมคว่ำบาตรรัสเซียจำนวน 48 ประเทศ เพื่อกำหนดมาตรการเฉพาะ (กองวิจัยเศรษฐกิจการค้าภาค, 2566)

จากสถานการณ์ความตึงเครียดที่เกิดขึ้นจากสงครามระหว่างประเทศรัสเซียและยูเครน รวมถึงมาตรการคว่ำบาตรต่างๆที่เกิดขึ้นส่งผลให้หลายประเทศได้กำหนดมาตรการสะสมทองคำเพื่อความมั่นคงต่อเศรษฐกิจและการเงินของประเทศ นอกจากนี้ทำให้นักลงทุนที่ต้องการสินทรัพย์ที่มีความเสี่ยงต่ำในช่วงสภาวะสงครามเช่นนี้ จะลงทุนทองคำมากขึ้น เนื่องจากทองคำได้รับความน่าเชื่อถือให้เป็นสินทรัพย์ที่

ปลอดภัยสำหรับการลงทุนในสภาวะวิกฤติ ส่งผลให้อุปทานของทองคำในช่วงสงครามรัสเซีย-ยูเครนมีมากขึ้นในขณะที่ทองคำมีอยู่อย่างจำกัด ส่งผลให้ราคาทองคำสูงขึ้นอย่างเห็นได้ชัดหลังจากการบุกโจมตีของรัสเซียและการประกาศมาตรการคว่ำบาตรของพันธมิตรชาติตะวันตก แสดงได้ดังรูปที่ 1.1



รูปที่ 1.1 ราคาทองคำหลังจากรัสเซียส่งกองกำลังทหารโจมตียูเครน

การพยากรณ์ราคาทองคำจึงมีความสำคัญ สามารถเป็นประโยชน์ในด้านการลงทุนสำหรับนักลงทุนที่สนใจลงทุนในทองคำเพื่อรักษามูลค่าทรัพย์สินหรือเพื่อเก็งกำไร และสามารถเป็นกรณีศึกษาสำหรับการพยากรณ์ราคาทองคำในช่วงสภาวะสงครามในอนาคต ในปัจจุบันได้มีงานวิจัยที่พยากรณ์ราคาทองคำด้วยวิธีการอนุกรมเวลาโดยมักจะนิยมใช้วิธี ARIMA เช่น Sharma (2016) ได้ทำการนำข้อมูลราคาทองคำรายเดือนในประเทศอินเดียเพื่อสร้างแบบจำลองในการพยากรณ์โดยใช้แบบจำลอง พบว่าแบบจำลอง ARIMA(3,1,3) เหมาะสมที่จะนำมาใช้พยากรณ์ราคาทองคำในประเทศอินเดียมากที่สุด Yang (2018) ได้ทำการนำแบบจำลอง ARIMA มาพยากรณ์ราคาทองคำรายวันพบว่า แบบจำลอง ARIMA (3, 1, 2) ให้ผลการพยากรณ์ที่แม่นยำที่สุด ขณะที่ Khalid & Halim (2019) ได้ทำการพยากรณ์ราคาทองคำรายวันด้วยแบบจำลอง ARIMA พบว่า ARIMA(1,1,1) เหมาะสำหรับการใช้พยากรณ์ราคาทองคำรายวันมากที่สุด นอกจากวิธีการทางอนุกรมเวลาแล้ว วิธีการพยากรณ์ด้วยเทคนิคการเรียนรู้ของเครื่องก็เป็นอีกวิธีที่ได้รับความนิยมสำหรับการพยากรณ์ราคาทองคำ พบว่ามีการศึกษาของ Makala and Li (2021) ได้ทำการนำแบบจำลอง ARIMA มาเปรียบเทียบกับประสิทธิภาพการพยากรณ์ราคาทองคำกับแบบจำลอง SVM ซึ่งเป็นหนึ่งในวิธีการพยากรณ์ด้วยเทคนิคการเรียนรู้ของเครื่อง พบว่า SVM มีประสิทธิภาพดีกว่า ARIMA

เมื่อวัดประสิทธิภาพด้วย RMSE และ MAPE และการการศึกษาของ Fawzy, Rady, & Fattah (2020) ที่ได้ทำการเปรียบเทียบวิธีการพยากรณ์ราคาทองคำรายเดือน โดยใช้เกณฑ์การเปรียบเทียบ RMSE พบว่าแบบจำลอง SVM มีประสิทธิภาพดีกว่า K-NN ในการพยากรณ์ราคาทองคำและการศึกษาของ Nwokike et al. (2020) ได้นำโครงข่ายประสาทเทียม (ANN) 17 รูปแบบมาใช้ในการพยากรณ์ราคาทองคำรายเดือนแล้วทำการเปรียบเทียบด้วย MSE และ MAE พบว่า โครงสร้างที่มีเซลล์ประสาท 2, 6 และ 1 สำหรับเซลล์ในชั้นนำเข้า, ชั้นซ่อน และชั้นผลลัพธ์ตามลำดับเป็นตัวแทนที่ดีที่สุด

1.2 วัตถุประสงค์ของการศึกษา

1) เพื่อศึกษาและสร้างตัวแบบพยากรณ์ราคาทองคำในสภาวะสงครามระหว่างประเทศรัสเซียและยูเครน 4. วิธี ได้แก่ Smoothing Exponential, Autoregressive Integrated Moving Average (ARIMA) , Long Short-Term Memory (LSTM), Extreme Gradient Boosting (XGBoost)

2) เพื่อเปรียบเทียบวิธีการพยากรณ์ราคาทองคำในสภาวะสงครามระหว่างประเทศรัสเซียและประเทศยูเครน

1.3 ขอบเขตของการศึกษา

จากการศึกษางานวิจัยต่างๆที่ได้ทำการพยากรณ์ราคาทองคำทำให้ผู้วิจัยจึงมีความสนใจที่จะทำการศึกษาเปรียบเทียบวิธีการพยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซีย-ยูเครนโดยผู้วิจัยจะนำการพยากรณ์ทั้ง 2 รูปแบบคือวิธีการพยากรณ์อนุกรมเวลาทางสถิติ ได้แก่ วิธีการปรับให้เรียบ และวิธีของ Box-Jenkins หรือ ARIMA มาเปรียบเทียบประสิทธิภาพการพยากรณ์กับการพยากรณ์ข้อมูลอนุกรมเวลาด้วยเทคนิคการเรียนรู้ของเครื่อง ได้แก่ การเรียนรู้ของเครื่องแบบ LSTM และ การเรียนรู้ของเครื่องแบบ XGBoost ข้อมูลที่นำมาศึกษาคือ ข้อมูลทศัญฉฎมิอัตราแลกเปลี่ยนย้อนหลัง XAU/USD ซึ่งมีลักษณะเป็นข้อมูลรายวัน ตั้งแต่วันที่ 24 กุมภาพันธ์ พ.ศ. 2565 ถึงวันที่ 14 กุมภาพันธ์ พ.ศ.2568 สืบค้นจาก investing.com ในการวิเคราะห์และพยากรณ์ครั้งนี้จะนำข้อมูลราคาล่าสุดมาใช้ในการสร้างตัวแบบพยากรณ์ เปรียบเทียบประสิทธิภาพโดยพิจารณาจากค่าเฉลี่ยความผิดพลาดสัมบูรณ์ หรือ Mean Absolute Deviation : MAD ค่ารากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง หรือ Root Mean

Square Error : RMSE และ ค่าเฉลี่ยร้อยละของความคลาดเคลื่อนสัมบูรณ์ หรือ Mean Absolute Percentage Error : MAPE

1.4 นิยามศัพท์

- XAU ย่อมาจาก Index Aurum แปลว่า ดัชนีทองคำ โดย “X” ย่อมาจาก Index แปลว่าดัชนี และ “Aurum” เป็นคำมาจากภาษาละตินให้ความหมายว่าทองคำ
- USD ย่อมาจาก United States dollar แปลว่า ดอลลาร์สหรัฐ

1.5 ประโยชน์ที่คาดว่าจะได้รับ

ทำให้ทราบวิธีการที่เหมาะสมที่สุดในการพยากรณ์ราคาทองคำในกรอบเวลาสถานการณ์สงครามระหว่างประเทศรัสเซียและยูเครน

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 การพยากรณ์

ความหมายของการพยากรณ์และการพยากรณ์อนุกรมเวลา

การพยากรณ์ (forecasting) หมายถึงการคาดการณ์ (forecasting) การทำนาย (prediction) การประมาณค่าในอนาคต โดยใช้ข้อมูลหรือเหตุการณ์ที่เกิดขึ้นในอดีตที่มีองค์ประกอบมาจากสถานการณ์เดียวกัน โดยผู้พยากรณ์จะต้องอาศัยประสบการณ์หรือทฤษฎีหลักเกณฑ์เพื่อสนับสนุนการพยากรณ์ จึงทำให้มีคนกล่าวว่าการพยากรณ์เป็นทั้งศาสตร์และศิลป์ (science and art) (ศิริลักษณ์, 2556) วิธีการพยากรณ์สามารถแบ่งได้เป็น 2 กลุ่ม ได้แก่ (ทรงศิริ, 2549)

1. การพยากรณ์เชิงปริมาณ (quantitative forecasting) เป็นการพยากรณ์ที่ใช้ข้อมูลในอดีตที่มีการเก็บรวบรวมอย่างต่อเนื่องมาใช้พยากรณ์ การพยากรณ์เชิงปริมาณแบ่งออกได้เป็น 3 กลุ่ม ได้แก่ การวิเคราะห์ข้อมูลอนุกรมเวลา การศึกษาความสัมพันธ์ระหว่างปัจจัยหรือตัวแปร และการตรวจสอบการดำเนินงานของระบบ

2. การพยากรณ์เชิงคุณภาพ (qualitative forecasting) เป็นการพยากรณ์ที่นำข้อมูลอนุกรมเวลามาใช้พยากรณ์โดยใช้ ความรู้ความสามารถ ประสบการณ์และวิจารณญาณของผู้พยากรณ์ โดยส่วนใหญ่จะใช้การพยากรณ์เชิงคุณภาพเมื่อไม่มีข้อมูลในอดีตหรือมีน้อยมาก หรือการพยากรณ์ระยะยาวที่ไม่สามารถใช้ข้อมูลในอดีต

การพยากรณ์อนุกรมเวลา หมายถึง การพยากรณ์กลุ่มของค่าสังเกตที่เก็บรวบรวมตามเวลาอย่างต่อเนื่อง โดยแต่ละค่าสังเกตมักจะเก็บรวบรวมในช่วงเวลาระยะห่างเท่ากัน และแต่ละค่าสังเกตจะมีความสัมพันธ์กันซึ่งจะแตกต่างจากค่าสังเกตจากการสำรวจที่จะเป็นอิสระกันและไม่ขึ้นกับเวลา เช่น ข้อมูลที่เก็บรายปี รายครึ่งปี รายไตรมาส รายเดือน ตัวอย่างของอนุกรมเวลา เช่น ยอดขาดสินค้ารายปี ของห้างสรรพสินค้าแห่งหนึ่ง จำนวนนักท่องเที่ยวรายปีที่เดินทางเข้าประเทศ อัตราการว่างงานทำรายปี

รายปีตรายวันของหุ้นของธนาคารแห่งหนึ่ง และเนื่องจากค่าสังเกตจากอนุกรมเวลามีความแตกต่างจากค่าสังเกตจากการสำรวจทำให้การวิเคราะห์ค่าสังเกตอนุกรมเวลาจะแตกต่างจากการวิเคราะห์ค่าสังเกตจากการสำรวจ โดยการวิเคราะห์อนุกรมเวลาเป็นการศึกษาแผนแบบการเคลื่อนไหวของอนุกรมเวลาและสร้างรูปแบบอนุกรมเวลาแทนลักษณะการเคลื่อนไหวดังกล่าว เพื่อพยากรณ์ค่าในอนาคต ในขณะที่การวิเคราะห์ค่าสังเกตจากการสำรวจเป็นการศึกษาลักษณะของตัวอย่างที่สุ่มมาเพื่อสรุปผลเกี่ยวกับลักษณะของประชากร (ทรงศิริ แต่สมบัติ) โดยการพยากรณ์ข้อมูลอนุกรมเวลาสามารถทำได้ด้วยวิธีการพยากรณ์อนุกรมเวลาทางสถิติซึ่งเป็นวิธีการพยากรณ์แบบดั้งเดิม และวิธีการพยากรณ์ด้วยเทคนิคการเรียนรู้ของเครื่อง

2.2 การพยากรณ์ด้วยวิธีการทางสถิติ

ขั้นตอนการพยากรณ์ด้วยวิธีการทางอนุกรมเวลามี 5 ขั้นตอนดังนี้ (ทรงศิริ, 2549)

- 1) กำหนดปัญหาว่าจะนำค่าพยากรณ์ไปใช้งานใด ใช้อย่างไร ผู้ใช้คือใคร และเกิดประโยชน์อย่างไร
- 2) การรวบรวมข้อมูล ทั้งข้อมูลเชิงปริมาณและข้อมูลเชิงคุณภาพตามวิจารณ์ญาณและความสามารถขอผู้เชี่ยวชาญรวมถึงข้อมูลที่มีอิทธิพลต่อข้อมูลที่สนใจ
- 3) การวิเคราะห์เบื้องต้น เพื่อพิจารณาลักษณะการเคลื่อนไหวของอนุกรมเวลาว่ามีส่วนประกอบใดบ้าง มีความสัมพันธ์ระหว่างตัวแปรหรือไม่เพื่อที่จะเป็นแนวทางในการเลือกตัวแบบพยากรณ์
- 4) กำหนดรูปแบบและสร้างสมการพยากรณ์โดยสมการพยากรณ์จะถูกสร้างจากข้อมูลที่เก็บรวบรวม
- 5) ใช้ค่าพยากรณ์และประเมินรูปแบบการพยากรณ์ ซึ่งจะต้องตรวจสอบเสมอว่าค่าพยากรณ์ที่ได้จากสมการยังคงถูกต้องและมีประสิทธิภาพ

ในขั้นตอนการประเมินความสำเร็จของการพยากรณ์ นอกจากประเมินจากค่าพยากรณ์ที่ถูกต้องแล้วผลลัพธ์การพยากรณ์จะต้องได้รับการยอมรับและมีการนำผลลัพธ์ไปใช้ประโยชน์ต่อไป

การพยากรณ์ด้วยวิธีการทางสถิติสามารถทำได้โดยวิธีปรับให้เรียบ และวิธีของ Box และ Jenkins หรือ ARIMA ซึ่งถือว่าเป็นวิธีการพยากรณ์ที่นิยมนำมาใช้เมื่อต้องการพยากรณ์ข้อมูลอนุกรมเวลา

2.2.1 วิธีปรับให้เรียบ (Smoothing method)

วิธีปรับให้เรียบ (smoothing method) หมายถึงการใช้ข้อมูลหรือค่าสังเกตในอดีตบางส่วนหรือทั้งหมดมาใช้ในการสร้างสมการพยากรณ์ โดยให้ค่าน้ำหนักกับค่าสังเกตในอนุกรมเวลาแตกต่างกัน วิธีการปรับให้เรียบที่ได้รับความนิยมคือวิธีการปรับให้เรียบแบบเอ็กซ์โพเนนเชียล (Exponential Smoothing Method) หมายถึงการใช้ค่าเฉลี่ยถ่วงน้ำหนักของข้อมูลในอดีตโดยให้ค่าน้ำหนักสูงกับข้อมูลล่าสุด และค่าน้ำหนักจะลดลงแบบเอ็กซ์โพเนนเชียลเมื่อค่าสังเกตมีระยะเวลาดำเนินการออกไป การพยากรณ์ข้อมูลอนุกรมเวลาด้วยวิธีปรับให้เรียบแบบเอ็กซ์โพเนนเชียลสามารถเลือกวิธีที่จะนำมาใช้พยากรณ์ได้ 3 วิธี โดยเลือกวิธีการพยากรณ์จากการตรวจสอบส่วนประกอบของข้อมูลอนุกรมเวลา

1. วิธีการทำให้เรียบแบบเอ็กซ์โพเนนเชียลอย่างง่าย (Simple Exponential Smoothing: SES)

เป็นเทคนิคที่ใช้ในการพยากรณ์ข้อมูลอนุกรมเวลาที่ไม่มีความโน้ม (trend) และไม่มีฤดูกาล (seasonality) โดยค่าเฉลี่ยของข้อมูลอนุกรมเวลาจะมีการเปลี่ยนแปลงเพียงเล็กน้อยตลอดช่วงเวลา การพยากรณ์ด้วยวิธี SES สามารถพยากรณ์ล่วงหน้าได้เพียง 1 ช่วงเวลาเนื่องจากต้องใช้ข้อมูลจริงของช่วงเวลาก่อนหน้า สำหรับการพยากรณ์ข้อมูลอนุกรมเวลาที่ไม่มีความโน้มสามารถเขียนได้ดังนี้

$$Z_t = \beta_0 + \varepsilon_t$$

โดย Z_t หมายถึง ค่าจริงของอนุกรมเวลา ณ ช่วงเวลา t

β_0 หมายถึง พารามิเตอร์แสดงค่าในแนวระดับ

ε_t หมายถึง ค่าความคลาดเคลื่อนสุ่ม ณ ช่วงเวลา t

โดยจะมีตัวแบบพยากรณ์สำหรับ Z_t ดังนี้

$$Z_t = S_{t-1} \quad \text{เมื่อ } t = 2, 3, \dots, n$$

$$\text{เมื่อ } t = 1 \quad Z_1 = S_0$$

โดย S_0 หมายถึง ค่าเริ่มต้นของการปรับให้เรียบ ซึ่ง $S_0 = \frac{\sum_{t=1}^n Z_t}{n} = \bar{Z}$

Z_1 หมายถึง ค่าพยากรณ์ของอนุกรมเวลา ณ ช่วงเวลาแรก

และเมื่อ $t = 2, 3, \dots, n$ $Z_t = S_{t-1}$

สามารถหาค่า S_t ได้จาก

$$S_t = \alpha Z_t + (1 - \alpha) S_{t-1} \quad \text{เมื่อ } t = 2, 3, \dots, n$$

โดย S_t หมายถึง ค่าปรับให้เรียบ ณ ช่วงเวลาที่ t

S_{t-1} หมายถึง ค่าปรับให้เรียบ ณ ช่วงเวลาที่ $t-1$

α หมายถึง ค่าคงที่ในการทำให้เรียบ โดย $0 \leq \alpha \leq 1$

Z_t หมายถึง ค่าจริงของอนุกรมเวลา ณ ช่วงเวลาที่ t

Z_t หมายถึง ค่าพยากรณ์ของอนุกรมเวลา ณ ช่วงเวลาที่ t

n หมายถึง จำนวนข้อมูลจริงที่นำมาใช้ในการพยากรณ์

2. วิธีการทำให้เรียบแบบเอ็กซ์โพเนนเชียลโดยวิธีของ Holt (Holt's Exponential Smoothing)

เป็นเทคนิคที่ใช้ในการพยากรณ์ข้อมูลอนุกรมเวลาที่มีแนวโน้มเป็นเส้นตรง (linear trend) แต่ไม่มีฤดูกาล (seasonality) ซึ่งหากข้อมูลอนุกรมเวลาที่มีแนวโน้มที่เพิ่มขึ้นหรือลดลงในอัตราคงที่จะสามารถอธิบายได้โดยตัวแบบแนวโน้มเส้นตรง

$$Z_t = \beta_0 + \beta_1 t + \varepsilon_t$$

โดย Z_t หมายถึง ค่าจริงของอนุกรมเวลา ณ เวลาที่ t

β_0 หมายถึง พารามิเตอร์แสดงค่าในแนวระดับ

β_1 หมายถึง พารามิเตอร์แสดงความชันของแนวโน้ม

ε_t หมายถึง ค่าความคลาดเคลื่อนสุ่ม ณ ช่วงเวลาที่ t

สามารถเขียนตัวแบบพยากรณ์ข้อมูลล่วงหน้า ℓ ช่วงเวลา สำหรับ Z_t

$$\hat{Z}_{t+\ell} = S_t + (\hat{\beta}_t \times \ell) \quad \text{เมื่อ } t = 1, 2, 3, \dots, n$$

โดย $\hat{Z}_{t+\ell}$ หมายถึง ค่าพยากรณ์ล่วงหน้า ℓ ช่วงเวลา สำหรับ Z_t

S_t หมายถึง ค่าสถิติจากการปรับให้เรียบในแนวนระดับ ณ ช่วงเวลาที่ t

$$\text{ซึ่ง } S_t = \alpha Z_t + (1 - \alpha)(S_{t-1} + \beta_{t-1})$$

$\hat{\beta}_t$ หมายถึง ค่าสถิติจากการปรับให้เรียบในแนวความชัน ณ ช่วงเวลาที่ t

$$\text{ซึ่ง } \hat{\beta}_t = \gamma(S_t - S_{t-1}) + (1 - \gamma)\beta_{t-1}$$

α หมายถึง ค่าคงที่ในการทำให้เรียบในแนวนระดับ โดย $0 \leq \alpha \leq 1$

γ หมายถึง ค่าคงที่ในการทำให้เรียบในแนวโน้ม โดย $0 \leq \gamma \leq 1$

n หมายถึง จำนวนข้อมูลจริงที่นำมาใช้ในการพยากรณ์

สำหรับการคำนวณค่าเริ่มต้นของ S_t และ $\hat{\beta}_t$ สามารถทำได้ดังนี้

ค่าเริ่มต้นของ S_t คือ S_0 ซึ่ง

$$S_0 = Z_1 - \frac{1}{2}\beta_0$$

และค่าเริ่มต้นของ $\hat{\beta}_t$ คือ β_0 ซึ่ง

$$\beta_0 = \frac{Z_n - Z_1}{n - 1}$$

3. วิธีการทำให้เรียบแบบเอ็กซ์โพเนนเชียลโดยวิธีของ Holt-Winter

การพยากรณ์ด้วยวิธีของ Holt-Winter เหมาะสมกับการพยากรณ์ข้อมูลอนุกรมเวลาที่มีแนวโน้ม และมีความแปรผันจากฤดูกาล โดยทำการปรับปรุงจากวิธีของ Holt ด้วยการเพิ่มการประมาณค่าสำหรับ

ฤดูกาลซึ่งจะช่วยอธิบายส่วนประกอบของฤดูกาลของข้อมูลอนุกรมเวลา สำหรับข้อมูลที่มีแนวโน้มเส้นตรง และมีส่วนประกอบของฤดูกาลสามารถเลือกวิธีการพยากรณ์ของ Holt-Winter ได้ 2 วิธี คือ

(1) วิธีของ Holt-Winter สำหรับอนุกรมเวลาที่มีแนวโน้มเส้นตรงและความผันแปรมาจาก ฤดูกาลเชิงคูณ หากข้อมูลอนุกรมเวลามีแนวโน้มเส้นตรงและความผันแปรจากฤดูกาลแบบเชิงคูณ ส่วนประกอบของอนุกรมเวลาจะถูกรัดในรูปร้อยละซึ่งข้อมูลและอนุกรมเวลานั้นจะสามารถอธิบายได้โดย

$$Z_t = (\beta_0 + \beta_1 t) S_t + \varepsilon_t$$

โดย Z_t หมายถึง ค่าจริงของอนุกรมเวลา ณ เวลาที่ t

β_0 หมายถึง พารามิเตอร์แสดงค่าในแนวระดับ

β_1 หมายถึง พารามิเตอร์แสดงความชันของแนวโน้ม

S_t หมายถึง ส่วนประกอบของฤดูกาล ณ เวลาที่ t

ε_t หมายถึง ค่าความคลาดเคลื่อนสุ่ม ณ ช่วงเวลาที่ t

สามารถเขียนตัวแบบพยากรณ์ข้อมูลล่วงหน้า ℓ ช่วงเวลา สำหรับ Z_t

$$Z_{t+\ell} = (\hat{\beta}_{0,t} + \hat{\beta}_{1,t} \times \ell) \hat{S}_{t+\ell-S} \quad \text{เมื่อ } \ell = 1, 2, 3, \dots, n$$

เมื่อ $Z_{t+\ell}$ หมายถึง ค่าพยากรณ์ล่วงหน้า ℓ ช่วงเวลา สำหรับ Z_t

$\hat{\beta}_{0,t}$ หมายถึง ค่าสถิติจากการปรับให้เรียบในแนวระดับ ณ เวลาที่ t

$$\text{โดยที่ } \hat{\beta}_{0,t} = \alpha \left(\frac{Z_t}{\hat{S}_{t-S}} \right) + (1-\alpha) [\hat{\beta}_{0,t-1} + \hat{\beta}_{1,t-1}]$$

$\hat{\beta}_{1,t}$ หมายถึง ค่าสถิติจากการปรับให้เรียบในแนวความชัน ณ เวลาที่ t

$$\text{โดยที่ } \hat{\beta}_{1,t} = \gamma [\hat{\beta}_{0,t} - \hat{\beta}_{0,t-1}] + (1-\gamma) \hat{\beta}_{1,t-1}$$

$\hat{S}_t$ หมายถึง ส่วนประกอบฤดูกาล โดยที่ $\hat{S}_t = \delta \left(\frac{Z_t}{\hat{\beta}_{0,t}} \right) + (1-\delta) S_{t-S}$

- S หมายถึง ความยาวของฤดูกาล เช่น 1ปี $S=12$ เดือน
- α หมายถึง ค่าคงที่ในการทำให้เรียบในแนวระดับ โดย $0 \leq \alpha \leq 1$
- γ หมายถึง ค่าคงที่ในการทำให้เรียบในแนวโน้ม โดย $0 \leq \gamma \leq 1$
- δ หมายถึง ค่าคงที่ในการทำให้เรียบสำหรับฤดูกาล $0 \leq \delta \leq 1$
- n หมายถึง จำนวนข้อมูลจริงที่นำมาใช้ในการพยากรณ์

สำหรับการคำนวณค่าเริ่มต้นของ $\hat{\beta}_{0,t}$, $\hat{\beta}_{1,t}$ และ $\hat{S}_t$ สามารถทำได้ดังนี้

$$\text{ค่าเริ่มต้นของ } \hat{\beta}_{0,t} \text{ คือ } \hat{\beta}_{0,0} = \frac{Z_1 + Z_2 + Z_3 + \dots + Z_S}{S}$$

$$\text{ค่าเริ่มต้นของ } \hat{\beta}_{1,t} \text{ คือ } \hat{\beta}_{1,0} = \frac{(Z_{S+1} - Z_1) + (Z_{S+2} - Z_2) + (Z_{S+3} - Z_3) + \dots + (Z_{2S} - Z_S)}{S^2}$$

ค่าเริ่มต้นของ $S_{1-S}, S_{2-S}, S_{3-S}, \dots, S_{S-S}$, จะหาค่า $S_{1-S}, S_{2-S}, S_{3-S}, \dots, S_{S-S}$, จำนวน S ค่า โดยที่ $S_t = \frac{Z_t}{\hat{\beta}_{0,0}}$ เมื่อ $t = 1, 2, 3, \dots, S$

(2) วิธีของ Holt-Winter สำหรับข้อมูลอนุกรมเวลาที่มีแนวโน้มเส้นตรงและมีความผันแปรมาจากฤดูกาลเชิงบวก หากข้อมูลอนุกรมเวลาที่มีแนวโน้มเป็นเส้นตรงและมีความผันแปรจากฤดูกาลเชิงบวก ส่วนประกอบของอนุกรมเวลาจะมีหน่วยเดียวกับข้อมูลและอนุกรมเวลานั้นสามารถอธิบายได้โดย

$$Z_t = \beta_0 + \beta_1 t + S_t + \varepsilon_t$$

- โดย Z_t หมายถึง ค่าจริงของอนุกรมเวลา ณ เวลาที่ t
- β_0 หมายถึง พารามิเตอร์แสดงค่าในแนวระดับ
- β_1 หมายถึง พารามิเตอร์แสดงความชันของแนวโน้ม
- S_t หมายถึง ส่วนประกอบของฤดูกาล ณ เวลาที่ t
- ε_t หมายถึง ค่าความคลาดเคลื่อนสุ่ม ณ ช่วงเวลาที่ t

สามารถเขียนตัวแบบพยากรณ์ข้อมูลล่วงหน้า l ช่วงเวลา สำหรับ Z_t

$$Z_{t+l} = \hat{\beta}_{0,t} + (\hat{\beta}_{1,t} \times l) + \hat{S}_{t+l-S} \quad \text{เมื่อ } l=1,2,3,\dots$$

เมื่อ Z_{t+l} หมายถึง ค่าพยากรณ์ล่วงหน้า l ช่วงเวลา สำหรับ Z_t

$\hat{\beta}_{0,t}$ หมายถึง ค่าสถิติจากการปรับให้เรียบในแนวระดับ ณ เวลาที่ t

$$\text{โดยที่ } \hat{\beta}_{0,t} = \alpha(Z_t - \hat{S}_{t-S}) + (1-\alpha)(\hat{\beta}_{0,t-1} + \hat{\beta}_{1,t-1})$$

$\hat{\beta}_{1,t}$ หมายถึง ค่าสถิติจากการปรับให้เรียบในแนวความชัน ณ เวลาที่ t

$$\text{โดยที่ } \hat{\beta}_{1,t} = \gamma[\hat{\beta}_{0,t} - \hat{\beta}_{0,t-1}] + (1-\gamma)\hat{\beta}_{1,t-1}$$

$\hat{S}_t$ หมายถึง ส่วนประกอบฤดูกาล โดยที่ $\hat{S}_t = \delta(Z_t - \hat{\beta}_{0,t}) + (1-\delta)S_{t-S}$

S หมายถึงจำนวนของฤดูกาล ใน 1 รอบ เช่น 1ปี $S=12$

α หมายถึง ค่าคงที่ในการทำให้เรียบในแนวระดับ โดย $0 \leq \alpha \leq 1$

γ หมายถึง ค่าคงที่ในการทำให้เรียบในแนวโน้ม โดย $0 \leq \gamma \leq 1$

δ หมายถึง ค่าคงที่ในการทำให้เรียบสำหรับฤดูกาล $0 \leq \delta \leq 1$

สำหรับการคำนวณค่าเริ่มต้นของ $\hat{\beta}_{0,t}$ $\hat{\beta}_{1,t}$ และ $\hat{S}_t$ สามารถทำได้ดังนี้

$$\text{ค่าเริ่มต้นของ } \hat{\beta}_{0,t} \text{ คือ } \hat{\beta}_{0,0} = \frac{Z_1 + Z_2 + Z_3 + \dots + Z_S}{S}$$

$$\text{ค่าเริ่มต้นของ } \hat{\beta}_{1,t} \text{ คือ } \hat{\beta}_{1,0} = \frac{(Z_{S+1} - Z_1) + (Z_{S+2} - Z_2) + (Z_{S+3} - Z_3) + \dots + (Z_{2S} - Z_S)}{S^2}$$

ค่าเริ่มต้นของ S_t จะหาค่า $S_{1-S}, S_{2-S}, S_{3-S}, \dots, S_{S-S}$, จำนวน S ค่า โดยที่ $S_t = Z_t - \hat{\beta}_{0,0}$ เมื่อ

$$t=1,2,3,\dots,S$$

2.2.2 วิธีของ Box และ Jenkins หรือ Autoregressive Integrated Moving Average

Autoregressive Integrated Moving Average หรือ ARIMA เป็นหนึ่งในวิธีการพยากรณ์ด้วยวิธีพยากรณ์ของ Box และ Jenkins เสนอโดย George E. P. Box และ Gwilym M. Jenkins ผ่านหนังสือ Time Series Analysis: Forecasting and Control โดยเริ่มเผยแพร่ในปี ค.ศ.1970 และได้รับความนิยมจนถึงปัจจุบัน ARIMA เป็นรูปแบบที่อธิบายลักษณะการเคลื่อนไหวของข้อมูลอนุกรมเวลาที่มีค่าสังเกตมีสหสัมพันธ์ในตัวเองและมีความนิ่ง (Stationary) อย่างไรก็ตามถึงแม้ว่าข้อมูลอนุกรมเวลาจะไม่มีคามนิ่ง ก็สามารถใช้รูปแบบ ARIMA ได้ โดยการแปลงให้เป็นอนุกรมเวลาที่มีความนิ่งก่อนแล้วจึงกำหนดรูปแบบ ARIMA ให้กับอนุกรมเวลาใหม่ที่มีความนิ่ง

ตัวแบบอาร์มา ARIMA(p, d, q)

ในตัวแบบ ARIMA ประกอบด้วยกระบวนการ Autoregressive อันดับที่ p หรือ AR(p) และกระบวนการ Moving Average อันดับที่ q หรือ MA(q) โดย AR(p) คือ กระบวนการที่แสดงว่าค่าสังเกตค่าหนึ่ง ณ เวลาที่ t (Y_t) ถูกกำหนดขึ้นจากความสัมพันธ์ของตัวมันเองในอดีต $Y_{t-1}, Y_{t-2}, Y_{t-3}, \dots, Y_{t-p}$ เมื่อ p คือลำดับของคาบเวลาในอดีตที่เหมาะสมในการอธิบายค่า Y ณ เวลาที่ t รูปแบบของ Autoregressive process หรือ AR(p) สามารถแสดงได้ดังสมการที่ 2.1

$$Y_t = \theta_0 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t \quad (2.1)$$

กระบวนการ MA(q) คือ กระบวนการที่แสดงว่าค่าสังเกตค่าหนึ่ง ณ เวลาที่ t (Y_t) ถูกกำหนดขึ้นจากความคลาดเคลื่อนของข้อมูลอนุกรมเวลาในอดีต $\varepsilon_{t-1}, \varepsilon_{t-2}, \varepsilon_{t-3}, \dots, \varepsilon_{t-q}$ เมื่อ q คือลำดับของคาบเวลาในอดีตที่เหมาะสมในการอธิบายค่า Y ณ เวลาที่ t รูปแบบของ Moving average process หรือ MA(q) สามารถแสดงได้ดังสมการที่ 2.2

$$Y_t = \theta_0 + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (2.2)$$

เมื่อทำการหาผลต่าง d ครั้ง เพื่อให้ข้อมูลอนุกรมเวลามีความนิ่งและนำกระบวนการ AR(p) และ MA(q) มารวมกันสามารถเขียนได้ในรูปของ ARIMA(p, d, q) ในรูป Backshift Operator ดังสมการที่ 2.3

$$(1-B)^d(1-\phi_1B-\phi_2B^2-\dots-\phi_pB^p)Y_t = \theta_0 + (1-\theta_1B-\theta_2B^2-\dots-\theta_qB^q)\varepsilon_t \quad (2.3)$$

โดยที่ $\phi_1, \dots, \phi_p$	แทน	พารามิเตอร์แสดงค่าของ Autoregressive process อันดับที่ 1, 2, ..., p ตามลำดับ
$\theta_1, \dots, \theta_q$	แทน	พารามิเตอร์แสดงค่าของ Moving average process อันดับที่ 1, 2, ..., q ตามลำดับ
Y_t	แทน	ข้อมูลอนุกรมเวลา ณ เวลาที่ t
θ_0	แทน	พจน์ค่าคงที่
B	แทน	Backshift operator
p	แทน	อันดับที่ p ของกระบวนการ Autoregressive
d	แทน	อันดับที่ d ของการหาผลต่างที่ทำให้ข้อมูลเป็น stationary
q	แทน	อันดับที่ q ของกระบวนการ moving average
ε_t	แทน	ความคลาดเคลื่อนสุ่ม ณ เวลาที่ t

ขั้นตอนการวิเคราะห์ข้อมูลด้วยตัวแบบ ARIMA

1) ตรวจสอบความนิ่งของข้อมูล (Stationary Test) และการแปลงข้อมูลให้มีความนิ่ง

อนุกรมเวลาที่จะนำมาใช้เพื่อการพยากรณ์มักจะมีลักษณะการเคลื่อนไหวแตกต่างกัน โดยทั่วไปจะอธิบายการเคลื่อนไหวด้วยส่วนประกอบของอนุกรมเวลา คือ แนวโน้ม ฤดูกาล วัฏจักร และเหตุการณ์ที่ผิดปกติ ลักษณะของข้อมูลอนุกรมเวลา $\{y_t\}$ เมื่อ y_t หมายถึงค่าสังเกต ณ เวลาที่ t ในข้อมูลอนุกรมเวลา สามารถแบ่งได้ 2 ประเภทตามลักษณะความนิ่งของข้อมูลดังนี้

(1) อนุกรมเวลาที่มีความนิ่ง (Stationary series) หมายถึงอนุกรมเวลา $\{y_t\}$ มีค่าเฉลี่ยและความแปรปรวนของ y_t คงที่ และค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองที่ช่วงเวลาห่างกัน k ขึ้นกับค่า k อย่างเดียว ไม่ขึ้นกับเวลา t อนุกรมเวลา y_t จะเป็นอนุกรมเวลาที่มีความนิ่ง ตัวอย่างของอนุกรมเวลาที่มีความนิ่ง

เช่นอนุกรมเวลาที่มีลักษณะการเกิดคงที่ ได้แก่ อนุกรมเวลาของค่าความคลาดเคลื่อน อนุกรมเวลาที่ได้จากการแปลงค่าสังเกต

(2) อนุกรมเวลาที่ไม่มีความนิ่ง (Nonstationary series) หมายถึงอนุกรมเวลา $\{y_t\}$ ที่มีค่าเฉลี่ยหรือค่าความแปรปรวนของ y_t ไม่คงที่ที่เวลา t และค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองที่ช่วงเวลาห่าง k ไม่ขึ้นอยู่กับเฉพาะค่า k แต่ขึ้นอยู่กับเวลา t ด้วย โดยสำหรับอนุกรมเวลาที่มีแนวโน้มและฤดูกาลจะเป็นลักษณะของอนุกรมเวลาที่มีค่าเฉลี่ยและความแปรปรวนไม่คงที่จึงเป็นอนุกรมเวลาที่ไม่มีความนิ่ง

การทดสอบความนิ่งของข้อมูลอนุกรมเวลา

สามารถทดสอบความนิ่งของข้อมูลอนุกรมเวลาได้ โดยการทดสอบ Unit Root Test ซึ่งหนึ่งในวิธีการทดสอบคือ วิธีของ Augmented Dickey – Fuller หรือ ADF Test (Dickey & Fuller, 1979) ซึ่งมีแนวคิดคือ อนุกรมเวลาจะมีความนิ่งของข้อมูลหรือไม่จะทดสอบโดยสมการถดถอยในรูปผลต่างที่มีลักษณะตัวแบบเป็น AR(1) และจะมีลักษณะเป็น AR(p) เมื่อทำการเพิ่มจำนวนพจน์ Lagged Difference โดยจะทำการทดสอบกรณีใดกรณีหนึ่ง ได้แก่ กรณีไม่มีค่าคงที่และแนวโน้มเวลา กรณีมีค่าคงที่ และกรณีที่มีทั้งค่าคงที่และแนวโน้มเวลา

สามารถเขียนสมการถดถอยในรูปผลต่างทั้ง 3 กรณีของรูปแบบ AR(1) ได้ดังนี้

$$\text{กรณีไม่มีค่าคงที่และแนวโน้มเวลา} \quad \Delta Y_t = \delta Y_{t-1} + \varepsilon_t$$

$$\text{กรณีมีค่าคงที่} \quad \Delta Y_t = \alpha + \delta Y_{t-1} + \varepsilon_t$$

$$\text{กรณีมีค่าคงที่และแนวโน้มเวลา} \quad \Delta Y_t = \alpha + \delta Y_{t-1} + \beta t + \varepsilon_t$$

ซึ่งหากทำการเพิ่มจำนวน Lagged Difference เข้าไปในสมการถดถอยในรูปผลต่าง

$$\text{กรณีไม่มีค่าคงที่และแนวโน้มเวลา} \quad \Delta Y_t = \delta Y_{t-1} + \sum_{i=1}^p \phi_i \Delta Y_{t-i} + \varepsilon_t$$

$$\text{กรณีมีค่าคงที่} \quad \Delta Y_t = \alpha + \delta Y_{t-1} + \sum_{i=1}^p \phi_i \Delta Y_{t-i} + \varepsilon_t$$

กรณีมีค่าคงที่และแนวโน้มเวลา
$$\Delta Y_t = \alpha + \delta Y_{t-1} + \sum_{i=1}^p \phi_i \Delta Y_{t-i} + \beta t + \varepsilon_t$$

จากสมการที่ทำการเพิ่ม Lagged Difference สามารถทำการทดสอบ Augmented Dickey-Fuller

$H_0 : \delta = 0$ (ข้อมูลมี Unit Root ข้อมูลยังไม่นิ่ง)

$H_1 : \delta < 0$ (ข้อมูลไม่มี Unit Root ข้อมูลมีความนิ่งแล้ว)

กำหนดระดับนัยสำคัญ $\alpha = 0.05$

สถิติทดสอบ

$$t = \frac{\hat{\delta}}{S(\hat{\delta})}$$

เกณฑ์การตัดสินใจ

ทำการเปรียบเทียบค่าสถิติทดสอบ t กับค่าวิกฤติของตาราง ADF หากค่าสถิติ t มีค่าน้อยกว่าค่าวิกฤติจะปฏิเสธสมมติฐาน H_0 ข้อมูลอนุกรมเวลาไม่มี unit root ข้อมูลอนุกรมเวลานั้นจะมีความนิ่ง

การแปลงข้อมูลที่ไม่นิ่งให้เป็นข้อมูลที่มีความนิ่ง

การปรับปรุงข้อมูลที่ไม่นิ่งให้เป็นข้อมูลที่มีความนิ่งทำได้โดยการกำจัดแนวโน้ม กำจัดฤดูกาลหรือการใช้ฟังก์ชันคณิตศาสตร์มาใช้ในการแปลงข้อมูลอนุกรมเวลา วิธีที่จะใช้ในการแปลงข้อมูลให้มีความนิ่งจะขึ้นอยู่กับรูปแบบของข้อมูลอนุกรมเวลา มีรายละเอียดดังนี้ (ทรงศิริ แต่สมบัติ)

(1) หากอนุกรมเวลา $\{Y_t\}$ มีการเคลื่อนไหวเนื่องจากแนวโน้ม จะต้องทำการแปลงอนุกรมเวลาเดิม $\{Y_t\}$ เป็นอนุกรมเวลาใหม่ $\{Z_t\}$ ที่ไม่มีแนวโน้ม ซึ่ง $Z_t = \nabla^d Y_t$ โดย d เป็นจำนวนครั้งของการหาผลต่าง เช่น d เท่ากับหนึ่งจะได้

$$Z_t = \nabla Y_t = Y_t - Y_{t-1}$$

และเมื่อ d เท่ากับสองจะได้

$$Z_t = \nabla^2 Y_t = \nabla(Y_t - Y_{t-1}) = \nabla Y_t - \nabla Y_{t-1} = Y_t - 2Y_{t-1} + Y_{t-2}$$

โดยที่ d หรือจำนวนครั้งในการหาผลต่างจะขึ้นอยู่กับผลลัพธ์จากการทำอนุกรมเวลาใหม่ว่าข้อมูลมีความนิ่งแล้วหรือไม่ หากยังข้อมูลยังไม่นิ่งจะต้องทำการหาผลต่างต่อไปโดยใช้ d ที่เพิ่มขึ้นจนกว่าอนุกรมเวลาใหม่จะมีความนิ่ง ซึ่งหากอนุกรมเวลามีแนวโน้มเส้นตรงจะหาผลต่าง 1 ครั้ง และถ้าอนุกรมเวลามีแนวโน้มกำลังสองจะหาผลต่าง 2 ครั้ง

(2) ถ้าอนุกรมเวลา $\{Y_t\}$ มีการเคลื่อนไหวเนื่องจากฤดูกาลจะแปลงอนุกรมเวลาเดิม $\{Y_t\}$ เป็นอนุกรมเวลาใหม่ $\{Z_t\}$ ที่ไม่มีฤดูกาลจาก $Z_t = \nabla_L^D Y_t$ โดย D เป็นจำนวนครั้งของการหาผลต่างฤดูกาล L เป็นจำนวนฤดูกาลต่อปี ตัวอย่างเช่น อนุกรมเวลารายเดือนที่มี $L = 12$ เมื่อ $D = 1$ จะได้

$$Z_t = \nabla_{12} Y_t = Y_t - Y_{t-12}$$

และเมื่อ D เท่ากับสองจะได้

$$Z_t = \nabla_{12}^2 Y_t = \nabla_{12}(Y_t - Y_{t-12}) = Y_t - 2Y_{t-12} + Y_{t-24}$$

โดยที่จำนวนครั้งของการหาผลต่างฤดูกาลจะขึ้นอยู่กับผลลัพธ์จากการทำอนุกรมเวลาใหม่ว่าข้อมูลมีความนิ่งแล้วหรือไม่ หากยังไม่มีคามนิ่งของข้อมูลจะต้องทำการหาผลต่างต่อไปโดยใช้ D ที่เพิ่มขึ้นจนกว่าอนุกรมเวลาใหม่จะมีความนิ่ง

(3) หากอนุกรมเวลา $\{Y_t\}$ มีการเคลื่อนไหวเนื่องจากทั้งแนวโน้มและฤดูกาลจะทำการแปลงอนุกรมเดิม $\{Y_t\}$ เป็นอนุกรมเวลาใหม่ $\{Z_t\}$ ที่ไม่มีแนวโน้มและไม่มีฤดูกาลจาก

$$Z_t = \nabla^d \nabla_L^D Y_t$$

(4) หากอนุกรมเวลา $\{Y_t\}$ มีความแปรปรวนไม่คงที่นั่นคือค่าความแปรปรวนของ Y_t หรือ $V(Y)_t$ ที่เวลา t ไม่คงที่ จะต้องแปลง $\{Y_t\}$ ให้เป็นอนุกรมเวลาใหม่ $\{Z_t\}$ จาก $Z_t = \ln(Y_t)$ หรือ $Z_t = \sqrt{Y_t}$ ซึ่งอนุกรมเวลาใหม่จะมีความแปรปรวนคงที่

2) ขั้นตอนการระบุตัวแบบ ARIMA(p,d,q)

การระบุตัวแบบ ARIMA(p, d, q) จะกำหนดอันดับ d จากจำนวนครั้งในการหาผลต่างของข้อมูลจนกว่าข้อมูลจะมีความนิ่ง และ ระบุอันดับ p และ q โดยการนำข้อมูลอนุกรมเวลาที่มีความนิ่ง หรือข้อมูลอนุกรมเวลาที่แปลงให้มีความนิ่งแล้วสร้างกราฟแสดงค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเอง (Autocorrelation หรือ ACF) และสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน (Partial Autocorrelation หรือ PACF) การระบุอันดับ p และ q โดยใช้ ACF และ PACF มีรายละเอียดดังนี้

(1) ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเอง (Autocorrelation)

ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเอง ρ_k หรือ ACF เป็นค่าวัดความสัมพันธ์ระหว่างค่าสังเกตในอนุกรมเวลากับค่าสังเกตที่อยู่ห่างออกไปก่อนหน้า k ช่วงเวลา ใช้อธิบายว่า Y_t และ Y_{t-k} มีสหสัมพันธ์แบบทิศทางเดียวกันหรือตรงข้ามกัน และขนาดของความสัมพันธ์ ซึ่งมีค่าระหว่าง -1 ถึง 1 ρ_k จะสามารถประมาณค่าด้วย r_k ที่สามารถคำนวณได้จาก

$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2}$$

โดยที่	r_k	แทน	ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเอง k ช่วงเวลา
	k	แทน	ช่วงเวลาที่ห่างกัน k โดยที่ $k = 1, 2, 3, \dots$
	n	แทน	จำนวนของข้อมูลทั้งหมด

สามารถประมาณค่าความคลาดเคลื่อนมาตรฐานของ r_k ได้ด้วย $\frac{1}{\sqrt{n}}$ เมื่อ n คือจำนวนของข้อมูล

(2) ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน (Partial autocorrelation)

ค่าสัมประสิทธิ์สหสัมพันธ์ในตัวเองบางส่วน ρ_{kk} หรือ PACF เป็นค่าวัดความสัมพันธ์ระหว่างค่าสังเกตในอนุกรมเวลาที่อยู่ห่างกัน ช่วงเวลา เมื่อกำหนดให้ค่าสังเกตที่เวลาอื่น ๆ ที่มีระยะห่างไกลกว่าคงที่ เช่น การวัดความสัมพันธ์ระหว่าง Y_t และ Y_{t-k} เมื่อกำหนด Y_t ที่ช่วงเวลาห่างอื่น ๆ ที่มีระยะห่างสั้นกว่า Y_{t-k} เช่น $Y_{t-k+1}, Y_{t-k+2}, \dots, Y_{t-1}$ คงที่ ρ_{kk} ประมาณค่าได้จาก r_{kk} ที่คำนวณโดยใช้ r_k ที่ได้จากการคำนวณสัมประสิทธิ์สหสัมพันธ์ในตัวเองหรือ ACF

$$r_{kk} = \begin{cases} r_1 & \text{เมื่อ } k = 1 \\ \frac{r_k - \sum_{j=1}^{k-1} r_{k-1,j} r_{k-j}}{1 - \sum_{j=1}^{k-1} r_{k-1,j} r_j} & \text{เมื่อ } k = 2, 3, \dots \end{cases}$$


โดยที่ r_{kk} แทน ค่าสัมประสิทธิ์สหสัมพันธ์บางส่วนในตัวเอง k ช่วงเวลา
 r_k แทน ค่าสัมประสิทธิ์สหสัมพันธ์แบบออในตัวเอง k ช่วงเวลา
 k แทน ช่วงเวลาที่ห่างกัน k โดยที่ $k = 1, 2, 3, \dots$
 n แทน จำนวนของข้อมูลทั้งหมด

(3) ทำการระบุอันดับของ $AR(p)$ $MA(q)$ และ $ARMA(p, q)$ จากการพล็อตคอเรโลแกรม ACF และ PACF แต่ละช่วงเวลาย้อนหลังด้วยข้อมูลอนุกรมเวลาที่มีความนิ่งแล้วโดยจะทำการระบุตามหลักเกณฑ์ตามตาราง 2.1

ตารางที่ 2.1 แสดงการพิจารณา ACF และ PACF


ตัวแบบ	ACF	PACF
$AR(p)$	มีลักษณะลดลงเข้าใกล้ 0 แบบเอ็กซ์โพเนนเชียล หรือ คลื่นรูป sine	เกิดค่าที่ชัดเจน p ค่าแล้วหายไป
$MA(q)$	เกิดค่าที่ชัดเจน q ค่าแล้วหายไป	มีลักษณะลดลงเข้าใกล้ 0 แบบเอ็กซ์โพเนนเชียล หรือ คลื่นรูป sine
$ARMA(p, q)$	ลดลงเข้าใกล้ 0 หลัง lag ที่ q	ลดลงเข้าใกล้ 0 หลัง lag ที่ p

จากตารางที่ 2.1 หากคอเรโลแกรมของ ACF มีลักษณะลดลงเข้าใกล้ 0 หรือแกว่งนบ ในขณะที่ PACF เกิดค่าที่ชัดเจน p ค่าแล้วหายไป จะกำหนดด้วยตัวแบบ $AR(p)$ โดยอันดับ p จะถูกระบุด้วยจำนวนแท่งที่เกิดขึ้นมาชัดเจนบนคอเรโลแกรมของ PACF ก่อนที่จะหายไป เช่น $AR(1)$ คอเรโลแกรมของ ACF จะมีลักษณะลดลงเข้าใกล้ 0 และ PACF จะมีลักษณะเกิดขึ้นชัดเจน 1 แท่งแล้วหายไป




รูปที่ 2.1 ตัวอย่างการเกิดแบบจำลอง $AR(1)$ (นิภาพร, 2552)

หากคอเรโลแกรมของ ACF เกิดค่าที่ชัดเจน q ค่าแล้วหายไป ในขณะที่ PACF มีลักษณะลดลงเข้าใกล้ 0 หรือเข้าใกล้แกว่งนบ จะกำหนดด้วยตัวแบบ $MA(q)$ โดยอันดับ q จะถูกระบุด้วยจำนวนแท่งที่เกิดขึ้นมาชัดเจนบนคอเรโลแกรมของ ACF ก่อนที่จะหายไป เช่น $MA(1)$ คอเรโลแกรมของ ACF จะมีลักษณะเกิดขึ้นชัดเจน 1 แท่งแล้วหายไป และ PACF จะมีลักษณะลดลงเข้าใกล้ 0



รูปที่ 2.2 ตัวอย่างการเกิดแบบจำลอง $MA(1)$ (นิภาพร, 2552)

หากคอเรโลแกรมของ ACF และ PACF มีค่าลดลงหลักจาก lag ที่ p และ q ตามลำดับ จะกำหนดด้วยตัวแบบ ARMA(p, q) โดยอันดับ p และ q จะถูกระบุด้วยจำนวนแท่งที่ปรากฏขึ้นมาอย่างชัดเจนก่อนที่จะมีค่าลดลงในคอเรโลแกรมของ ACF และ PACF เช่น ARMA(2,1) คอเรโลแกรมของ ACF จะมีลักษณะเกิดขึ้นชัดเจน 2 แท่งแล้วค่อยๆลดลง และคอเรโลแกรมของ PACF จะมีลักษณะเกิดขึ้นชัดเจน 1 แท่งแล้วค่อยๆลดลง



รูปที่ 2.3 ตัวอย่างการเกิดแบบจำลอง ARMA(1,2) (นิภาพร, 2552)

3) การประมาณค่าพารามิเตอร์

การประมาณค่าพารามิเตอร์ของสมการพยากรณ์จากตัวแบบ ARIMA(p,d,q) ที่ได้จากการระบุอันดับ d จากจำนวนครั้งในการหาผลต่างของข้อมูล และระบุอันดับ p,q โดยการพิจารณาแผนภาพคอเรโลแกรมของ ACF และ PACF สามารถประมาณค่าพารามิเตอร์ 3 วิธี ได้แก่ วิธีการประมาณแบบง่าย วิธีกำลังสองน้อยที่สุดและวิธีภาวะน่าจะเป็นสูงสุด (ทรงศิริ, 2549) หลังจากประมาณค่าพารามิเตอร์และได้สมการตัวแบบ ARIMA(p,d,q) ในรูป Backshift Operator

$$(1-B)^d(1-\phi_1B-\phi_2B^2-\dots-\phi_pB^p)Y_t = \theta_0 + (1-\theta_1B-\theta_2B^2-\dots-\theta_qB^q)\varepsilon_t$$

ในขั้นต่อไปจะต้องทำตรวจสอบว่าพารามิเตอร์ในตัวแบบมีค่าแตกต่างจากศูนย์หรือไม่ ซึ่งหากทำการทดสอบแล้วพบว่าพารามิเตอร์ตัวใดมีค่าไม่แตกต่างจากศูนย์ หมายความว่าไม่มีพารามิเตอร์นั้นอยู่ในสมการตัวแบบที่พิจารณา จะต้องทำการกำหนดตัวแบบ ARIMA(p,d,q) ใหม่ การตรวจสอบว่าพารามิเตอร์ในตัวแบบ ARIMA ที่พิจารณามีค่าแตกต่างจากศูนย์หรือไม่ขึ้นตอนดังนี้

(1) การตรวจสอบพารามิเตอร์ Autoregressive process อันดับ p ว่ามีค่าแตกต่างจากศูนย์หรือไม่โดยการทดสอบสมมติฐาน

$$H_0 : \phi_p = 0 \quad \text{เมื่อ } p = 1, 2, 3, \dots$$

$$H_1 : \phi_p \neq 0 \quad \text{เมื่อ } p = 1, 2, 3, \dots$$

กำหนดระดับนัยสำคัญ $\alpha = 0.05$

สถิติทดสอบ

$$t = \frac{\hat{\phi}_p}{S_{\hat{\phi}_p}} \quad \text{มีการแจกแจงแบบ } t \text{ ที่ d.f.} = n-m$$

โดยที่	n	แทน	จำนวนข้อมูลที่ศึกษา
	m	แทน	จำนวนพารามิเตอร์ในตัวแบบ
	ϕ_p	แทน	พารามิเตอร์ Autoregressive process อันดับที่ p
	$\hat{\phi}_p$	แทน	ค่าประมาณพารามิเตอร์ Autoregressive process อันดับที่ p
	$S_{\hat{\phi}_p}$	แทน	ค่าประมาณของค่าความคลาดเคลื่อนมาตรฐาน ของ $\hat{\phi}_p$

เกณฑ์การตัดสินใจ

ปฏิเสธ H_0 ถ้า $|t| > t_{\alpha/2, n-m}$ หมายถึง พารามิเตอร์ ϕ_p มีค่าแตกต่างจากศูนย์
มีพารามิเตอร์ ϕ_p ในตัวแบบ

2) การตรวจสอบพารามิเตอร์ Moving average process อันดับ q ว่ามีค่าแตกต่างจากศูนย์หรือไม่โดยการทดสอบสมมติฐาน

$$H_0 : \theta_q = 0 \quad \text{เมื่อ } q = 1, 2, 3, \dots$$

$$H_1 : \theta_q \neq 0 \quad \text{เมื่อ } q = 1, 2, 3, \dots$$

กำหนดระดับนัยสำคัญ $\alpha = 0.05$

สถิติทดสอบ

$$t = \frac{\hat{\theta}_q}{S_{\hat{\theta}_q}} \quad \text{มีการแจกแจงแบบ } t \text{ ที่ d.f.} = n-m$$

โดยที่	n	แทน	จำนวนข้อมูลที่ศึกษา
	m	แทน	จำนวนพารามิเตอร์ในตัวแบบ
	θ_q	แทน	พารามิเตอร์ Moving average process อันดับที่ q
	$\hat{\theta}_q$	แทน	ค่าประมาณพารามิเตอร์ Moving average process อันดับ ที่ q
	$S_{\hat{\theta}_q}$	แทน	ค่าประมาณของค่าความคลาดเคลื่อนมาตรฐาน ของ $\hat{\theta}_q$

เกณฑ์การตัดสินใจ

ปฏิเสธ H_0 ถ้า $|t| > t_{\alpha/2, n-m}$ หมายถึง พารามิเตอร์ θ_q มีค่าแตกต่างจากศูนย์
มีพารามิเตอร์ θ_q ในตัวแบบ

4) การตรวจสอบความเหมาะสมของตัวแบบ

เมื่อระบุตัวแบบและประมาณค่าพารามิเตอร์ในตัวแบบแล้ว จะต้องทำการตรวจสอบความ
เหมาะสมของตัวแบบ ARIMA(p,d,q) โดยการตรวจสอบจะทำการทดสอบสมมติฐานคุณสมบัติของความ
คลาดเคลื่อนสุ่ม หากตัวแบบไม่ผ่านการทดสอบสมมติฐานอย่างน้อย 1 คุณสมบัติ หากนำตัวแบบไปใช้งาน
จะต้องใช้อย่างมีความระมัดระวัง การตรวจสอบคุณสมบัติของความคลาดเคลื่อนสุ่มมีขั้นตอนดังนี้

(1) ตรวจสอบสหสัมพันธ์ในตัวเองของความคลาดเคลื่อนสุ่มโดยใช้สถิติทดสอบ Box-

Ljung: Q

$$H_0 : \rho_{\varepsilon_t}(1) = \rho_{\varepsilon_t}(2) = \dots = \rho_{\varepsilon_t}(K) = 0$$

(ความคลาดเคลื่อนสุ่มไม่มีสหสัมพันธ์ในตัวเองตั้งแต่ Lag ที่ $k = 1, 2, 3, \dots, K$)

$$H_1 = \text{มี } \rho_{\varepsilon_t}(k) \text{ อย่างน้อย 1 ค่าที่แตกต่างจาก 0}$$

(ความคลาดเคลื่อนสุ่มมีสหสัมพันธ์ในตัวเองตั้งแต่ lag ที่ $k = 1, 2, 3, \dots, K$)

กำหนดระดับนัยสำคัญ $\alpha = 0.05$

สถิติทดสอบ

$$Q = n(n+2) \sum_{k=1}^K \frac{r_{\varepsilon_t}^2(k)}{(n-k)}; k = 1, 2, 3, \dots, K$$

โดย n แทน ขนาดตัวอย่างของข้อมูล

$r_{\varepsilon_t}(k)$ แทน สหสัมพันธ์ในตัวเองของความคลาดเคลื่อนที่ Lag k

$$\text{เมื่อ } r_{\varepsilon_t}(k) = \frac{\sum_{t=k+1}^n (e_t - \bar{e})(e_{t-k} - \bar{e})}{\sum_{t=1}^n (e_t - \bar{e})^2}$$

k แทน ช่วงเวลาที่พิจารณาค่าสหสัมพันธ์ในตัวเองของความคลาดเคลื่อน $k = 1, 2, 3, \dots, n/4$

K แทน จำนวน Lags ทั้งหมด

เกณฑ์การตัดสินใจ

ปฏิเสธ H_0 ถ้า $Q > \chi_{\alpha, K-m}^2$ หมายความว่า ความคลาดเคลื่อนสุ่มมีสหสัมพันธ์ในตัวเองตั้งแต่ lag ที่ 1 ถึง lag ที่ K เมื่อ $\chi_{\alpha, K-m}^2$ คือค่าจากตารางสถิติ Chi-Square ที่มี d.f. = $K - m$ ซึ่ง m หมายถึงจำนวนพารามิเตอร์ในตัวแบบที่นำมาตรวจสอบความเหมาะสม

(2) การตรวจสอบการแจกแจงปกติของความคลาดเคลื่อนสุ่มสามารถทำได้โดยวิธีการทดสอบโดยวิธี Kolmogorov-Smirnov ในการทดสอบนี้จะเปรียบเทียบระหว่างความถี่ที่สังเกตได้กับความถี่ที่

คาดหวัง โดยใช้ความถี่สะสมแทนความถี่ปกติ ซึ่งจะนำมาใช้ตรวจสอบว่าความคลาดเคลื่อนสุ่มที่ได้จาก
โมเดล ARIMA(p,d,q) ที่นำมาตรวจสอบนั้นมีการแจกแจงปกติหรือไม่ โดยการทดสอบสมมติฐาน

H_0 : ความคลาดเคลื่อนสุ่มของตัวแบบมีการแจกแจงปกติ

H_1 : ความคลาดเคลื่อนสุ่มของตัวแบบไม่มีการแจกแจงปกติ

กรณีที่ $n \leq 30$

$$K - S = D_n = \max(D_n^+, D_n^-)$$

$$= \max \left[\max \left| \frac{i}{n} - F(e) \right|, \max \left| F(e) - \frac{(i-1)}{n} \right| \right]; i = 1, 2, \dots, n$$

โดยที่ $F(e)$ คือ ความน่าจะเป็นสะสมของค่าประมาณของค่าความคลาดเคลื่อน

เกณฑ์การตัดสินใจ

ปฏิเสธ H_0 ถ้า $D_n > D_{n,\alpha}$ หมายถึงความคลาดเคลื่อนสุ่มของตัวแบบไม่มีการแจกแจง
ปกติ เมื่อ $D_{n,\alpha}$ ความคลาดเคลื่อนสุ่มของตัวแบบมีการแจกแจงปกติ คือ ค่าจากตารางสถิติ
Kolmogorov-Smirnov

กรณีที่ $n > 30$

$$Z = \frac{D_n}{\sqrt{\frac{1}{n}}}$$

$$= \sqrt{n} D_n$$

เกณฑ์การตัดสินใจ

ปฏิเสธ H_0 ถ้า $|Z| > Z_{\alpha/2}$ หมายความว่า ความคลาดเคลื่อนสุ่มไม่มีการแจกแจงปกติ
โดยที่ $Z_{\alpha/2}$ คือค่าจากตารางสถิติ Standard Normal

(3) การตรวจสอบความคลาดเคลื่อนสุ่มมีค่าเฉลี่ยไม่แตกต่างจากศูนย์สามารถทำการทดสอบโดยใช้ t-test โดยการทดสอบสมมติฐาน

H_0 : ความคลาดเคลื่อนสุ่มของตัวแบบมีค่าเฉลี่ยไม่แตกต่างจากศูนย์

H_1 : ความคลาดเคลื่อนสุ่มของตัวแบบมีค่าเฉลี่ยแตกต่างจากศูนย์

ระดับนัยสำคัญ $\alpha = 0.05$

สถิติทดสอบ

$$t = \frac{\bar{e}}{S_{\bar{e}}}$$

$$\text{และ } S_{\bar{e}} = \sqrt{\frac{\sum (e - \bar{e})^2}{n-1}}$$

โดย	$\bar{e}$	แทน	ค่าเฉลี่ยตัวอย่างของค่าความคลาดเคลื่อน
	$S_{\bar{e}}$	แทน	ส่วนเบี่ยงเบนมาตรฐานตัวอย่างของค่าความคลาดเคลื่อน
	e	แทน	ความคลาดเคลื่อน
	n	แทน	จำนวนข้อมูลตัวอย่าง

เกณฑ์การตัดสินใจ

ปฏิเสธ H_0 ถ้า $|t| > t_{\alpha/2, n-1}$ หมายความว่าความคลาดเคลื่อนสุ่มมีค่าเฉลี่ยแตกต่างจากศูนย์

(4) การตรวจสอบความแปรปรวนคงที่ของความคลาดเคลื่อนสุ่มโดยการทดสอบ Levene's Test โดยการทดสอบสมมติฐาน

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$$

$$H_1 : \text{มี } \sigma_i^2 \neq \sigma_j^2 \text{ อย่างน้อย 1 กลุ่ม ; } i=1,2,\dots,k \text{ และ } j = 1,2,\dots, k$$

กำหนดระดับนัยสำคัญ $\alpha = 0.05$

สถิติทดสอบ

$$W = \frac{(N-k)}{k-1} \frac{\sum_{i=1}^k N_i (\bar{Z}_{i.} - \bar{Z}_{..})^2}{\sum_{i=1}^k \sum_{j=1}^{N_i} (Z_{ij} - \bar{Z}_{i.})^2}$$

โดยที่	N	แทน	ขนาดตัวอย่างทั้งหมด
	N_i	แทน	ขนาดตัวอย่างกลุ่มที่ i
	$\bar{Z}_{i.}$	แทน	ค่าเฉลี่ยของกลุ่ม $Z_{i.}$
	$\bar{Z}_{..}$	แทน	ค่าเฉลี่ยรวมของ Z_{ij}

เกณฑ์การตัดสินใจ

ปฏิเสธ H_0 ถ้า $W > F_{\alpha, k-1, N-k}$ หมายความว่า ความคลาดเคลื่อนสุ่มมีความแปรปรวนไม่คงที่

โดย $F_{\alpha, k-1, N-k}$ คือค่าจากตารางการแจกแจง F ที่มีระดับนัยสำคัญ α และมี d.f. เป็น $k-1$ และ $N-k$

2.3 วิธีเทคนิคการเรียนรู้ของเครื่อง (Machine Learning)

การเรียนรู้ของเครื่องสามารถนิยามโดยกว้างว่าเป็น กระบวนการเชิงคำนวณที่ใช้ประสบการณ์ในการปรับปรุงประสิทธิภาพหรือสร้างการคาดการณ์ที่แม่นยำ ซึ่งประสบการณ์ในที่นี้หมายถึงการเรียนรู้ข้อมูลในอดีตที่มีอยู่แล้ว โดยการเรียนรู้ของเครื่องใช้วิธีอัลกอริทึมที่สามารถทำนายได้อย่างมีประสิทธิภาพและแม่นยำ อย่างไรก็ตามประสิทธิภาพของ Algorithm นี้ขึ้นอยู่กับข้อมูลที่นำมาใช้สำหรับการเรียนรู้ โดยทั่วไปแล้วการเรียนรู้ของเครื่องคือการผสมผสานความรู้ด้านวิทยาการคอมพิวเตอร์เข้ากับสถิติ ความน่าจะเป็น และการเพิ่มประสิทธิภาพ (Optimization) (Mohri et al., 2018)

การเรียนรู้แบบมีผู้สอน (Supervised Learning)


หลักการของการเรียนรู้แบบมีผู้สอน คือ กระบวนการทำงานที่โมเดลจะได้รับชุดข้อมูลฝึกสอนที่มีป้ายกำกับ (Labeled Examples) และใช้ข้อมูลเหล่านั้นเพื่อเรียนรู้รูปแบบในการทำนายค่าของข้อมูลที่ไม่เคยเห็นมาก่อน ซึ่งการเรียนรู้แบบมีผู้สอนจะถูกนำมาใช้กับปัญหาประเภทการทำนายประเภท (Classification) และการถดถอย (Regression) (Mohri et al., 2018) โดยการพยากรณ์อนุกรมเวลาเป็นปัญหาประเภทถดถอย (Regression) นั่นคือต้องการทำนายค่าต่อเนื่องจริงให้มีความผิดพลาดน้อยที่สุด โดยความผิดพลาดที่เกิดขึ้นคือความแตกต่างระหว่างค่าจริงและค่าทำนาย

การตรวจสอบความถูกต้องของโมเดล (Model Validation)

การตรวจสอบความถูกต้องของโมเดลคือขั้นตอนที่ใช้ประเมินว่าแบบจำลองที่ผ่านการฝึกสามารถพยากรณ์ได้ดีเพียงใด โดยทั่วไปในงานเรียนรู้ของเครื่องจะนิยมแบ่งข้อมูลฝึกบางส่วนออกมาเป็นชุดตรวจสอบ (validation set) หรือใช้วิธี Cross-Validation ซึ่งเป็นการแบ่งข้อมูลฝึกเป็นหลายส่วนเพื่อสลับกันใช้สำหรับการฝึกและการทดสอบ กระบวนการเหล่านี้ช่วยให้ได้ผลการประเมินที่เสถียรและใช้ข้อมูลได้อย่างมีประสิทธิภาพ อย่างไรก็ตาม สำหรับข้อมูลอนุกรมเวลา วิธีดังกล่าวยังไม่สามารถใช้ได้อย่างสมบูรณ์ เนื่องจากข้อมูลมีความหลากหลายสูง ทั้งความยาวของข้อมูล วิธีการในการสร้างแบบจำลองระยะเวลาที่ต้องการพยากรณ์ รวมถึงข้อมูลมีความสัมพันธ์กันตามลำดับเวลา นอกจากนี้หากมีการแบ่งข้อมูลแบบสุ่มร่วมด้วย อาจทำให้ผลลัพธ์การประเมินโมเดลก่อนนำไปใช้งานให้ผลที่ดูดีเกินจริง

จากข้อจำกัดของ Cross-validation ทำให้การตรวจสอบโมเดลด้วยวิธี Rolling Window เป็นแนวทางที่ตอบโจทย์ในสถานการณ์ที่ข้อมูลมีการเปลี่ยนแปลงไปตามช่วงเวลา โดยจะทำการแบ่งข้อมูลสำหรับการฝึกและทดสอบแบบเลื่อนหน้าต่าง โดยมีหลักการสำคัญคือการกำหนดความยาวของข้อมูลฝึก (Training Split) ให้คงที่ตลอดเวลา กล่าวคือ เมื่อเลื่อนจุดเริ่มต้น (Origin) ของการทดสอบไปข้างหน้า เช่น 3 ช่วงเวลา ข้อมูลฝึกก็จะตัดข้อมูลเก่าออก 3 จุดจากด้านซ้าย และเพิ่มข้อมูลใหม่ 3 จุดเข้ามาจากด้านขวา ทำให้โมเดลพยากรณ์ได้เรียนรู้จากข้อมูลล่าสุดที่สะท้อนสถานการณ์ปัจจุบันมากที่สุด การฝึกโมเดลด้วยวิธีนี้จึงช่วยลดความเสี่ยงที่แบบจำลองจะอิงกับข้อมูลเก่ามากเกินไป การอัปเดตหน้าต่างข้อมูล

อยู่เสมอจึงทำให้ผลการพยากรณ์มีความเหมาะสม และมีความทันสมัยต่อข้อมูลมากขึ้น อย่างไรก็ตาม แม้กลยุทธ์ Rolling Window จะมีข้อดีในด้านการสะท้อนลักษณะข้อมูลที่เปลี่ยนแปลงได้อย่างต่อเนื่อง แต่ก็ มีข้อจำกัดที่ต้องพิจารณา โดยเฉพาะต้นทุนทางการคำนวณ เนื่องจากทุกครั้งที่เลื่อนหน้าต่างข้อมูลไป ข้างหน้า โมเดลจำเป็นต้องถูกฝึกใหม่ซ้ำอีกครั้งตามชุดข้อมูลล่าสุด การดำเนินการในลักษณะนี้อาจใช้เวลา และทรัพยากรค่อนข้างมาก โดยเฉพาะเมื่อชุดข้อมูลมีขนาดใหญ่หรือช่วงเวลาที่ต้องการพยากรณ์มีความ ยาว แสดงตัวอย่างการตรวจสอบโมเดลด้วยวิธี Rolling Window ดังรูปที่ 2.4




รูปที่ 2.4 ตัวอย่างการตรวจสอบโมเดลด้วยวิธีการ Rolling Window

กลยุทธ์การพยากรณ์ล่วงหน้าหลายช่วงเวลาแบบ Direct (Direct strategy)

กลยุทธ์พยากรณ์ล่วงหน้าหลายช่วงเวลาแบบ Direct คือ การสร้างโมเดลพยากรณ์หลายก้าว ล่วงหน้าโดยแยกโมเดลเป็นโมเดลละ 1 ค่าพยากรณ์ เช่น ถ้าต้องการพยากรณ์ 10 วันข้างหน้า ก็จะต้อง สร้าง 10 โมเดล แต่ละโมเดลจะเรียนรู้ข้อมูลโดยตรง ไม่ต้องวนใช้ค่าพยากรณ์กลับมาช่วยในการพยากรณ์ หลายช่วงเวลา ทำให้เสี่ยงปัญหาความผิดพลาดที่สะสมจากการพยากรณ์ก้าวก่อนหน้าได้ ข้อเสียคือโมเดล แต่ละก้าวไม่เกี่ยวข้องกันเลย จึงไม่สะท้อนความสัมพันธ์ของค่าพยากรณ์ที่ได้ อีกทั้งยังใช้ทรัพยากรมาก เพราะจำนวนโมเดลที่ต้องสร้างขึ้นอยู่กับจำนวนก้าวที่ต้องการพยากรณ์ เช่น ต้องพยากรณ์ 100 ก้าว ก็ ต้องสร้าง 100 โมเดล ซึ่งทำให้ซับซ้อนและกินเวลามาก วิธีนี้มักจะใช้ร่วมกับเครื่องมือสมัยใหม่ เช่น โครงข่ายประสาทเทียม, K-nearest neighbors หรือการเรียนรู้แบบต้นไม้ตัดสินใจ เพื่อช่วยให้การ

พยากรณ์หลายช่วงเวลามีประสิทธิภาพมากขึ้นแสดงตัวอย่างของการใช้กลยุทธ์ Direct ในการพยากรณ์ ช่วงเวลาล่วงหน้า 3 ช่วงเวลาดังรูปที่ 2.5



รูปที่ 2.5 ตัวอย่างการสร้างโมเดลจำนวน 3 โมเดลเพื่อพยากรณ์ช่วงเวลาล่วงหน้า 3 ช่วงเวลา


การนำการเรียนรู้ของเครื่องมาใช้ในการพยากรณ์อนุกรมเวลามีหลายจุดที่ต้องพิจารณาเพื่อให้การพยากรณ์ได้ผลลัพธ์ที่มีประสิทธิภาพ เช่น การเลือกข้อมูลสำหรับเป็นข้อมูลนำเข้าเพื่อสร้างโมเดลพยากรณ์ กลยุทธ์การตรวจสอบโมเดล กลยุทธ์ที่นำมาใช้เพื่อพยากรณ์หลายช่วงเวลา รวมถึงการเลือกใช้ อัลกอริทึมให้มีความเหมาะสมต่อข้อมูลเนื่องจากแต่ละอัลกอริทึมจะมีคุณลักษณะเฉพาะแตกต่างกัน เช่น โครงข่ายประสาทเทียมแบบ LSTM ที่มีความสามารถในการรักษาข้อมูลในอดีตพร้อมปรับปรุงบริบทตามข้อมูลใหม่ที่ได้รับ และ XGBoost ที่มีหลักการคือการสร้างโมเดลย่อยหลายโมเดลแล้วสร้างโมเดลรวมแบบเป็นลำดับพร้อมทั้งมีความสามารถในการจัดการปัญหา Overfitting ในตัวเอง

2.3.1 Long-Short term memory

1) โครงข่ายประสาทเทียม (Artificial Neural Networks)


โครงข่ายประสาทเทียม (Artificial Neural Networks) เป็นเทคนิคการเรียนรู้ของเครื่อง (Machine Learning) ที่ได้รับความนิยม ซึ่งจำลองกลไกการเรียนรู้ของสิ่งมีชีวิต ระบบประสาทของมนุษย์ ประกอบด้วยเซลล์ที่เรียกว่า นิวรอน (Neurons) โดยนิวรอนเชื่อมต่อกันผ่าน แอกซอน (Axons) และเดนไดรต์ (Dendrites) บริเวณที่แอกซอนและเดนไดรต์เชื่อมต่อกันเรียกว่า ซินแนปส์ (Synapses) ซึ่งการ

เชื่อมต่อนี้แสดงดังรูปที่ 2.6 โดยความแข็งแกร่งของการเชื่อมต่อของไซแนปส์มักจะเปลี่ยนตามการตอบสนองต่อสิ่งเร้าภายนอก ซึ่งกระบวนการเปลี่ยนแปลงความแข็งแกร่งของการเชื่อมต่อไซแนปส์นี้เป็นกระบวนการที่ทำให้มนุษย์เกิดการเรียนรู้ แสดงได้ดังรูปที่ 2.6




รูปที่ 2.6 แบบจำลองโครงข่ายประสาททางชีววิทยา

โครงข่ายประสาทเทียมที่จำลองมาจากระบบประสาทของมนุษย์นี้จะมีหน่วยย่อยเรียกว่า Node เปรียบเสมือนเซลล์ประสาทประกอบด้วย Input Node สำหรับนำข้อมูลเข้า และ Output Node สำหรับนำข้อมูลออก แต่ละ Node มีเส้นโครงข่ายที่คล้ายเส้นประสาทเรียกว่า Edge ซึ่งจะเชื่อมต่อกับ Node ด้วยค่าน้ำหนักเฉพาะของแต่ละ Edge ค่าน้ำหนักนี้จะทำหน้าที่คล้ายไซแนปส์ของสิ่งมีชีวิตโดยจะทำงานร่วมกับฟังก์ชันกระตุ้นเพื่อนำไปสู่ผลลัพธ์ และเมื่อโครงข่ายประสาทเทียมนี้ได้รับการฝึกค่าน้ำหนักเหล่านี้จะถูกปรับเปลี่ยนไป เปรียบได้กับการเปลี่ยนแปลงของความแข็งแกร่งไซแนปส์ที่ทำให้มนุษย์เกิดการเรียนรู้ โครงสร้างแบบจำลองโครงข่ายประสาทเทียม และแบบจำลองโครงข่ายประสาทเทียมเปรียบเทียบกับระบบประสาทของมนุษย์สามารถแสดงได้ดังรูปที่ 2.7 และ รูปที่ 2.8




รูปที่ 2.7 แบบจำลองโครงข่ายประสาทเทียม



รูปที่ 2.8 แบบจำลองโครงข่ายประสาทเทียมเปรียบเทียบกับระบบประสาทของมนุษย์

สำหรับโครงข่ายประสาทเทียมแบบหลายชั้น (Multi-layer Neural Network) นิวรอนจะถูกเรียงเป็นชั้น โดยที่ชั้นข้อมูลนำเข้า (Input Layer) และชั้นข้อมูลนำออก (Output Layer) จะถูกคั่นกลางด้วยกลุ่มของชั้นซ่อน (Hidden Layer) โดยจะมีขั้นตอนการทำงานคือชั้นนำเข้าส่งข้อมูลไปตามโครงข่ายที่เชื่อมแต่ละ Node เข้าด้วยกัน เมื่อข้อมูลนำเข้าถูกส่งไปยัง Hidden Layer ข้อมูลจะถูกนำมาคำนวณด้วยค่าน้ำหนักและฟังก์ชันกระตุ้นจากนั้นส่งต่อข้อมูลไปยังทุกๆ Node ถัดไปที่อยู่ใน Hidden Layer เมื่อเสร็จสิ้นกระบวนการครบทุก Node ใน Hidden Layer แล้วจึงส่งข้อมูลไปยัง Output Layer ซึ่งจะทำให้ได้รับผลลัพธ์ในท้ายที่สุด โดยกระบวนการทำงานของโครงข่ายประสาทเทียมแบบหลายชั้นนี้สามารถแสดงได้ดังรูปที่ 2.9




รูปที่ 2.9 แสดงโครงสร้างและลำดับการทำงานของโครงข่ายประสาทเทียมแบบหลายชั้น

โดยผลลัพธ์ในขั้นตอนสุดท้ายที่ได้รับจากชั้นนำออกจะขึ้นอยู่กับ การนำโครงข่ายประสาทเทียมไปใช้ ซึ่งสามารถใช้งานได้กับการถดถอย (Regression) และการทำนายประเภท (Classification)

2) Recurrent Neural Network (RNN)

โครงข่ายประสาทเทียมแบบวนซ้ำ (Recurrent Neural Network หรือ RNN) ใช้หลักการเดียวกันกับโครงข่ายประสาททั่วไป (Neural Network) แต่มีความแตกต่างที่ RNN ทำงานเป็นลำดับได้ ผ่านการวนซ้ำใน Node กล่าวคือมีการนำข้อมูลที่ออกจาก Node วนกลับเข้าไปใน Node อีกครั้ง เพื่อใช้กับข้อมูลที่จะถูกนำเข้ามาใน Node เป็นลำดับถัดไปทำให้สามารถรักษา state ที่จดจำความสัมพันธ์ของข้อมูลที่เคยประมวลผลไปแล้วได้ การทำงานของ Node สำหรับ RNN แสดงได้ดังรูปที่ 2.10




รูปที่ 2.10 การวนซ้ำของ RNN จะมีการเก็บข้อมูลที่จะนำออกจาก Node มาใช้ร่วมกับข้อมูลถัดไป

จากที่ได้กล่าวว่า RNN สามารถจัดการกับข้อมูลที่มีความสัมพันธ์กันได้ เช่น ข้อมูลอนุกรมเวลา อย่างไรก็ตามหากความสัมพันธ์ที่เกิดขึ้นของข้อมูลมีระยะยาว ในทางทฤษฎี RNN สามารถจัดการกับข้อมูลที่มีความสัมพันธ์ระยะยาวได้ โดยการนำ RNN ไปใช้โดยการกำหนด Parameter แต่ในทางในทางปฏิบัติ RNN มักไม่สามารถเรียนรู้ข้อมูลที่มีความสัมพันธ์ระยะยาวได้อย่างมีประสิทธิภาพ (Olah, 2015)

3) หน่วยความจำระยะสั้นแบบยาว (Long-Short Term Memory)


หน่วยความจำระยะสั้นแบบยาว (Long-Short Term Memory หรือ LSTM) เป็นรูปแบบพิเศษของ RNN ที่สามารถเรียนรู้และจัดการกับความสัมพันธ์ระยะยาวและระยะสั้นได้อย่างมีประสิทธิภาพ

แนวคิดนี้ถูกนำเสนอครั้งแรกโดย Hochreiter & Schmidhuber (1997) และได้รับการปรับปรุงและเผยแพร่อย่างแพร่หลายจากงานวิจัยของนักวิจัยหลายคนในภายหลัง ในปัจจุบัน LSTM ถูกนำมาใช้แก้ไขปัญหากันอย่างแพร่หลายโดย LSTM ได้รับการพิสูจน์แล้วว่าสามารถทำงานได้อย่างยอดเยี่ยมในปัญหาหลากหลายประเภท หลักการทำงานของ LSTM แสดงได้ในรูปที่ 2.11



รูปที่ 2.11 แผนผังการทำงานของ LSTM

สิ่งสำคัญของ LSTM คือ cell state หรือเส้นแนวนอนที่อยู่บริเวณด้านบนของแผนภาพในรูปที่ 2.12 โดย LSTM มีความสามารถในการลบหรือเพิ่มข้อมูลเข้าไปใน Cell state อย่างระมัดระวังด้วยโครงสร้างที่เรียกว่า gates หรือประตูที่เป็นทางผ่านของข้อมูลที่สามารถเลือกได้ว่าจะให้ข้อมูลใดผ่านได้ หรือข้อมูลใดไม่สามารถผ่านได้



รูปที่ 2.12 cell gate ที่จะทำหน้าที่ลบข้อมูลที่ไม่ควรเก็บและนำเข้าข้อมูลที่ไม่ควรจดจำ


ในขั้นแรก LSTM จะตัดสินใจว่าข้อมูลใดจะถูกลบและข้อมูลใดถูกนำออกผ่านชั้นซิกมอยด์ เรียกว่าฟอร์เก็ตเกต (Forget gate) ซึ่งรับค่า h_{t-1} และ x_t เข้าสู่สมการ (2.4) ผลลัพธ์ f_t ที่ได้จากฟอร์เก็ตเกตจะมีค่าระหว่าง 0 ถึง 1 โดย 0 หมายถึง ลบข้อมูลนี้ออกจาก State ก่อนหน้าทั้งหมด และ 1 หมายถึง เก็บข้อมูลใน State ไว้ต่อทั้งหมด

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.4)$$

ส่วนถัดไปจะเป็นการตัดสินใจว่าข้อมูลใหม่ใดจะถูกจัดเก็บใน cell state ประกอบไปด้วย 2 ส่วนย่อย คือ ชั้นซิกมอยด์เรียกว่าชั้นอินพุตเกต (Input gate layer) ที่จะตัดสินใจว่าค่าใดจะถูกปรับปรุงผ่านสมการ (2.5) และชั้นฟังก์ชัน tanh ที่จะสร้าง vector ที่เก็บค่าของค่าที่ต้องการนำเข้าไปใน cell state ผ่านสมการ (2.6) ซึ่งทั้งชั้นซิกมอยด์และชั้นฟังก์ชัน tanh จะถูกใช้ร่วมกันเพื่อปรับเปลี่ยน cell state ดังรูปที่ 2.13

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.5)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (2.6)$$




รูปที่ 2.13 การดำเนินการในชั้นซิกมอยด์และชั้น tanh ที่จะทำงานร่วมกัน
เพื่อนำเข้าข้อมูลที่ควรจดจำไปยัง cell state

จากที่กล่าวไว้ก่อนหน้านี้ถึงการลืมข้อมูล และการตัดสินใจเลือกข้อมูลที่จะถูกเพิ่มเข้าสู่ Cell state หลังจากได้ทำการตัดสินใจเรียบร้อยแล้วว่าจะทำการนำออกหรือเพิ่มข้อมูลใดเข้าสู่ Cell State ในขั้นตอน

ต่อไปคือการดำเนินการปรับปรุงข้อมูลใน Cell state ปัจจุบัน (C_t) ทำได้โดย การคูณ State ก่อนหน้า C_{t-1} ด้วย f_t เพื่อนำข้อมูลที่ต้องการจะลืมนอกจากนั้นบวกด้วย ($i_t \cdot \tilde{C}_t$) หรือข้อมูลที่เราต้องการนำเข้ามาเพิ่มใน Cell state ปัจจุบัน (C_t) ดังสมการ (2.7) และแสดงแผนภาพของขั้นตอนนี้ได้ดังรูปที่ 2.14

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (2.7)$$




รูปที่ 2.14 แสดงการนำข้อมูลออกและการเพิ่มข้อมูลเข้า Cell State C_t


ในขั้นตอนสุดท้ายจะเป็นการดำเนินการของข้อมูลที่จะเป็น Output โดยจะเริ่มจากชั้นซิกมอยด์ที่จะตัดสินใจว่าส่วนไหนของ Cell state ที่จะนำมาใช้ในกระบวนการเพื่อหา Output ดังสมการ (2.8) จากนั้นนำข้อมูลที่ต้องการใช้จาก Cell State เข้าสู่ฟังก์ชัน tanh ซึ่งทำให้ค่าที่ได้อยู่ระหว่าง -1 ถึง 1 ซึ่งจะนำไปคูณกับผลลัพธ์ที่ได้จากชั้นซิกมอยด์ดังสมการ (2.9) ทำให้ได้รับผลลัพธ์เฉพาะส่วนที่เราต้องการ (h_t) ที่จะถูกส่งต่อไปยัง Node ถัดไป แสดงได้ดังรูปที่ 2.15 และการทำงานร่วมกันของโครงข่ายประสาทเทียม LSTM แบบหลายหน่วยแสดงได้ดังรูป 2.16

$$O_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.8)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (2.9)$$



รูปที่ 2.15 แสดงกระบวนการทำงานในขั้นตอนสุดท้ายก่อนจะส่งออกผลลัพธ์ h_t




รูปที่ 2.16 แสดงการทำงานร่วมกันของโครงข่ายประสาทเทียมแบบ LSTM หลายหน่วย

2.3.2 Extreme Gradient Boosting (XGBoost)

XGBoost เป็น เทคนิคการเรียนรู้ของเครื่องแบบเอ็นเซมเบิล (ensemble method) ซึ่งหมายถึง การผสมผสานแบบจำลองหลายตัวเข้าด้วยกันเพื่อให้ทำงานร่วมกันอย่างมีประสิทธิภาพโดยแบบจำลองแต่ละตัวที่ประกอบกันใน XGBoost เรียกว่า แบบจำลองพื้นฐาน (base learners) โดยแบบจำลองพื้นฐานที่นิยมใช้ในวิธีการเรียนรู้ XGBoost คือ วิธีต้นไม้ตัดสินใจ (Decision tree)


ต้นไม้ตัดสินใจ (Decision Tree)

ต้นไม้ตัดสินใจ หรือ Decision Tree เป็นอัลกอริทึมที่ใช้สำหรับงานประเภท Regression และ Classification โดยหากนำมาใช้สำหรับการทำนายค่าต่อเนื่อง (Continuous Variable) หรือ ใช้ในงานประเภท Regression จะถูกเรียกว่า Regression Tree และหากนำไปใช้สำหรับการทำนายค่าไม่ต่อเนื่อง หรือทำนายหมวดหมู่ (Category Variable) จะเรียกว่า Classification Tree สามารถแสดงการทำงานของต้นไม้ตัดสินใจสำหรับการทำนายค่าต่อเนื่องได้ดังรูปที่ 2.17



รูปที่ 2.17 แสดงตัวอย่างของการตัดสินใจของ Regression Tree สำหรับการทำนายค่าต่อเนื่อง

ต้นไม้ตัดสินใจเป็นโมเดลที่เลียนแบบกระบวนการตัดสินใจของมนุษย์ ผลลัพธ์ที่ได้จะมีลักษณะคล้ายแผนภาพต้นไม้ ซึ่งแสดงถึงการแบ่งปัจจัยในการตัดสินใจโดยมีส่วนประกอบ Node หรือจุดที่ใช้ในการตัดสินใจ Root node คือจุดเริ่มต้นของต้นไม้ตัดสินใจ Parent node คือ Node ที่ทำหน้าที่แบ่งข้อมูลออกเป็น Child node และเมื่อข้อมูลถูกแบ่งจนไม่สามารถแบ่งต่อได้อีก จะเรียก node นั้นว่า Leaf node ซึ่งจะเป็นผลลัพธ์สุดท้าย (Output) แสดงโครงสร้างส่วนประกอบของต้นไม้ได้ดังรูปที่ 2.18



รูปที่ 2.18 แสดงโครงสร้างส่วนประกอบของ Decision Tree

Ensemble Learning

วิธี Ensemble เป็นเทคนิคในการเรียนรู้ของเครื่องที่ช่วยเพิ่มความแม่นยำของโมเดล โดยการรวมผลลัพธ์จากโมเดลย่อยหลายตัวเข้าด้วยกัน ซึ่งการรวม Model ย่อยเข้าด้วยกันนี้จะสามารถช่วยลดความผิดพลาดที่อาจเกิดขึ้นจากโมเดลเดี่ยว และทำให้ได้ผลลัพธ์ที่มีความแม่นยำมากขึ้น

การเรียนรู้แบบ Boosting

สำหรับ Machine Learning Boosting หมายถึงเทคนิค Ensemble Learning ที่รวมหลายโมเดลย่อยเข้าด้วยกันแบบมีลำดับ (Sequential Ensemble Learning) กล่าวได้ว่าโมเดลย่อยแต่ละโมเดลจะทำงานต่อเนื่องกันแบบเป็นลำดับ ซึ่งกระบวนการนี้จะเป็นการเปลี่ยนโมเดลทำนายที่อ่อนแอ (Weak Learners) หรือโมเดลที่มีความสัมพันธ์กับค่าจริงในระดับต่ำ ให้กลายเป็นโมเดลทำนายที่แข็งแกร่ง (Strong Learners) หรือโมเดลที่สามารถทำนายหรือพยากรณ์ค่าจริงของข้อมูลได้ดีขึ้น โดยผลลัพธ์ที่ได้จากกระบวนการสร้างโมเดลทำนายหลายโมเดลแบบเป็นลำดับหรือที่เรียกว่าการ Boosting นี้สามารถช่วยเพิ่มความแม่นยำของโมเดลหลักที่มาจากการรวมโมเดลย่อยหลายๆโมเดลเข้าด้วยกันเพิ่มมากยิ่งขึ้น

การเรียนรู้แบบ XGBoost

XGBoost สำหรับการทำนายข้อมูลค่าต่อเนื่อง จะเริ่มเรียนรู้โดยการสร้างโมเดลการเรียนรู้ที่อ่อนแอขึ้นมาเป็นโมเดลแรก ได้ผลลัพธ์เป็น base score เขียนแทนด้วย b ซึ่งจะเป็นโมเดลที่ยังใช้ทำนายข้อมูลจริงไม่ได้มากนัก จากนั้นจึงทำการสร้างโมเดลต่อไปที่จะพยายามลดความผิดพลาดของโมเดลก่อนหน้า โดยความผิดพลาดที่เกิดขึ้นจะอยู่ในรูปความแตกต่างระหว่างค่าจริงกับค่าพยากรณ์ (Residual) ของแต่ละจุดข้อมูล กระบวนการการสร้างโมเดลเพื่อลดความผิดพลาดที่เกิดขึ้นจะทำการสร้าง Decision Tree ที่กำหนด Residual ของทุกจุดข้อมูลที่ได้จากผลลัพธ์การพยากรณ์จากการรวมทุกโมเดลที่มีอยู่แล้วก่อนหน้านี้ไว้ใน Root node หรือจุดเริ่มต้นของต้นไม้ตัดสินใจ จากนั้นจึงทำการสร้างเกณฑ์เพื่อแบ่ง residuals ซึ่งหากเงื่อนไขเป็นจริง residuals จะถูกส่งต่อไปยัง node ฝั่งซ้ายของ child node และหากเงื่อนไขไม่เป็นจริง residuals จะถูกส่งต่อไปยัง node ด้านขวาของ child node โดยเกณฑ์การแบ่งของ Parent node จะเลือกจากเกณฑ์ที่มีค่า Gain สูงที่สุดซึ่งสามารถคำนวณได้จาก Similarity Score (SS) ดังสมการที่ (2.10) ดังนี้

$$Gain = (SS_L + SS_R) - SS_{root} \quad (2.10)$$

โดย $Gain$ หมายถึง ค่าสำหรับคัดเลือกเกณฑ์ที่ดีที่สุดในการแบ่งข้อมูล

SS_L หมายถึง ค่า Similarity Score ของการตัดสินใจฝั่งซ้ายของ Node เมื่อทำการแบ่งข้อมูลตามเกณฑ์ที่กำหนด

SS_R หมายถึง ค่า Similarity Score ของการตัดสินใจฝั่งขวาของ Node เมื่อทำการแบ่งข้อมูลตามเกณฑ์ที่กำหนด

SS_{root} หมายถึง ค่า Similarity Score ของ root node

ซึ่ง SS_L , SS_R และ SS_{root} คำนวณได้จาก

$$Similarity\ Score\ (SS) = \frac{(\sum residuals)^2}{No.\ of\ residuals + \lambda}$$

โดย λ หมายถึง พารามิเตอร์ปรับค่า regularization ของการเรียนรู้

หลังจากทำการต้นไม้ตัดสินใจได้ทำการการแบ่งข้อมูลที่ดีที่สุด ต้นไม้ตัดสินใจจะทำการแบ่งข้อมูลต่อไปอีกเรื่อย ๆ ด้วยหลักการเดียวกันไปจนถึง leaf node หรือ node สุดท้ายที่ไม่สามารถแบ่งได้อีก

ในขั้นตอนต่อไปคือการสร้าง leaf node โดยการพยายามทำให้ค่าของ output value ที่ได้จากต้นไม้ตัดสินใจเมื่อนำไปรวมกับโมเดลที่มีอยู่ก่อนหน้านี้แล้ว จะมีความผิดพลาดจากการทำนายของโมเดลรวมใหม่ต่ำที่สุดเรียกว่าการเพิ่มประสิทธิภาพ (Optimization) โดยใช้ฟังก์ชันวัตถุประสงค์หรือฟังก์ชันที่จะพยายามทำให้ความผิดพลาดจากการทำนายต่ำที่สุด

$$\arg \min_{O_v} \sum_{i=1}^N L(y_i, p_i) + \frac{1}{2} \lambda O_v^2$$

โดย $L(y_i, p_i)$ หมายถึง Loss function ซึ่งใช้วัดความผิดพลาดจากการทำนายของ

โมเดล คำนวณจาก $L(y_i, p_i) = (y_i - p_i)^2$

y_i หมายถึง ข้อมูลจริงลำดับที่ i

p_i หมายถึง ผลลัพธ์จากการพยากรณ์ของข้อมูลจริงลำดับที่ i หลังจาก

รวมผลลัพธ์ จากต้นไม้ตัดสินใจ

λ หมายถึง พารามิเตอร์ปรับค่า regularization ของการเรียนรู้

O_v หมายถึง ผลลัพธ์จากต้นไม้ตัดสินใจ

ผลลัพธ์จากการทำนายหลังจากรวมผลลัพธ์จากต้นไม้ตัดสินใจสามารถเขียนได้ในรูป $p_i = b + O_v$ เมื่อ

b หมายถึงผลลัพธ์ base score ทำให้สามารถเขียนฟังก์ชันวัตถุประสงค์ ได้ดังนี้

$$\arg \min_{O_v} \sum_{i=1}^N L(y_i, b + O_v) + \frac{1}{2} \lambda O_v^2$$

การเพิ่มประสิทธิภาพดังกล่าวสามารถคำนวณให้ง่ายขึ้นโดยการประยุกต์ใช้สมการประมาณค่าเทย์เลอร์อันดับ 2 ดังสมการที่ (2.11)

$$f(x, y+a) = f(x, y) + a \cdot \frac{df(x, y)}{dy} + \frac{1}{2} a^2 \cdot \frac{d^2 f(x, y)}{dy^2} \quad (2.11)$$

เขียน $\sum_{i=1}^N L(y_i, b + O_v) + \frac{1}{2} \lambda O_v^2$ ในรูปสมการประมาณค่าเทย์เลอร์อันดับ 2 ได้ดังสมการที่ (2.12)

$$L(y_i; b + o_v) = L(y_i, b) + o_v \cdot \frac{dL(y_i, b)}{db} + \frac{1}{2} o_v^2 \cdot \frac{d^2 L(y_i, b)}{db^2} \quad (2.12)$$

นำสมการที่ 2.12 แทนค่าในฟังก์ชันวัตถุประสงค์

$$\arg \min_{O_v} \sum_i^N \left\{ L(y_i, b) + o_v \cdot \frac{dL(y_i, b)}{db} + \frac{1}{2} o_v^2 \cdot \frac{d^2 L(y_i, b)}{db^2} \right\} + \frac{1}{2} \lambda o_v^2$$

ซึ่งจะทำการเขียน $\frac{dL(y_i, b)}{db}$ แทนด้วย G สำหรับ **gradient** และ $\frac{d^2 L(y_i, b)}{db^2}$ แทนด้วย H สำหรับ

hessian เขียนผลลัพธ์จากประมาณค่าฟังก์ชันวัตถุประสงค์โดยประยุกต์จากการประมาณค่าเทย์เลอร์อันดับที่ 2 ได้ดังนี้

$$\arg \min_{O_v} \sum_i^N \left(L(y_i, b) + o_v \cdot G + \frac{1}{2} o_v^2 \cdot H \right) + \frac{1}{2} \lambda O_v^2$$

ทำการลบพจน์ที่จะไม่ทำให้ผลลัพธ์ที่นำไปรวมกับโมเดลใหม่มีความผิดพลาดน้อยที่สุดนั่นคือพจน์

$$L(y_i, b)$$

$$\arg \min_{O_v} o_v \cdot \sum_i^N G + \frac{1}{2} o_v^2 \cdot \sum_i^N H + \frac{1}{2} \lambda o_v^2$$

สามารถจัดรูปใหม่ได้ดังนี้

$$O_v = \frac{-\sum_{i=1}^N G}{\sum_{i=1}^N H + \lambda}$$

จากนั้นหาค่าต่ำสุดของสมการนี้โดยการหาอนุพันธ์เทียบกับ o_v และกำหนดให้สมการเท่ากับ 0 เนื่องจากความชันที่ตำแหน่งต่ำสุดหรือสูงสุดมีค่าเท่ากับ 0 ดังสมการที่ (2.13) และทำการจัดรูปสมการดังสมการที่ (2.14)

$$\frac{d}{do_v} \left(o_v \cdot \sum_{i=1}^N G + \frac{1}{2} o_v^2 \cdot \left(\sum_{i=1}^N H + \lambda \right) \right) = 0 \quad (2.13)$$

$$\sum_{i=1}^N G + o_v \cdot \left(\sum_{i=1}^N H + \lambda \right) = 0$$

$$O_v = \frac{-\sum_{i=1}^N G}{\sum_{i=1}^N H + \lambda} \quad (2.14)$$

จากนั้นหาค่าของ G และ H ดังสมการที่ (2.15) และ (2.16) เพื่อแก้สมการหาค่า o_v

$$\sum_{i=1}^N G = \sum_{i=1}^N \frac{dL(y_i, b)}{db} = \frac{1}{2} \sum_{i=1}^N \frac{d(y_i - b)^2}{db} = -\sum_{i=1}^N (y_i - b) \quad (2.15)$$

และ

$$\sum_{i=1}^N H = \sum_{i=1}^N \frac{d^2 L(y_i, b)}{db^2} = \frac{1}{2} \sum_{i=1}^N \frac{d^2 (y_i - b)^2}{db^2} = \sum_{i=1}^N 1 \quad (2.16)$$

จะได้สมการผลลัพธ์ดังสมการที่ (2.17)

$$O_v = \frac{\sum_{i=1}^N (y_i - b)}{\sum_{i=1}^N 1 + \lambda} \quad (2.17)$$

สามารถเขียนสมการคำนวณผลลัพธ์อย่างง่ายได้ดังสมการที่ (2.18)

$$O_v = \frac{\sum residuals}{No. of residuals + \lambda} \quad (2.18)$$

O_v จะเป็นผลลัพธ์จาก leaf node ของต้นไม้ตัดสินใจ ซึ่งจะเป็นผลลัพธ์จากการทำนายของต้นไม้ตัดสินใจในรอบนั้น และผลลัพธ์จากการทำนาย O_v จะถูกนำไปรวมกับผลลัพธ์ของตัวทำนายทั้งหมดที่มีอยู่ก่อนหน้า ผลลัพธ์จากการทำนายด้วยโมเดลใหม่ที่รวมผลลัพธ์จากต้นไม้ตัดสินใจสามารถแสดงได้ดังสมการที่ (2.16)

$$\text{ผลลัพธ์จากการทำนายด้วยโมเดลรวม} = b + \eta(T_1 + T_2 + \dots T_n) \quad (2.19)$$

โดยที่ b หมายถึง base score หรือผลลัพธ์จากโมเดลการเรียนรู้ที่อ่อนแอโมเดลแรก

η หมายถึง พารามิเตอร์อัตราการเรียนรู้

T_i หมายถึง ผลลัพธ์จากการทำนาย O_v ของต้นไม้ตัดสินใจที่ i

เมื่อ $i = 1, 2, 3, \dots, n$

ซึ่งกระบวนการสร้างต้นไม้ตัดสินใจจะเกิดขึ้นต่อไปจนกว่าแบบจำลองทั้งหมดจะไม่สามารถลดค่าความผิดพลาดลงได้อีก หรือถึงรอบการเรียนรู้ที่ตั้งไว้ล่วงหน้า

2.4 การเปรียบเทียบประสิทธิภาพการพยากรณ์

ความถูกต้องของการพยากรณ์จะขึ้นอยู่กับความคลาดเคลื่อนหรือความแตกต่างระหว่างค่าจริงและค่าพยากรณ์ นั่นคือหากค่าจริงกับพยากรณ์แตกต่างกันมาก จะมีความคลาดเคลื่อนจากการพยากรณ์สูง โดยความคลาดเคลื่อนคำนวณได้จาก

$$e_t = Y_t - \hat{Y}_t$$

โดยที่ e_t แทน ความคลาดเคลื่อนจากการพยากรณ์ ณ เวลาที่ t

Y_t แทน ค่าจริงของข้อมูล ณ เวลาที่ t

$\hat{Y}_t$ แทน ค่าพยากรณ์ของข้อมูล ณ เวลาที่ t

ค่าความคลาดเคลื่อน e_t จะนำไปใช้คำนวณค่าเปรียบเทียบประสิทธิภาพการพยากรณ์ดังนี้

1. ค่าเฉลี่ยความผิดพลาดสัมบูรณ์ หรือ Mean Absolute Deviation : MAD เป็นค่าวัดความถูกต้องที่จะทำการเฉลี่ยค่าความผิดพลาดของการพยากรณ์โดยไม่คำนึงทิศทางของความคลาดเคลื่อน มีหน่วยเดียวกับข้อมูล

$$MAD = \frac{1}{n} \sum_{i=1}^n |e_i|$$

2. ค่ารากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง หรือ Root Mean Square Error : RMSE เป็นค่ารากที่สองของความแตกต่างระหว่างค่าจริงและค่าพยากรณ์มีหน่วยเดียวกับค่าสังเกต คำนวณได้ดังนี้

$$RMSE = \sqrt{\frac{\sum_{i=1}^n e_i^2}{n}}$$

3. ค่าเฉลี่ยร้อยละของความคลาดเคลื่อนสัมบูรณ์ หรือ Mean Absolute Percentage Error : MAPE เป็นค่าได้จากการหาอัตราส่วนขนาดของความผิดพลาดต่อค่าจริงและเฉลี่ยในรูปของร้อยละ ไม่มีหน่วย เหมาะกับการเปรียบเทียบอนุกรมเวลาหลายชุดที่หน่วยวัดต่างกัน คำนวณได้จาก

$$MAPE = \frac{\sum_{i=1}^n \left| \frac{e_i}{Y_i} \right| \times 100}{n}$$

2.5 งานวิจัยที่เกี่ยวข้อง

Sharma (2016) ได้ทำการศึกษาการพัฒนาแบบจำลองการพยากรณ์ราคาทองคำในประเทศไทย อินเดีย โดยใช้ข้อมูลตัวอย่างที่นำมาศึกษาคือราคาทองคำรายเดือนในหน่วยรูปีอินเดียต่อทรอยออนซ์ โดยใช้ข้อมูลตั้งแต่วันที่ 1 มกราคม 1995 ถึง 1 มิถุนายน 2014 ในการสร้างตัวแบบพยากรณ์ และใช้ข้อมูลจนถึงวันที่ 1 มิถุนายน 2014 เพื่อสร้างตัวแบบพยากรณ์ด้วยวิธี Box-Jenkins Autoregressive Integrated Moving Average (ARIMA) ตามระเบียบวิธีของ Box-Jenkins หลายตัวแบบ ทำการเปรียบเทียบโดยพบว่าตัวแบบที่เหมาะสมที่สุดสำหรับการพยากรณ์ราคาทองคำรายเดือนในประเทศไทย อินเดียคือ ARIMA (3,1,3)

Yang (2018) ได้ทำการศึกษาการพยากรณ์ราคาทองคำรายวันตั้งแต่เดือนกรกฎาคม 2013 ถึงเดือนมิถุนายน 2018 เพื่อที่จะทำการพยากรณ์และวิเคราะห์ราคาทองคำรายวัน (ดอลลาร์สหรัฐ) ตั้งแต่ครั้งแรกของเดือนกรกฎาคมปี 2018 โดยใช้แบบจำลอง ARIMA ใช้ค่า AC, PAC, AIC, BIC เพื่อประมาณความแม่นยำของโมเดล ผลลัพธ์ศึกษาพบว่าแบบจำลอง ARIMA(3,1,2) เป็นแบบจำลองที่ดีที่สุดในการพยากรณ์ราคาทองคำในหน่วยดอลลาร์สหรัฐ

Khalid & Halim (2019) ได้ทำการศึกษาหาตัวแบบที่ดีที่สุดในการพยากรณ์ราคาทองคำ และทำการพยากรณ์ราคาทองคำในปี 2018 โดยใช้วิธีการพยากรณ์ของ Box-Jenkins ข้อมูลที่ใช้ในงานวิจัยมาจาก investing.com ตั้งแต่ปี 2015 ถึงปี 2017 โดยใช้เกณฑ์ในการเปรียบเทียบ MAPE ผลจากการศึกษาพบว่า แบบจำลอง ARIMA(1,1,1) เป็นแบบจำลองที่ดีที่สุดในการพยากรณ์ราคาทองคำ มีค่า MAPE เท่ากับ 0.02%

Makala and Li (2021) ได้ทำการศึกษาเปรียบเทียบวิธีการพยากรณ์ 2 วิธีระหว่างวิธี ARIMA ซึ่งเป็นวิธีการทางอนุกรมเวลา กับ SVM ซึ่งเป็นการประยุกต์ใช้เทคนิคการเรียนรู้ของเครื่องมาใช้ในการพยากรณ์ข้อมูลอนุกรมเวลา โดยใช้ข้อมูลราคาทองคำรายวันจาก World Gold Council ตั้งแต่ปี ค.ศ. 1979 ถึงปี ค.ศ. 2019 ในการวิเคราะห์ ใช้เกณฑ์ RMSE และ MAPE มาใช้เปรียบเทียบประสิทธิภาพการพยากรณ์ ผลการศึกษาพบว่า SVM มีความแม่นยำในการพยากรณ์สูงกว่าวิธี ARIMA โดยมีค่า RMSE เท่ากับ 0.028 และ MAPE เท่ากับ 2.5 ในขณะที่ ARIMA มีค่า RMSE เท่ากับ 36.18 และ MAPE สูงถึง 2897

Fawzy, Rady, & Fattah (2020) ได้ทำการศึกษาเปรียบเทียบประสิทธิภาพของการพยากรณ์อนุกรมเวลาตัวแปรเดียว (Univariate Time Series) ด้วยเทคนิคการเรียนรู้ของเครื่อง 2 วิธี ได้แก่ Support Vector Machine หรือ SVM และ K-Nearest Neighbor หรือ K-NN ข้อมูลที่ใช้สำหรับการเรียนรู้คือราคาทองคำรายเดือนตั้งแต่เดือนพฤศจิกายน ค.ศ. 1979 ถึง เดือนธันวาคม ค.ศ. 2019 รวม 362 จุดข้อมูล เปรียบเทียบประสิทธิภาพด้วย RMSE ผลลัพธ์จากการศึกษาพบว่าแบบจำลอง SVM มี

ประสิทธิภาพดีกว่า K-NN ในการพยากรณ์ราคาทองคำรายเดือนโดยมีค่า RMSE เท่ากับ 33.77 ในขณะที่วิธี K-NN มีค่า RMSE เท่ากับ 70.01

Nwokike et al., (2020) ได้ทำการศึกษาเปรียบเทียบวิธีการพยากรณ์อนุกรมเวลาด้วยเทคนิคการเรียนรู้ของเครื่องแบบโครงข่ายประสาทเทียม (Artificial Neural Network) ในการพยากรณ์ราคาทองคำรายเดือนในหน่วยดอลลาร์สหรัฐและเซนต์ต่อทรอยออนซ์ โดยใช้ข้อมูลตั้งแต่เดือนตุลาคม ค.ศ. 2004 จนถึง เดือนกุมภาพันธ์ ค.ศ. 2020 โดยมีโครงข่ายประสาทเทียมที่กำหนดไว้ 17 แบบ โดยใช้ค่าเปรียบเทียบ MSE และ พบว่าแบบที่มีจำนวนเซลล์ประสาท 2 เซลล์ในชั้นอินพุต 6 เซลล์ในชั้นซ่อน และ 1 เซลล์ในชั้นเอาต์พุตตามลำดับ (ANN(2-6-1)) มีความเหมาะสมสำหรับการพยากรณ์ราคาทองคำรายเดือนมากที่สุดโดยมีค่า MSE เท่ากับ 0.6511 และ MAE เท่ากับ 0.0375


บทที่ 3

วิธีดำเนินการวิจัย

ในบทนี้จะกล่าวถึงวิธีการดำเนินการวิจัยเปรียบเทียบกับวิธีการพยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซีย-ยูเครน โดยใช้วิธีการพยากรณ์ Smoothing Exponential , ARIMA , การเรียนรู้ของเครื่องแบบ LSTM และ การเรียนรู้ของเครื่องแบบ XGBoost มีวิธีการดำเนินการวิจัยดังนี้

3.1 การเก็บรวบรวมและลักษณะของข้อมูล

การวิจัยครั้งนี้ใช้ข้อมูลทุติยภูมิ โดยเป็นข้อมูลอัตราแลกเปลี่ยนทองคำต่อดอลลาร์สหรัฐ (XAU/USD) รวมข้อมูลวันที่ 24 กุมภาพันธ์ พ.ศ. 2565 ถึงวันที่ 14 กุมภาพันธ์ พ.ศ. 2568 รวมทั้งสิ้น 773 วัน เก็บรวบรวมวันจันทร์ถึงวันศุกร์ ไม่ปรากฏข้อมูลวันเสาร์และวันอาทิตย์ ในชุดข้อมูลมีข้อมูลที่เก็บรวบรวม ได้แก่ วันเดือนปี ราคาต่ำสุด ราคาเปิด ราคาสูงสุด ราคาต่ำสุด และอัตราการเปลี่ยนแปลง ในการวิจัยนี้จะใช้ราคาต่ำสุดในการสร้างตัวแบบและทดสอบเปรียบเทียบวิธีการพยากรณ์แสดงข้อมูลได้ดังรูปที่ 3.1



รูปที่ 3.1 ข้อมูลอัตราแลกเปลี่ยนทองคำต่อดอลลาร์สหรัฐในกรอบเวลาที่จะนำมาวิเคราะห์ข้อมูล

ข้อมูลร้อยละ 80 ช่วงเวลาแรกนับจากวันที่ 24 กุมภาพันธ์ 2565 ถึงวันที่ 10 กรกฎาคม พ.ศ. 2567 จะถูกใช้สำหรับสร้างตัวแบบพยากรณ์ และข้อมูลช่วงเวลาสุดท้ายจำนวนร้อยละ 20 ของข้อมูลทั้งหมดตั้งแต่วันที่ 11 กรกฎาคม พ.ศ. 2567 ถึงวันที่ 14 กุมภาพันธ์ พ.ศ. 2568 จะถูกใช้สำหรับการ

ทดสอบประสิทธิภาพของตัวแบบด้วยสถิติเปรียบเทียบประสิทธิภาพการพยากรณ์ 3 ค่า ได้แก่ ค่าเฉลี่ยความผิดพลาดสัมบูรณ์ (MAD) ค่ารากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง (RMSE) และค่าเฉลี่ยร้อยละของความคลาดเคลื่อนสัมบูรณ์ (MAPE)

3.2 เครื่องมือที่ใช้ในการวิจัย

เครื่องมือที่ใช้ในการวิเคราะห์ข้อมูลราคาทองคำด้วยวิธีปรับให้เรียบแบบเอกซ์โพเนนเชียล, ARIMA และวิธีการเรียนรู้ของเครื่องแบบ LSTM และ XGBoost ในครั้งนี้ จะใช้การเขียนโปรแกรมทางสถิติ R เวอร์ชัน 4.4.2 และภาษา Python version 3.10.8 ผ่านโปรแกรม RStudio ซึ่งคำสั่งของการวิเคราะห์ทั้ง 4 วิธีจะถูกแสดงในภาคผนวก

3.3 การวิเคราะห์ข้อมูล

การวิเคราะห์ข้อมูลเพื่อหาวิธีพยากรณ์ที่เหมาะสมสำหรับการพยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซียและยูเครน โดยใช้ตัวแบบปรับให้เรียบ ARIMA LSTM และ XGBoost มีขั้นตอนดังนี้

3.3.1 ขั้นตอนการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยวิธีปรับให้เรียบแบบเอกซ์โพเนนเชียล

- (1) ตรวจสอบส่วนประกอบของอนุกรมเวลา ได้แก่ แนวโน้ม และ ฤดูกาล
- (2) เลือกตัวแบบพยากรณ์ด้วยวิธีปรับให้เรียบจากส่วนประกอบอนุกรมเวลา
- (3) สร้างตัวแบบพยากรณ์
- (4) ทดสอบประสิทธิภาพตัวแบบพยากรณ์ที่ได้โดยการพยากรณ์ข้อมูลชุดทดสอบ และคำนวณค่าสถิติวัดประสิทธิภาพ

3.3.2 ขั้นตอนการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยวิธี ARIMA

- (1) ทำการตรวจสอบว่าข้อมูลอนุกรมเวลาที่นำมาวิเคราะห์มีลักษณะคงที่ (Stationary) คือ มีค่าเฉลี่ยคงที่และมีความแปรปรวน ซึ่งสามารถทำการทดสอบด้วย ADF Test หากข้อมูลอนุกรมเวลาอย่างไม่จำเป็นต้องปรับข้อมูลให้มีคุณสมบัติความนิ่งก่อนโดยการแปลงด้วย Natural Logarithms ให้กับข้อมูล

อนุกรมเวลาที่มีความแปรปรวนไม่คงที่ และทำการหาผลต่างอันดับที่ d แบบไม่มีฤดูกาล (Nonseasonal Difference) ให้กับข้อมูลอนุกรมเวลาที่มีแนวโน้ม เพื่อให้อนุกรมเวลามีค่าเฉลี่ยคงที่

(2) เมื่อข้อมูลมีลักษณะคงที่แล้วจะทำการพล็อตกราฟแสดงค่าฟังก์ชันสหสัมพันธ์ในตัวเอง (ACF) และค่าฟังก์ชันสหสัมพันธ์ในตัวเองส่วนย่อย (PACF) เพื่อหาอันดับของ p และอันดับของ q ตามลำดับ

(3) นำอันดับ p และอันดับของ q และ d หากมีการหาผลต่าง ที่ได้จากข้อ (1) และข้อ (2) มาสร้างตัวแบบที่เป็นไปได้ ซึ่งแทนด้วย ARIMA (p,d,q) โดยตัวแบบที่เป็นไปได้อาจมีมากกว่า 1 ตัวแบบ

(4) นำตัวแบบที่เป็นไปได้แต่ละตัวแบบมาประมาณค่าของพารามิเตอร์ในตัวแบบด้วยวิธีภาวะความน่าจะเป็นสูงสุด หลังจากนั้นจะทำการทดสอบพารามิเตอร์แต่ละตัวว่าอยู่ในสมการตัวแบบหรือไม่

(5) คำนวณค่าพยากรณ์และความคลาดเคลื่อนจากการพยากรณ์ด้วยตัวแบบที่ได้จากข้อ (4)

(6) ตรวจสอบความเหมาะสมของตัวแบบโดยการวิเคราะห์คุณสมบัติของความคลาดเคลื่อน ได้แก่ ตรวจสอบสหสัมพันธ์ในตัวเอง โดยใช้สถิติทดสอบ Box-Ljung: Q ตรวจสอบการแจกแจงปกติ โดยใช้สถิติทดสอบของ Kolmogorov – Smirnov ตรวจสอบว่าค่าเฉลี่ยไม่แตกต่างจากศูนย์ โดยใช้ t – test ตรวจสอบความแปรปรวนคงที่ โดยการทดสอบ Levene's Test

(7) เลือกตัวแบบที่เหมาะสมที่จะนำไปใช้เปรียบเทียบวิธีการพยากรณ์

(8) ทดสอบประสิทธิภาพตัวแบบพยากรณ์ที่ได้โดยการพยากรณ์ข้อมูลชุดทดสอบ และคำนวณค่าสถิติวัดประสิทธิภาพ

3.3.3 ขั้นตอนการการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยวิธีการเรียนรู้ของเครื่องแบบ LSTM

(1) ก่อนทำการสร้างตัวแบบพยากรณ์ด้วยโครงข่ายประสาทเทียม LSTM เตรียมข้อมูลฝึกให้มีความนิ่งเพื่อเพิ่มประสิทธิภาพการพยากรณ์ล่วงหน้าหลายช่วงด้วยวิธีการเรียนรู้เชิงลึกตามแนวทางของ Livieris & Pintelas (2022)

(2) กำหนดค่าไฮเพอร์พารามิเตอร์ที่สำคัญของการเรียนรู้แบบ โดยจะกำหนดในลักษณะของสถาปัตยกรรมของโมเดล LSTM ที่ประกอบไปด้วย 5 ชั้น ได้แก่ 2 ชั้น LSTM ที่ทำการประมวลผล และ 3 ชั้น Dense ที่ทำการแปลงค่าจากชั้น LSTM ให้กลับมาอยู่ในรูปผลลัพธ์จากการพยากรณ์ตาม

แนวทางของ Yiyang (2023) โดยจะทำการหาค่าชุดของ output shape แต่ละชั้นที่ให้ผลลัพธ์ที่ดีที่สุดหลายๆแบบที่กำหนดไว้ล่วงหน้า แสดงลักษณะของการเรียนรู้ด้วยโครงข่ายประสาทเทียมแบบ LSTM ที่กำหนดให้มีชั้น LSTM 2 ชั้นและชั้น Dense 3 ชั้น โดยการหนดให้ชั้นแรกส่งข้อมูลออกเป็นลำดับได้ดังตารางที่ 3.1

ตารางที่ 3.1 ลักษณะที่กำหนดทั้ง 5 ชั้นของวิธีการเรียนรู้แบบ LSTM เพื่อสร้างตัวแบบพยากรณ์

ประเภท Layer	คำอธิบาย
lstm (LSTM)	(None, time steps, units)
lstm_1 (LSTM)	(None, units)
dense (Dense)	(None, units)
dense_1 (Dense)	(None, units)
dense_2 (Dense)	(None, units)

พารามิเตอร์ถูกกำหนดตามแต่ละชั้น ซึ่งระบุโดยลักษณะของข้อมูล Output ที่ได้จากชั้นนั้น กำหนดในรูป (Batch, Time steps, Units) เมื่อต้องการส่งข้อมูลออกทุกกระบวนการในการประมวลผลจากเวลาย้อนหลัง (Return_Sequence = TRUE) และ (Batch, Units) เมื่อต้องการส่งข้อมูลออกมาจากชั้นนั้นเพียงผลลัพธ์สุดท้าย (Return_Sequence = FALSE) โดย Batch แทนจำนวนข้อมูลที่จะถูกแบ่งนำเข้าไปในแต่ละครั้งของการเรียนรู้, Time steps แทน เวลาที่มองย้อนหลัง และ Units แทน จำนวนหน่วยประมวลผลในชั้นนั้น การทำงานจะผ่านกระบวนการ 5 ชั้น โดยผ่านกระบวนการของชั้น lstm ซึ่งเป็นชั้นสำหรับการประมวลผลข้อมูลด้วยหน่วย LSTM จำนวน 2 ชั้น และ ชั้น dense ซึ่งเป็นชั้นที่จะทำการแปลงข้อมูลให้ที่ผ่านกระบวนการให้อยู่ในรูปแบบที่เหมาะสมสำหรับการส่งข้อมูลออกเป็นผลลัพธ์ของการทำนายจำนวน 3 ชั้น

การออกแบบการเรียนรู้และโครงสร้างแต่ละชั้น LSTM ในการศึกษาครั้งนี้ ได้ทำการกำหนดพารามิเตอร์การหลายค่า ได้แก่ ค่าอัตราการเรียนรู้ (learning rate), จำนวนรอบการเรียนรู้ (epochs), จำนวนข้อมูลนำเข้า (input size) และ จำนวนหน่วยย่อยของแต่ละชั้น (units) โดยค่าของแต่ละพารามิเตอร์ถูกตั้งไว้ในช่วงหรือระดับที่เหมาะสมล่วงหน้า จากนั้นจึงนำค่าทั้งหมดมาผสมกันเป็นชุดการ

ทดลองที่แตกต่างกัน เพื่อสร้างแบบจำลองหลายรูปแบบ แต่ละชุดที่นำมาใช้ทดลองจะถูกนำมาประเมิน โดยผลการทดลองแต่ละครั้งที่ได้จากทุกชุดพารามิเตอร์เหล่านี้จะถูกนำไปเปรียบเทียบและเลือกชุดที่ให้ ความแม่นยำสูงสุดในขั้นตอนการประเมินด้วย Rolling Window Cross Validation ชุดค่าที่ถูกเลือกจะ ถูกนำไปในการการสร้างโมเดลด้วยข้อมูลฝึกเพื่อนำมาวัดประสิทธิภาพการพยากรณ์ด้วยโครงข่ายประสาท เทียมแบบ LSTM บนข้อมูลทดสอบต่อไป อย่างไรก็ตามการศึกษานี้สามารถกำหนดค่าต่างๆ สำหรับการ เรียนรู้ของโครงข่ายประสาทเทียมให้มีความหลากหลายในเบื้องต้นเท่านั้นเนื่องจากข้อจำกัด ด้านทรัพยากรในการคำนวณ ช่วงของการหาค่าเหมาะสมที่สุดของแต่ละไฮเพอร์พารามิเตอร์และจำนวน หน่วยย่อยในแต่ละชั้น มาจากการทดลองวัดประสิทธิภาพเมื่อปรับเปลี่ยนค่าไฮเพอร์พารามิเตอร์นั้นเพียง ตัวเดียวเพื่อหาว่าไฮเพอร์พารามิเตอร์ดังกล่าวควรหาค่าที่เหมาะสมในช่วงใดที่จะทำให้การเรียนรู้มี ประสิทธิภาพมากขึ้น แสดงค่าที่กำหนดไว้ล่วงหน้าสำหรับการหาค่าเหมาะสมที่สุดของจำนวนข้อมูลนำเข้า และไฮเพอร์พารามิเตอร์การเรียนรู้ดังตารางที่ 3.2 และค่าที่กำหนดสำหรับจำนวนหน่วยย่อยแต่ละชั้นดัง ตารางที่ 3.3

ตารางที่ 3.2 ค่าที่กำหนดสำหรับหาค่าที่เหมาะสมของจำนวนข้อมูลนำเข้าและไฮเพอร์พารามิเตอร์

ไฮเพอร์พารามิเตอร์	ค่าที่กำหนด
Input size	10,20
Learning rate	0.001,0.1
epochs	50

ตารางที่ 3.3 output shape ที่กำหนดเพื่อหาค่าที่เหมาะสมสำหรับจำนวนหน่วยแต่ละ Layer

ประเภท Layer	Batch Size	Time steps	Units
lstm (LSTM)	None	(Time steps มีค่า เท่ากับ input size)	50,100
lstm_1 (LSTM)	None	-	32, 64
dense (Dense)	None	-	32, 64
dense_1 (Dense)	None	-	32, 64
dense_2 (Dense)	None	-	1

(3) นำวิธีโครงข่ายประสาทเทียม LSTM ที่กำหนดลักษณะและไฮเพอร์พารามิเตอร์ที่ดีที่สุดแล้ว ไปฝึกกับข้อมูลฝึกจำนวน 155 โมเดล โดยแต่ละโมเดลถูกออกแบบให้พยากรณ์ค่าของช่วงเวลาที่จะเจาะจง เช่น เมื่อให้จุดสุดท้ายของข้อมูลฝึกเป็นเวลา t โมเดลที่ 1 จะใช้ในการพยากรณ์ช่วงเวลา $t+1$ โมเดลที่ 2 ใช้ในการพยากรณ์ช่วงเวลา $t+2$ ไปจนถึงโมเดลที่ 155 สำหรับพยากรณ์ช่วงเวลา $t+155$ ตามกระบวนการพยากรณ์หลายช่วงเวลาล่วงหน้าแบบ Direct

(4) ทดสอบประสิทธิภาพโดยนำมาพยากรณ์ข้อมูลทดสอบโดยใช้ตัวแบบพยากรณ์ที่สร้างขึ้น และคำนวณค่าสถิติวัดประสิทธิภาพ

3.3.4 ขั้นตอนการการวิเคราะห์ข้อมูลอนุกรมเวลาด้วยวิธีการเรียนรู้ของเครื่องแบบ XGBoost

(1) หาผลต่างของข้อมูลอันดับที่ 1 เพื่อแก้ปัญหการพยากรณ์ค่านอกช่วงข้อมูลฝึกสำหรับการเรียนรู้แบบ XGBoost ที่ขาดความสามารถในการพยากรณ์ข้อมูลที่อยู่นอกช่วงข้อมูลฝึก (Extrapolation) ตามแนวทางของ Amat & Escobar (2025) ที่เผยแพร่ในเอกสารประกอบการใช้งานของไลบรารี SKforecast

(2) กำหนดค่าไฮเพอร์พารามิเตอร์ที่สำคัญที่จะนำมาใช้สำหรับการเรียนรู้ของเครื่องแบบ XGBoost ปรับปรุงจากแนวทางของ Liu (2024) จากนั้นกำหนดชุดตัวเลขที่จะทำการหาค่าที่เหมาะสมของแต่ละไฮเพอร์พารามิเตอร์มาทำการหาชุดค่าที่ดีที่สุด ประเมินผลลัพธ์ด้วย Time series validation แบบ Rolling forecast origin และเลือกใช้ชุดไฮเพอร์พารามิเตอร์ที่มีความแม่นยำสูงสุดในขั้นตอนการประเมินสำหรับการฝึกโมเดล ช่วงของการหาค่าที่เหมาะสมที่สุดของแต่ละไฮเพอร์พารามิเตอร์ มาจากการทดลองวัดประสิทธิภาพเมื่อทำการปรับค่าไฮเพอร์พารามิเตอร์นั้นเพียงตัวเดียวเพื่อหาว่าไฮเพอร์พารามิเตอร์ดังกล่าวควรหาค่าที่เหมาะสมในช่วงใดที่จะทำให้การเรียนรู้มีประสิทธิภาพมากขึ้น แสดงไฮเพอร์พารามิเตอร์ที่จะถูกนำมาใช้ในการหาค่าที่เหมาะสมที่สุดดังตารางที่ 3.4 และค่าที่กำหนดในการหาค่าที่เหมาะสมที่สุดดังตารางที่ 3.5

ตารางที่ 3.4 ไฮเพอร์พารามิเตอร์ที่กำหนดของวิธีการเรียนรู้แบบ XGBoost เพื่อสร้างตัวแบบพยากรณ์

พารามิเตอร์	คำอธิบาย
Minimum child weight	จำนวนข้อมูลขั้นต่ำในการแบ่ง Child Node ค่าที่น้อยลงจะทำให้ต้นไม้ตัดสินใจมีโอกาสแบ่ง Node มากขึ้น
Learning rate	อัตราการเรียนรู้ มีค่าตั้งแต่ 0 ถึง 1 ใช้ในการกำหนดค่าน้ำหนักของผลลัพธ์จากต้นไม้ตัดสินใจแต่ละรอบ
gamma	ค่าเกณฑ์ขั้นต่ำความผิดพลาดที่ลดลง ในการแบ่ง Node หากมีค่าสูงจะลดโอกาสในการแบ่ง Node ของต้นไม้
lambda	พารามิเตอร์ regularization
Max depth	ความลึกสูงสุดของต้นไม้
N_estimator	จำนวนโมเดลย่อยในการนำมาใช้สร้างโมเดลรวม

ตารางที่ 3.5 ค่าที่กำหนดสำหรับการหาค่าที่เหมาะสมของไฮเพอร์พารามิเตอร์

พารามิเตอร์	ค่าที่กำหนด
Minimum child weight	1, 3
Learning rate	0.01, 0.05
gamma	0.05, 0.1
lambda	0.1, 0.2
Max depth	6, 12
N_estimator	50, 100
จำนวนข้อมูลนำเข้า (วัน)	40, 80


(3) นำวิธีการเรียนรู้ XGBoost ที่กำหนดไฮเพอร์พารามิเตอร์ที่เหมาะสมที่สุดแล้วไปฝึกกับข้อมูลฝึกจำนวน 155 โมเดล โดยแต่ละโมเดลถูกออกแบบให้พยากรณ์ค่าของช่วงเวลาที่เจาะจง เช่น เมื่อให้จุดสุดท้ายของข้อมูลฝึกเป็นเวลา t โมเดลที่ 1 จะใช้ในการพยากรณ์ช่วงเวลาที่ $t+1$ โมเดลที่ 2 ใช้ในการ

พยากรณ์ช่วงเวลา $t+2$ ไปจนถึงโมเดลที่ 155 สำหรับพยากรณ์ช่วงเวลา $t+155$ ตามกระบวนการพยากรณ์หลายช่วงเวลาล่วงหน้าแบบ Direct


(4) ทดสอบประสิทธิภาพโดยนำมาพยากรณ์ข้อมูลทดสอบโดยใช้ตัวแบบพยากรณ์ที่สร้างขึ้น และคำนวณค่าสถิติวัดประสิทธิภาพ

3.3.5 การเปรียบเทียบประสิทธิภาพการพยากรณ์โดยใช้สถิติสำหรับการวัดประสิทธิภาพ


ทำการเปรียบเทียบประสิทธิภาพการพยากรณ์โดยใช้ ค่าเฉลี่ยความผิดพลาดสัมบูรณ์ หรือ Mean Absolute Deviation : MAD ค่ารากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง หรือ Root Mean Square Error : RMSE และ ค่าเฉลี่ยร้อยละของความคลาดเคลื่อนสัมบูรณ์ หรือ Mean Absolute Percentage Error : MAPE มาเปรียบเทียบเพื่อคัดเลือกวิธีการพยากรณ์ที่มีความเหมาะสมในการนำมาใช้พยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซีย-ยูเครนมากที่สุด




รูปที่ 3.2 แผนภาพขั้นตอนการวิจัย




รูปที่ 3.3 แผนภาพขั้นตอนการพยากรณ์ด้วยวิธีปรับให้เรียบแบบเอกซ์โพเนนเชียล



รูปที่ 3.4 แผนภาพขั้นตอนการพยากรณ์ด้วยวิธีของ Box และ Jenkins (ตัวแบบ ARIMA)



รูปที่ 3.5 แผนภาพขั้นตอนการพยากรณ์ด้วยโครงข่ายประสาทเทียมแบบ LSTM




รูปที่ 3.6 แผนภาพขั้นตอนการพยากรณ์ด้วยการเรียนรู้ของเครื่องแบบ XGBoost

บทที่ 4

ผลการวิจัยและอภิปรายผล

ผลการวิจัยในครั้งนี้จะประกอบด้วยผลการวิเคราะห์ข้อมูลในการสร้างตัวแบบพยากรณ์ราคาทองคำภายในกรอบเวลาสงครามระหว่างประเทศรัสเซียและยูเครนด้วยวิธีการพยากรณ์ทั้ง 4 วิธี ได้แก่ ผลการวิเคราะห์ข้อมูลด้วยวิธีปรับให้เรียบแบบเอ็กซ์โพเนนเชียล ผลการวิเคราะห์ข้อมูลด้วยวิธี ARIMA ผลการวิเคราะห์ข้อมูลด้วยวิธีการเรียนรู้ของเครื่องด้วยโครงข่ายประสาทเทียมแบบ LSTM และผลการวิเคราะห์ข้อมูลด้วยวิธีการเรียนรู้ของเครื่องแบบ XGBoost โดยใช้ข้อมูลสำหรับสร้างตัวแบบพยากรณ์และเป็นข้อมูลสำหรับฝึก (Training set) จำนวน 618 วัน ตั้งแต่วันที่ 24 กุมภาพันธ์ พ.ศ. 2565 ถึงวันที่ 10 กรกฎาคม พ.ศ. 2567 และนำตัวแบบพยากรณ์ที่ได้มาเปรียบเทียบกับประสิทธิภาพการพยากรณ์ด้วยข้อมูลทดสอบตั้งแต่วันที่ 11 กรกฎาคม พ.ศ. 2567 ถึงวันที่ 14 กุมภาพันธ์ พ.ศ. 2568 จำนวน 155 วัน

4.1 การเตรียมข้อมูลก่อนทำการพยากรณ์



รูปที่ 4.1 ข้อมูลอนุกรมเวลาชุดฝึกที่แบ่งมาจากร้อยละ 80 ช่วงเวลาแรกของข้อมูลทั้งหมด

จากการตรวจสอบลักษณะของข้อมูลฝึกพบว่าข้อมูลมีแนวโน้มและไม่มีฤดูกาล การพยากรณ์ด้วยวิธีการปรับให้เรียบแบบเอกซ์โพเนนเชียลจึงเลือกใช้วิธีการพยากรณ์ของโฮลท์ ในขั้นตอนต่อไปจะทำการตรวจสอบความนิ่งของข้อมูลเนื่องจากจะต้องทำให้ข้อมูลมีความนิ่งก่อนนำไปพยากรณ์ด้วยวิธีของ Box และ Jenkins, วิธีการเรียนรู้ของเครื่องด้วยโครงข่ายประสาทเทียมแบบ LSTM โดยจะทำการตรวจสอบความนิ่งด้วยการทดสอบ Augmented Dickey-Fuller Test ได้ผลลัพธ์ดังตารางที่ 4.1

ตารางที่ 4.1 ผลลัพธ์จากการทดสอบ Augmented Dickey-Fuller ข้อมูลฝึก

Dickey-Fuller	p-value
-2.7829	0.2469


สมมติฐานการทดสอบ

$H_0 : \delta = 0$ (ข้อมูลมี Unit Root ข้อมูลยังไม่นิ่ง)

$H_1 : \delta < 0$ (ข้อมูลไม่มี Unit Root ข้อมูลมีความนิ่งแล้ว)

จากตารางที่ 4.1 เนื่องจากสถิติที่ใช้ทดสอบความนิ่งของข้อมูลคือ Dickey-Fuller มีค่าเท่ากับ -2.7829 และมี p-value เท่ากับ 0.2469 ซึ่งมากกว่าระดับนัยสำคัญ $\alpha = 0.05$ จึงไม่ปฏิเสธสมมติฐานหลักที่ระดับนัยสำคัญ 0.05 หมายความว่าข้อมูลไม่มีความนิ่ง จะต้องทำการแปลงข้อมูลให้มีความนิ่งด้วยการหาผลต่างอันดับที่ 1 โดยจะทำการทดสอบ Augmented Dickey-Fuller Test อีกครั้งหลังทำการแปลงข้อมูล ได้ผลลัพธ์หลังจากการแปลงข้อมูลด้วยการหาผลต่างอันดับที่ 1 ดังรูปที่ 4.2

ลักษณะของข้อมูลฝึกหลังจากหาผลต่างครั้งที่ 1



รูปที่ 4.2 ข้อมูลฝึกหลังทำการหาผลต่างอันดับที่ 1

ตารางที่ 4.2 ผลลัพธ์จากการทดสอบ Augmented Dickey-Fuller Test ของข้อมูลฝึกหลังจากหาผลต่างอันดับที่ 1

Dickey-Fuller	p-value
-8.3439	0.01

สมมติฐานการทดสอบ

$H_0 : \delta = 0$ (ข้อมูลมี Unit Root ข้อมูลยังไม่นิ่ง)

$H_1 : \delta < 0$ (ข้อมูลไม่มี Unit Root ข้อมูลมีความนิ่งแล้ว)

จากตารางที่ 4.2 เนื่องจากสถิติที่ใช้ทดสอบความนิ่ง Dickey-Fuller มีค่า -8.3439 และมี p-value เท่ากับ 0.01 ซึ่งน้อยกว่าระดับนัยสำคัญ $\alpha = 0.05$ จึงปฏิเสธสมมติฐานหลักที่ระดับนัยสำคัญ 0.05 หมายความว่าข้อมูลมีความนิ่งแล้วสามารถใช้ในการสร้างตัวแบบหรือเป็นข้อมูลนำเข้าสำหรับวิธีการพยากรณ์ด้วย ARIMA และวิธีการเรียนรู้ของเครื่องแบบ LSTM สำหรับการสร้างโมเดลพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องแบบ XGBoost จะใช้ข้อมูลหลังจากหาผลต่างครั้งที่ 1 เป็นข้อมูลนำเข้าเพื่อแก้ปัญหาข้อจำกัดในการพยากรณ์ค่านอกช่วง

4.2 ผลการวิเคราะห์ข้อมูลด้วยวิธีปรับให้เรียบแบบเอ็กซ์โพเนนเชียล

จากรูปที่ 4.1 พบว่า อนุกรมเวลาราคาทองคำมีส่วนประกอบของแนวโน้ม และไม่มีฤดูกาล จึงเลือกใช้วิธีปรับให้เรียบแบบเอ็กซ์โพเนนเชียลของ Holt มาใช้ในการพยากรณ์ด้วยวิธีปรับให้เรียบแบบเอ็กซ์โพเนนเชียล จากการคำนวณค่าคงที่ในการทำให้เรียบในแนวระดับ α และค่าคงที่ในการทำให้เรียบในแนวโน้ม γ ค่าเริ่มต้นในแนวระดับ S_0 ค่าเริ่มต้นของความชันของแนวโน้ม β_0 ได้ผลลัพธ์ดังนี้

ตารางที่ 4.3 ผลลัพธ์จากการคำนวณค่าคงที่ในการทำให้เรียบในแนวระดับ ค่าคงที่ในการทำให้เรียบของแนวโน้ม ค่าเริ่มต้นในแนวระดับ ค่าเริ่มต้นของความชันของแนวโน้ม


พารามิเตอร์	ผลลัพธ์การวิเคราะห์
ค่าคงที่ในการทำให้เรียบในแนวระดับ (α)	0.9343
ค่าคงที่ในการทำให้เรียบของแนวโน้ม (γ)	0.0001
ค่าเริ่มต้นในแนวระดับ (S_0)	1,892.30
ค่าเริ่มต้นของความชันของแนวโน้ม (β_0)	0.804

จากการวิเคราะห์ข้อมูลสามารถเขียนสมการพยากรณ์ล่วงหน้า ℓ ช่วงเวลาจากข้อมูลชุดฝึก เมื่อกำหนดให้ t เป็นจุดสุดท้ายของข้อมูลชุดฝึก ดังนี้

$$\hat{Z}_{t+\ell} = 2370.6225 + 0.8034\ell$$

แสดงผลลัพธ์จากการพยากรณ์ล่วงหน้า 155 ช่วงเวลาบนข้อมูลสำหรับทดสอบ ได้ดังรูปที่ 4.3

ผลการพยากรณ์ราคาทองคำด้วยวิธีของ Holt




รูปที่ 4.3 แสดงผลลัพธ์จากการพยากรณ์ด้วยวิธีการปรับให้เรียบของ Holt

ตารางที่ 4.4 ค่าวัดประสิทธิภาพ MAD RMSE และ MAPE จากการพยากรณ์ด้วยวิธีการปรับให้เรียบแบบ เอ็กซ์โพเนนเชียลของโฮลท์


ค่าวัดความคลาดเคลื่อน	Holt's Exponential Smoothing
MAD	186.1688
RMSE	210.5272
MAPE	6.9454%

4.3 ผลการวิเคราะห์ข้อมูลด้วยวิธีการพยากรณ์ ARIMA

การพยากรณ์ด้วยวิธี ARIMA จะต้องทำการระบุ (p,d,q) จากคอเรโลแกรมของสหสัมพันธ์ในตัวเอง (ACF) และคอเรโลแกรมของสหสัมพันธ์ในตัวเองบางส่วน (PACF) จากข้อมูลอนุกรมเวลาที่มีความนิ่งแล้ว แสดงได้ดังรูปที่ 4.4 และ 4.5




รูปที่ 4.4 คอเรโลแกรมของสหสัมพันธ์ในตัวเองของราคาทองคำหลังจากหาผลต่างอันดับที่ 1



รูปที่ 4.5 คอเรโลแกรมของสหสัมพันธ์ในตัวเองบางส่วนราคาทองคำหลังจากหาผลต่างอันดับที่ 1

จากผลการพิจารณาคอเรโลแกรมของสหสัมพันธ์ในตัวเองและคอเรโลแกรมของสหสัมพันธ์บางส่วนตามที่แสดงในรูปที่ 4.4 และรูปที่ 4.5 พบว่า รูปแบบของ ACF และ PACF ยังไม่ปรากฏอย่างแน่ชัด จึงทำการหาผลต่างอันดับที่ 2 และทดสอบด้วย Augmented Dickey-Fuller Test เพื่อตรวจสอบ

ความนิ่ง หากข้อมูลมีความนิ่งแล้ว จะทำการพล็อตคอเรโลแกรมของสหสัมพันธ์ในตัวเอง และคอเรโลโลแกรมของสหสัมพันธ์ในตัวเองบางส่วนเพื่อทำการระบุตัวแบบ ARIMA ด้วยข้อมูลฝึกที่หาผลต่างอันดับที่ 2 แสดงผลลัพธ์การหาผลต่างข้อมูลฝึกอันดับที่ 2 ดังรูปที่ 4.6



รูปที่ 4.6 ข้อมูลฝึกหลังทำการหาผลต่างอันดับที่ 2

ตารางที่ 4.5 ผลลัพธ์จากการทดสอบ Augmented Dickey-Fuller หลังจากหาผลต่างอันดับที่ 2

Dickey-Fuller	p-value
-12.572	0.01


สมมติฐานการทดสอบ

$H_0 : \delta = 0$ (ข้อมูลมี Unit Root ข้อมูลยังไม่นิ่ง)


$H_1 : \delta < 0$ (ข้อมูลไม่มี Unit Root ข้อมูลมีความนิ่งแล้ว)

จากตารางที่ 4.5 เนื่องจากสถิติที่ใช้ทดสอบความนิ่งของข้อมูล Dickey-Fuller มีค่าเท่ากับ -12.572 และมี p-value เท่ากับ 0.01 ซึ่งน้อยกว่าระดับนัยสำคัญ $\alpha = 0.05$ จึงปฏิเสธสมมติฐานหลักที่

ระดับนัยสำคัญ 0.05 หมายความว่าข้อมูลมีความนิ่งแล้ว ในขั้นตอนต่อไปจะทำการกำหนดตัวแบบ ARIMA(p,d,q) ใหม่หลังจากหาผลต่างอันดับที่ 2



รูปที่ 4.7 คอเรโลแกรมของสหสัมพันธ์ในตัวเองของราคาทองคำหลังจากหาผลต่างอันดับที่ 2



รูปที่ 4.8 คอเรโลแกรมของสหสัมพันธ์ในตัวเองบางส่วนราคาทองคำหลังจากหาผลต่างอันดับที่ 2

จากรูปที่ 4.7 ลักษณะของสหสัมพันธ์ในตัวเองปรากฏอย่างชัดเจน ณ lag ที่ 1 แล้วลดลงอย่างรวดเร็ว และจากรูปที่ 4.8 สหสัมพันธ์ในตัวเองบางส่วนมีลักษณะลดลงเข้าใกล้ 0 จึงกำหนดตัวแบบ ARIMA(0,2,1) แล้วทำการประมาณค่าพารามิเตอร์ด้วยวิธีความน่าจะเป็นสูงสุด จากนั้นจึงตรวจสอบความมีนัยสำคัญของพารามิเตอร์ในตัวแบบนั้นคือทดสอบว่า θ_1 มีค่าแตกต่างจาก 0 หรือไม่ ได้ผลลัพธ์ดังนี้

ตารางที่ 4.6 การทดสอบความมีนัยสำคัญของพารามิเตอร์ในตัวแบบ ARIMA(0,2,1)

พารามิเตอร์	Coefficient	S.E. Coefficient	t	p-value
θ_1	-0.9964	0.0062	-160.86	0.0001

สมมติฐานการทดสอบ

$$H_0 : \theta_1 = 0 \quad \text{เมื่อ } q = 1, 2, 3, \dots$$

$$H_1 : \theta_1 \neq 0 \quad \text{เมื่อ } q = 1, 2, 3, \dots$$

จากตารางที่ 4.6 เนื่องจากสถิติที่ใช้ทดสอบความมีนัยสำคัญของพารามิเตอร์ θ_1 คือ t มีค่าเท่ากับ -160.86 และมี p-value เข้าใกล้ 0 ซึ่งมีค่าน้อยกว่าระดับนัยสำคัญ $\alpha = 0.05$ จึงปฏิเสธสมมติฐานหลัก หมายความว่าพารามิเตอร์ θ_1 ในตัวแบบ ARIMA(0,2,1) แตกต่างจาก 0 นั่นคือมีพารามิเตอร์ θ_1 มีอยู่ในตัวแบบ ได้สมการพยากรณ์ด้วยวิธีของ Box และ Jenkins ดังนี้

$$\hat{Y}_t = 2Y_{t-1} - Y_{t-2} + e_t - 0.996e_{t-1}$$

ในขั้นตอนต่อไป จะทำการตรวจสอบความเหมาะสมของตัวแบบ ARIMA(0,2,1) ที่ได้ โดยพิจารณาสมมติฐานเกี่ยวกับค่าคลาดเคลื่อนของตัวแบบ ได้แก่ การทดสอบสหสัมพันธ์ในตัวเองด้วย Ljung-Box test การทดสอบการแจกแจงปกติด้วย Kolmogorov-Smirnov test การทดสอบว่าเฉลี่ยของค่าคลาดเคลื่อนไม่แตกต่างจากศูนย์ด้วย t-test และการทดสอบความแปรปรวนคงที่ด้วย Levene's test เพื่อประเมินว่าตัวแบบมีความเหมาะสมในการพยากรณ์หรือไม่ดังตารางที่ 4.7-4.10

ตารางที่ 4.7 ผลการทดสอบสหสัมพันธ์ของค่าคลาดเคลื่อนด้วย Box-Ljung test

d.f.	ACF	Q	p-value
5	0.0221	12.2420	0.0316

สมมติฐานการทดสอบ

$$H_0 : \rho_{\varepsilon_t}(1) = \rho_{\varepsilon_t}(2) = \dots = \rho_{\varepsilon_t}(K) = 0$$

(ความคลาดเคลื่อนสุ่มไม่มีสหสัมพันธ์ในตัวเองตั้งแต่ Lag ที่ $k = 1, 2, 3, \dots, K$)

$$H_1 = \text{มี } \rho_{\varepsilon_t}(k) \text{ อย่างน้อย 1 ค่าที่แตกต่างจาก 0}$$

(ความคลาดเคลื่อนสุ่มมีสหสัมพันธ์ในตัวเองตั้งแต่ Lag ที่ $k = 1, 2, 3, \dots, K$)

จากตารางที่ 4.7 พบว่า การทดสอบ Box-Ljung สำหรับ lag ที่ 1 ถึง 5 มีสถิติ Q เท่ากับ 12.2420 และมี p-value เท่ากับ 0.0316 ซึ่งมีค่าน้อยกว่าระดับนัยสำคัญ 0.05 จึงปฏิเสธสมมติฐานหลัก หมายความว่าค่าคลาดเคลื่อนจากตัวแบบ ARIMA(0,2,1) ตั้งแต่ lag ที่ 1 ถึง lag ที่ 5 ยังมีสหสัมพันธ์ในตัวเองของความคลาดเคลื่อนหลงเหลืออยู่

ตารางที่ 4.8 ผลการทดสอบการแจกแจงปกติของค่าคลาดเคลื่อนด้วย Kolmogorov-Smirnov test

K-S	p-value
0.0485	0.1101

สมมติฐานการทดสอบ

$$H_0 : \text{ความคลาดเคลื่อนสุ่มของตัวแบบมีการแจกแจงปกติ}$$

$$H_1 : \text{ความคลาดเคลื่อนสุ่มของตัวแบบไม่มีการแจกแจงปกติ}$$

จากตารางที่ 4.8 พบว่า ค่าสถิติ K-S จากการทดสอบ Kolmogorov-Smirnov มีค่าเท่ากับ 0.0485 และมีค่า p-value 0.1101 ซึ่งสูงกว่าระดับนัยสำคัญ 0.05 จึงไม่ปฏิเสธสมมติฐานหลัก หมายความว่า ค่าคลาดเคลื่อนจากตัวแบบ ARIMA(0,2,1) มีการแจกแจงปกติ

ตารางที่ 4.9 ผลการทดสอบค่าเฉลี่ยของค่าคลาดเคลื่อนด้วย t-test

t	p-value
0.7796	0.4359

สมมติฐานการทดสอบ

H_0 : ความคลาดเคลื่อนสุ่มของตัวแบบมีค่าเฉลี่ยไม่แตกต่างจากศูนย์

H_1 : ความคลาดเคลื่อนสุ่มของตัวแบบมีค่าเฉลี่ยแตกต่างจากศูนย์

จากตารางที่ 4.9 เนื่องจากสถิติที่ใช้ทดสอบค่าเฉลี่ยของความคลาดเคลื่อนสุ่ม t มีค่าเท่ากับ 0.7796 และมีค่า p-value เท่ากับ 0.4359 ซึ่งมากกว่าระดับนัยสำคัญ 0.05 จึงไม่ปฏิเสธสมมติฐานหลัก หมายความว่า ค่าคลาดเคลื่อนที่ได้จากตัวแบบ ARIMA(0,2,1) มีค่าเฉลี่ยไม่แตกต่างจากศูนย์

ตารางที่ 4.10 ผลการทดสอบความแปรปรวนคงที่ของค่าคลาดเคลื่อนด้วย Levene's test

F	d.f. 1	d.f. 2	p-value
3.4178	9	606	0.0004


สมมติฐานการทดสอบ

$H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$

H_1 : มี $\sigma_i^2 \neq \sigma_j^2$ อย่างน้อย 1 กลุ่ม ; $i = 1, 2, \dots, k$ และ $j = 1, 2, \dots, k$

จากตารางที่ 4.10 พบว่า ค่าสถิติ F จากการทดสอบ Levene's Test มีค่าเท่ากับ 3.4178 โดยมีองศาอิสระ d.f.1 = 9 และ d.f.2 = 606 และมีค่า p-value เท่ากับ 0.0004 ซึ่งน้อยกว่าระดับนัยสำคัญ 0.05 จึงปฏิเสธสมมติฐานหลัก หมายความว่า ค่าคลาดเคลื่อนที่ได้จากตัวแบบ ARIMA(0,2,1) มีความแปรปรวนไม่คงที่

จากการตรวจสอบความเหมาะสมของตัวแบบ $ARIMA(0,2,1)$ พบว่าตัวแบบผ่านการตรวจสอบคุณสมบัติการแจกแจงปกติของค่าคลาดเคลื่อน และค่าคลาดเคลื่อนมีค่าเฉลี่ยไม่แตกต่างจาก 0 แต่ไม่ผ่านการทดสอบค่าคลาดเคลื่อนในตัวแบบมีสหสัมพันธ์ในตัวเอง และมีความแปรปรวนไม่คงที่ ดังนั้นตัวแบบ $ARIMA(0,2,1)$ ที่ได้จากวิธีการพยากรณ์ของ Box และ Jenkins นี้ไม่มีความเหมาะสมในการนำมาใช้พยากรณ์ อย่างไรก็ตามไม่พบตัวแบบ $ARIMA(p,d,q)$ อื่นๆที่มีความเหมาะสม จึงนำตัวแบบ $ARIMA(0,2,1)$ มาใช้เป็นตัวแบบที่ได้จากการวิเคราะห์ด้วยวิธีการพยากรณ์ด้วยวิธีการทางอนุกรมเวลาด้วยตัวแบบ $ARIMA$ เพื่อเปรียบเทียบกับวิธีการพยากรณ์อื่นซึ่งจะทำให้เห็นประสิทธิภาพของแต่ละวิธีการพยากรณ์ได้ดียิ่งขึ้น



รูปที่ 4.9 ผลลัพธ์การพยากรณ์ของข้อมูลชุดฝึกและข้อมูลชุดทดสอบด้วยวิธี $ARIMA(0,2,1)$

ตารางที่ 4.11 ค่าวัดประสิทธิภาพ MAD RMSE และ MAPE จากการพยากรณ์ด้วยวิธี $ARIMA(0,2,1)$

ค่าความคลาดเคลื่อน	$ARIMA(0,2,1)$
MAD	151.2608
RMSE	173.1838
MAPE	5.6424%

4.4 ผลการวิเคราะห์ข้อมูลด้วยวิธีการเรียนรู้ของเครื่องแบบ LSTM

ก่อนดำเนินการพยากรณ์ ได้มีการแปลงข้อมูลฝึกด้วยการหาผลต่าง 1 ครั้ง หลังจากนั้นจึงทำการคัดเลือกลักษณะของโครงข่ายประสาทเทียม LSTM โดยจะทำการคัดเลือกหาจำนวนหน่วยประสาทในชั้น LSTM ชั้นแรกและชั้นที่สอง (lstm1_units, lstm2_units), จำนวนหน่วยประสาทในชั้น Dense ชั้นแรกและชั้นที่สอง (dense1_units, dense2_units) ที่มีประสิทธิภาพสูงสุดในขั้นตอนการตรวจสอบโมเดลโดยใช้วิธีการ Grid Search ร่วมกับกลยุทธ์การประเมินผลแบบ Rolling Window ผลลัพธ์จากการประเมินพบว่าการใช้ ข้อมูลย้อนหลัง 10 วัน เป็นหน้าต่างสำหรับสร้างตัวแปรนำเข้าถือเป็นทางเลือกที่เหมาะสมที่สุด ภายใต้ลักษณะของชั้นในการเรียนรู้ LSTM และค่าไฮเพอร์พารามิเตอร์ของการเรียนรู้ที่ได้จากการค้นหา ซึ่งแสดงไว้ในตารางที่ 4.12 และตารางที่ 4.13

ตารางที่ 4.12 ลักษณะของแต่ละชั้นที่กำหนดสำหรับการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องแบบ LSTM


ประเภท Layer	Output Shape
lstm (LSTM)	(None, 10, 50)
lstm_1 (LSTM)	(None, 32)
dense (Dense)	(None, 32)
dense_1 (Dense)	(None,32)
dense_2 (Dense)	(None,1)

ตารางที่ 4.13 ไฮเพอร์พารามิเตอร์ที่กำหนดสำหรับการเรียนรู้


ไฮเพอร์พารามิเตอร์	ค่าที่กำหนด
Learning rate	0.001
epochs	50

หลังจากกำหนดพารามิเตอร์สำหรับการเรียนรู้ จึงทำการฝึกโมเดลด้วยข้อมูลชุดฝึก (Training Set) ที่แปลงให้อยู่ในรูปของผลต่างอันดับที่ 1 โดยทำการฝึกโมเดลตามจำนวนช่วงเวลาล่วงหน้าที่ต้องการพยากรณ์ ดังนั้นจึงมีการฝึกโมเดลทั้งสิ้น 155 โมเดลโดยกำหนดไฮเพอร์พารามิเตอร์สำหรับแต่ละโมเดลเหมือนกันทั้งหมด

ภายหลังการฝึกโมเดลทำการพยากรณ์บนชุดข้อมูลฝึกโดยใช้โมเดลแบบ 1 ก้าวล่วงหน้า (1-step ahead) ค่าพยากรณ์ที่ได้จะถูกแปลงกลับโดยการนำผลลัพธ์จากโมเดลสำหรับพยากรณ์ 1 ช่วงเวลาล่วงหน้าบวกกับข้อมูลจริงในเวลาก่อนหน้า และในชุดข้อมูลทดสอบ ใช้วิธีการพยากรณ์ล่วงหน้าหลายช่วงเวลาแบบตรง (Direct Multi-step Forecasting Strategy) โดยแต่ละช่วงเวลาการพยากรณ์จะใช้โมเดลที่ฝึกไว้เฉพาะสำหรับช่วงเวลานั้น เช่น โมเดลสำหรับพยากรณ์ 1 ก้าว โมเดลสำหรับ 2 ก้าวล่วงหน้า ไปจนถึงช่วงเวลาสุดท้ายของชุดทดสอบแปลงค่าพยากรณ์ในชุดข้อมูลทดสอบกลับโดยการบวกสะสมจากจุดสุดท้ายของข้อมูลฝึก แสดงผลลัพธ์การพยากรณ์ในรูปผลต่างลำดับที่ 1 ดังรูปที่ 4.10 และแสดงผลพยากรณ์ที่แปลงข้อมูลกลับแล้วดังรูปที่ 4.11 จากนั้นจึงทำการคำนวณสถิติวัดประสิทธิภาพการพยากรณ์ดังตารางที่ 4.14



รูปที่ 4.10 ผลลัพธ์การพยากรณ์ด้วยวิธีโครงข่ายประสาทเทียมแบบ LSTM ในรูปผลต่างอันดับที่ 1



รูปที่ 4.11 ผลลัพธ์การพยากรณ์ด้วยโครงข่ายประสาทเทียมแบบ LSTM หลังแปลงค่ากลับ

ตารางที่ 4.14 ค่าวัดประสิทธิภาพ MAD RMSE และ MAPE จากการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องแบบ LSTM

ค่าวัดความคลาดเคลื่อน	LSTM
MAD	221.6092
RMSE	246.5823
MAPE	8.2916

4.5 ผลการวิเคราะห์ข้อมูลด้วยวิธีการเรียนรู้ของเครื่องแบบ XGBoost

ก่อนดำเนินการพยากรณ์ ได้มีการแปลงข้อมูลชุดฝึกให้อยู่ในรูปของผลต่างลำดับที่หนึ่ง (First-order Differencing) เพื่อให้ข้อมูลเหมาะสมสำหรับการพยากรณ์นอกช่วง (Extrapolation) ทำการคัดเลือกค่าไฮเพอร์พารามิเตอร์ที่เหมาะสมที่สุด ได้แก่ minimum_child_weight, learning_rate, gamma, lambda, max_depth และ n_estimators โดยใช้วิธีการ Grid Search ควบคู่กับกลยุทธ์การประเมินผลแบบ Rolling Window ผลลัพธ์การประเมินที่ได้พบว่าการใช้ช่วงเวลาก่อนหน้าเป็นระยะเวลา 40 วันในการสร้างตัวแปรนำเข้าเป็นทางเลือกที่ให้ความแม่นยำสูงที่สุดภายใต้ค่าไฮเพอร์พารามิเตอร์ที่กำหนดไว้ดังนี้


ตารางที่ 4.15 ไฮเพอร์พารามิเตอร์ที่กำหนดสำหรับการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องแบบ XGBoost

ไฮเพอร์พารามิเตอร์	ค่าที่กำหนด
Minimum child weight	1
Learning rate	0.01
Gamma	0.1
Lambda	0.1
Max depth	12
N_estimator	50

หลังจากกำหนดพารามิเตอร์สำหรับการเรียนรู้ จึงทำการฝึกโมเดลด้วยข้อมูลชุดฝึก (Training Set) ที่แปลงให้อยู่ในรูปของผลต่างลำดับที่ 1 (First-order Differencing) ซึ่งจะฝึกโมเดลจำนวนเท่ากับ ช่วงเวลาล่วงหน้าที่ต้องการพยากรณ์ ดังนั้นจึงมีการฝึกโมเดลทั้งสิ้น 155 โมเดล โดยกำหนดไฮเพอร์พารามิเตอร์สำหรับแต่ละโมเดลเหมือนกันทั้งหมด


ภายหลังการฝึกโมเดลทำการพยากรณ์บนชุดข้อมูลฝึกโดยใช้โมเดลแบบ 1 ก้าวล่วงหน้า (1-step ahead) ค่าพยากรณ์ที่ได้จะถูกแปลงกลับโดยการนำผลลัพธ์จากโมเดลสำหรับพยากรณ์ 1 ช่วงเวลาล่วงหน้าบวกกับข้อมูลจริงในเวลาก่อนหน้า และในชุดข้อมูลทดสอบ ใช้วิธีการพยากรณ์ล่วงหน้าหลายช่วงเวลาแบบตรง (Direct Multi-step Forecasting Strategy) โดยแต่ละช่วงเวลาการพยากรณ์จะใช้โมเดลที่ฝึกไว้เฉพาะสำหรับช่วงเวลานั้น เช่น โมเดลสำหรับพยากรณ์ 1 ก้าว โมเดลสำหรับ 2 ก้าวล่วงหน้า ไปจนถึงช่วงเวลาสุดท้ายของชุดทดสอบแปลงค่าพยากรณ์ในชุดข้อมูลทดสอบกลับโดยการบวกสะสมจากจุดสุดท้ายของข้อมูลฝึก แสดงผลลัพธ์การพยากรณ์ในรูปผลต่างลำดับที่ 1 ดังรูปที่ 4.12 และแสดงผลลัพธ์การพยากรณ์ที่แปลงข้อมูลกลับแล้วดังรูปที่ 4.13 จากนั้นจึงทำการคำนวณสถิติวัดประสิทธิภาพการพยากรณ์ดังตารางที่ 4.16

ผลการพยากรณ์ราคาทองคำด้วย XGBoost (ผลต่างลำดับที่ 1)



รูปที่ 4.12 ผลลัพธ์การพยากรณ์ด้วยวิธี XGBoost ในรูปผลต่างอันดับที่

ผลการพยากรณ์ราคาทองคำด้วย XGBoost



รูปที่ 4.13 ผลลัพธ์การพยากรณ์ด้วยวิธี XGBoost หลังแปลงค่ากลับ


ตารางที่ 4.16 ค่าวัดประสิทธิภาพ MAD RMSE และ MAPE จากการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องแบบ XGBoost

ค่าวัดความคลาดเคลื่อน	XGBoost
MAD	132.5518
RMSE	156.4902
MAPE	4.9578

4.6 เปรียบเทียบประสิทธิภาพการพยากรณ์

จากรูปที่ 4.14 ผลการพยากรณ์ราคาทองคำในช่วงข้อมูลทดสอบ (Test Set) พบว่าราคาทองคำจริง (เส้นสีน้ำเงิน) มีแนวโน้มปรับตัวสูงขึ้นตลอดเวลาในช่วงข้อมูลทดสอบ และมีความผันผวนเกิดขึ้นในระยะสั้น เมื่อวิเคราะห์ผลลัพธ์ของแต่ละวิธีการพยากรณ์พบว่าโมเดล Holt's Exponential Smoothing (เส้นสีเขียว) และตัวแบบ ARIMA(0,2,1) สามารถจับทิศทางแนวโน้มขาขึ้นโดยรวมได้ดี แต่เส้นพยากรณ์ที่ได้มีลักษณะค่อนข้างเรียบเนื่องจากไม่สามารถสะท้อนความผันผวนของราคาที่เกิดขึ้นได้ ในส่วนของการเรียนรู้ของเครื่อง XGBoost (เส้นสีส้ม) มีความสามารถในการพยากรณ์แนวโน้มและตรวจจับความผันผวนได้เล็กน้อย ในขณะที่ โมเดล LSTM (เส้นสีแดง) นั้น ให้ผลลัพธ์ที่ดีกว่าโมเดลอื่นโดยสามารถพยากรณ์แนวโน้มและความผันผวนที่เกิดขึ้นได้ใกล้เคียงกับการเคลื่อนไหวของราคาทองคำมากกว่าวิธีการพยากรณ์อื่น แสดงตัวอย่างของการเปรียบเทียบผลลัพธ์การพยากรณ์ในข้อมูลทดสอบดังรูปที่ 4.14

ผลการพยากรณ์ในช่วงข้อมูลทดสอบ (Test Set)



รูปที่ 4.14 ผลลัพธ์การพยากรณ์ทั้ง 4 วิธีบนข้อมูลชุดทดสอบ

ตารางที่ 4.17 เปรียบเทียบค่าวัดประสิทธิภาพการพยากรณ์ด้วยวิธี Holt's Exponential Smoothing, ARIMA(0,2,1), XGBoost, และ LSTM

	Holt's Exponential Smoothing	ARIMA (0,2,1)*	LSTM	XGBoost
MAD	186.1688	151.2608	221.6092	132.5518
RMSE	210.5272	173.1838	246.5823	156.4902
MAPE	6.9454 %	5.6424 %	8.2916	4.9578

หมายเหตุ : *ตัวแบบ ARIMA (0,2,1) ไม่ผ่านการทดสอบความเหมาะสม

ผลการวิเคราะห์ด้วยค่าวัดประสิทธิภาพการพยากรณ์ด้วยวิธีการทางอนุกรมเวลาพบว่า การพยากรณ์ด้วยวิธี Holt's Exponential Smoothing มีค่า MAD เท่ากับ 186.1688 ค่า RMSE เท่ากับ 210.5272 และค่า MAPE เท่ากับ 6.95% สำหรับตัวแบบ ARIMA(0,2,1) จากผลการตรวจสอบสมมติฐานของค่าคลาดเคลื่อน พบว่า ไม่ผ่านการทดสอบสหสัมพันธ์ของค่าคลาดเคลื่อน (Box-Ljung test) และ ไม่

ผ่านการทดสอบความแปรปรวนคงที่ (Levene's test) ทำให้แบบจำลองที่ได้จากวิธีการพยากรณ์ด้วยวิธี ARIMA ไม่เหมาะสมสำหรับการนำมาใช้พยากรณ์แต่นำมาศึกษาประสิทธิภาพเพื่อใช้ในการเปรียบเทียบเท่านั้นซึ่งพบว่าค่า MAD เท่ากับ 151.2608 ค่า RMSE เท่ากับ 173.1838 และค่า MAPE เท่ากับ 5.6424% ในส่วนของวิธีการพยากรณ์ด้วยการเรียนรู้ของเครื่อง พบว่าวิธี XGBoost มีค่า MAD เท่ากับ 132.5518 ค่า RMSE เท่ากับ 156.4902 และค่า MAPE เท่ากับ 4.9578% และการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องด้วยโครงข่ายประสาทเทียมแบบ LSTM มีค่า MAD เท่ากับ 221.6092 ค่า RMSE เท่ากับ 246.5823 และค่า MAPE 8.2916%

จากการเปรียบเทียบประสิทธิภาพด้วยสถิติวัดประสิทธิภาพการพยากรณ์ทั้ง 3 ค่า ได้แก่ MAD RMSE และ MAPE ผลจากการเปรียบเทียบพบว่าทั้งสามค่ามีความสอดคล้องกันคือ วิธีการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องมีประสิทธิภาพสูงกว่าการพยากรณ์ด้วยวิธีการพยากรณ์ทางอนุกรมเวลา โดยวิธีการพยากรณ์ที่มีประสิทธิภาพสูงที่สุดคือวิธีการเรียนรู้ของเครื่องด้วยโครงข่ายประสาทเทียมแบบ XGBoost อันดับที่สองคือวิธีการพยากรณ์ของ Box และ Jenkins อันดับที่สามคือวิธีการปรับให้เรียบแบบเอกซ์โพเนนเชียลของ Holt และวิธีการพยากรณ์ที่มีประสิทธิภาพต่ำที่สุดคือวิธีการเรียนรู้ของเครื่องแบบ LSTM

บทที่ 5

สรุปผลการวิจัยและข้อเสนอแนะ

การวิจัยครั้งนี้มีวัตถุประสงค์เพื่อศึกษา สร้างตัวแบบ และเปรียบเทียบวิธีการพยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามระหว่างรัสเซียและยูเครนโดยใช้วิธีการพยากรณ์ทางอนุกรมเวลา 2 วิธี ได้แก่ วิธีการปรับให้เรียบแบบเอกซ์โพเนนเชียล และวิธีของ Box และ Jenkins กับวิธีการเรียนรู้ของเครื่อง 2 วิธี ได้แก่ วิธีการเรียนรู้ของเครื่องแบบโครงข่ายประสาทเทียมแบบ Long-short term memory (LSTM) และวิธีการเรียนรู้ของเครื่องแบบ Extreme Gradient Boosting (XGBoost) โดยแบ่งข้อมูลเป็น 2 ส่วน คือส่วนหนึ่งใช้ในการสร้างตัวแบบพยากรณ์และใช้เป็นข้อมูลสำหรับฝึก ตั้งแต่วันที่ 24 กุมภาพันธ์ พ.ศ. 2565 ถึงวันที่ 10 กรกฎาคม พ.ศ. 2567 จำนวน 618 วัน และอีกส่วนหนึ่งสำหรับการเปรียบเทียบประสิทธิภาพของแต่ละวิธีการพยากรณ์ตั้งแต่วันที่ 11 กรกฎาคม พ.ศ. 2567 ถึงวันที่ 14 กุมภาพันธ์ พ.ศ. 2568 จำนวน 155 วัน โดยใช้เกณฑ์ค่าวัดประสิทธิภาพในการพยากรณ์ ได้แก่ ค่ารากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง (MAD), ค่ารากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง (RMSE), และค่าเฉลี่ยร้อยละของความคลาดเคลื่อนสัมบูรณ์ (MAPE) เพื่อหาวิธีที่ดีที่สุดในการพยากรณ์

5.1 สรุปผลการวิจัย

จากการศึกษาและเปรียบเทียบประสิทธิภาพในการพยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซียและยูเครนด้วยวิธีปรับให้เรียบแบบเอกซ์โพเนนเชียลของ Holt ,วิธีของ Box และ Jenkins, วิธีการเรียนรู้ของเครื่องแบบโครงข่ายประสาทเทียม, วิธีการเรียนรู้ของเครื่องแบบ XGBoost พบว่าผลการวิเคราะห์จากทุกเกณฑ์การประเมินด้วยค่า MAD, RMSE, MAPE ต่างสะท้อนผลลัพธ์ที่สอดคล้องกัน โดยชี้ให้เห็นอย่างชัดเจนว่าการพยากรณ์ด้วยวิธีการพยากรณ์ด้วยวิธีการเรียนรู้ของแบบ XGBoost มีความแม่นยำมากที่สุด โดยมีค่า MAD, RMSE และ MAPE เท่ากับ 132.5518, 156.4902 และ 4.9578% ตามลำดับ ผลการศึกษาข้างต้นสะท้อนให้เห็นว่าการพยากรณ์ราคาทองคำด้วยวิธีการอนุกรมเวลา เช่น Holt และ ARIMA(0,2,1) ยังคงมีข้อจำกัดของตัวแบบที่ไม่สามารถอธิบายความผันผวนของข้อมูล หากเป้าหมายการพยากรณ์มีความผันผวนเป็นปัจจัยสำคัญที่ต้องพิจารณา เช่น ข้อมูลทางการเงินระยะสั้นที่มีความผันผวนสูง การพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องร่วมกับกลยุทธ์การพยากรณ์ล่วงหน้าหลาย

ช่วงเวลาจะมีความเหมาะสมมากกว่า สำหรับการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องแบบ LSTM ที่ถูกออกแบบโครงสร้างภายในให้สามารถเรียนรู้และจดจำความสัมพันธ์ของข้อมูลในระยะยาวและปรับปรุงหน่วยความจำเมื่อได้รับข้อมูลใหม่ได้อย่างมีประสิทธิภาพ อย่างไรก็ตามด้วยเป้าหมายการพยากรณ์ที่ต้องการหาวิธีพยากรณ์ในช่วงสงครามซึ่งเป็นสถานการณ์วิกฤติและสามารถรวบรวมข้อมูลได้อย่างจำกัดทำให้ข้อมูลที่ใช้สำหรับการฝึกโมเดลอาจไม่เพียงพอสำหรับวิธี Deep Learning ที่ต้องการข้อมูลมากกว่าวิธีอื่นๆ ในขณะที่ XGBoost ซึ่งเป็นวิธี Machine Learning แบบดั้งเดิมมักจะมีความต้องการจำนวนข้อมูลที่น้อยกว่าและยังจัดการความสัมพันธ์ไม่เป็นเชิงเส้นของข้อมูลได้เป็นอย่างดี ทำให้มีประสิทธิภาพการพยากรณ์สูงกว่าวิธีอื่นๆ

5.2 ข้อเสนอแนะ

5.2.1 ข้อเสนอแนะเพื่อการใช้ประโยชน์

จากการวิจัยในครั้งนี้ได้ทำการเปรียบเทียบเพื่อหาวิธีการพยากรณ์ที่มีความเหมาะสมมากที่สุดในการนำไปใช้พยากรณ์ราคาทองคำภายใต้สถานการณ์สงครามรัสเซียและยูเครน ซึ่งผลลัพธ์จากการพยากรณ์สามารถนำมาใช้ประโยชน์ในเพื่อจัดทำข้อมูลประกอบการตัดสินใจสำหรับนักลงทุน หน่วยงานด้านการเงิน และผู้ที่เกี่ยวข้องในการกำหนดนโยบายที่เกี่ยวข้องกับตลาดทองคำภายใต้สภาวะความไม่แน่นอนสูง ทั้งจากสถานการณ์สงคราม ภัยโรคระบาด วิกฤติเศรษฐกิจ หรือเหตุการณ์สำคัญที่ส่งผลกระทบต่อเสถียรภาพของตลาดการเงินโลก อย่างไรก็ตาม การวิจัยในครั้งนี้เป็นการพยากรณ์ที่วัดประสิทธิภาพในระยะยาวสำหรับการพยากรณ์ด้วยความถี่รายวัน สำหรับการพยากรณ์ด้วยวิธีการเรียนรู้ของเครื่องที่มีกรอบเวลาเป้าหมายที่แตกต่างจากการศึกษานี้ เช่น การพยากรณ์ในระยะสั้นสามารถปรับเปลี่ยนกลยุทธ์การพยากรณ์หลายช่วงเวลาจากกลยุทธ์ Direct เป็น Recursive ซึ่งจะช่วยให้ประหยัดทรัพยากรการคำนวณได้ อย่างไรก็ตามค่าพยากรณ์ที่ได้ อาจสะสมความผิดพลาดต่อเนื่องเมื่อช่วงเวลาเป้าหมายที่ต้องการพยากรณ์มีระยะไกลขึ้น นอกจากนี้โมเดลพยากรณ์ควรมีการปรับปรุงอย่างสม่ำเสมอ โดยเฉพาะเมื่อข้อมูลมีลักษณะการเคลื่อนไหวที่แตกต่างไปจากเดิม เช่น สำหรับการพยากรณ์ หากข้อมูลมีลักษณะของแนวโน้มหรือความผันผวนเปลี่ยนไปจากเดิมควรมีการพิจารณาเพิ่มหรือปรับปรุงข้อมูลสำหรับการฝึกโมเดลแล้วทำการสร้างโมเดลใหม่ สำหรับการเรียนรู้ของเครื่องควรพิจารณาหาไฮเพอร์

พารามิเตอร์ที่เหมาะสมใหม่ให้เหมาะกับข้อมูลมากที่สุด เพื่อให้ผลการพยากรณ์ที่ได้มีความถูกต้องแม่นยำ และทันต่อการเปลี่ยนแปลงของบริบททางเศรษฐกิจและตลาดการเงินอยู่ตลอดเวลา โดยการดำเนินการเช่นนี้จะช่วยเพิ่มความน่าเชื่อถือของการพยากรณ์ และสามารถนำผลลัพธ์ไปใช้ในการตัดสินใจเชิงกลยุทธ์ การจัดการความเสี่ยง และการวางแผนการลงทุนได้อย่างมีประสิทธิภาพมากยิ่งขึ้น

5.2.2 ข้อเสนอแนะเพื่อการวิจัย

การพยากรณ์ราคาทองคำอาจขึ้นอยู่กับหลายปัจจัย ในการวิจัยครั้งต่อไปผู้วิจัยควรพิจารณาปัจจัยอื่นๆ เช่น ดัชนีดอลลาร์สหรัฐ อัตรา Federal Fund อัตราแลกเปลี่ยน และดัชนี S&P 500 มาใช้เป็นตัวแปรอิสระร่วมด้วยนอกเหนือจากองค์ประกอบของอนุกรมเวลา เพื่อให้การพยากรณ์มีความสมบูรณ์และมีความแม่นยำมากยิ่งขึ้น

นอกจากนี้ สำหรับการศึกษาครั้งต่อไปอาจทำการเปรียบเทียบวิธีการพยากรณ์โดยใช้แนวทางอื่นๆ ที่นอกเหนือจากวิธีการพยากรณ์ที่ใช้ในงานวิจัยนี้ เช่น ตัวแบบ ARIMAX ซึ่งเป็นตัวแบบที่สามารถนำปัจจัยอื่น ๆ ที่คาดว่าจะมีอิทธิพลต่อราคาทองคำมาร่วมในการพยากรณ์ได้ รวมถึงวิธีการเรียนรู้ของเครื่องชนิดอื่น ๆ เช่น LightGBM นอกจากนี้ อาจพิจารณาใช้โมเดลที่ผสมกัน (Ensemble) เช่น ARIMA-XGboost

บรรณานุกรม

- Amat Rodrigo, J., & Escobar Ortiz, J. (2025). skforecast (Version 0.18.0) [Computer software]. <https://doi.org/10.5281/zenodo.8382788>
- Bontempi, G., Taieb, S. B., & Le Borgne, Y.-A. (2013). Machine learning strategies for time series forecasting. In G. Kitsios (Ed.), Business intelligence (pp. 62–77). Springer. https://doi.org/10.1007/978-3-642-36318-4_3
- Dogucu, M., & Çetinkaya-Rundel, M. (2022). Modern time series forecasting with Python. Packt Publishing. <https://doi.org/10.1007/978-1-80324-680-2>
- Fawzy, H., Rady, E. H. A., & Abdel Fattah, A. M. (2020). Comparison between support vector machines and K-nearest neighbor for time series forecasting. Journal of Mathematical and Computational Science, 10(6), 2342–2359. <https://doi.org/10.28919/jmcs/4884>
- Khalid, N. A., & Halim, N. A. (2019). Gold Price Forecasting using Box-Jenkins Method. Universiti Malaysia Terengganu Journal of Undergraduate Research, 1(3), 15–27. <https://doi.org/10.46754/umtjur.v1i3.75>
- Leng, S. H., Phauk, S., & Has, S. (2023). An empirical investigation of gold price forecasting using ARIMA compare with LSTM model. Techno-Science Research Journal, 11(2), 38–46. <https://techno-srj.itc.edu.kh/>
- Liu, S. (2024). A gold and Bitcoin trading model based on XGBoost prediction. In Proceedings of the 2023 International Conference on Digital Economy and Artificial Intelligence (DEAI 2023) (pp. 7–11). Association for Computing Machinery. <https://doi.org/10.1145/3675417.3675419>

- Livieris, I. E., & Pintelas, P. (2022). A novel multi-step forecasting strategy for enhancing deep learning models' performance. *Neural Computing and Applications*, 34, 19453–19470. <https://doi.org/10.1007/s00521-022-07158-9>
- Makala, D., & Li, Z. (2021). Prediction of gold price with ARIMA and SVM. *Journal of Physics: Conference Series*, 1767(1), 012022. <https://doi.org/10.1088/1742-6596/1767/1/012022>
- Mohri, M., Rostamizadeh, A., & Talwalkar, A. (2018). *Foundations of machine learning* (2nd ed.). The MIT Press.
- Nwokike, C., Ugoala, C., Obubu, M., Offorha, B., Uche-Ikonne, O., & Ukomah, H. (2020). Forecasting Monthly Prices of Gold Using Artificial Neural Network. 9, 19-28.
- Nur Atikah Khalid, & Nurfadhlin Abdul Halim. (2019). Gold Price Forecasting using Box-Jenkins Method. *Universiti Malaysia Terengganu Journal of Undergraduate Research*, 1(3), 15–27. <https://doi.org/10.46754/umtjur.v1i3.75>
- Olah, C. (2015, August 27). Understanding LSTM networks. Colah's blog. สืบค้นจาก <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- Sarvaiya, D., & Ramchandani, D. (2022). Time series analysis and forecasting of gold price using ARIMA and LSTM model. *International Journal for Research in Applied Science & Engineering Technology*, 10(9), 1–7. <https://www.ijraset.com>
- Sharma, R. K. (2016). Forecasting gold price with Box-Jenkins autoregressive integrated moving average method. *Journal of International Economics*, 7(1), 32–60.
- Suga, A. (2018). Exploring the effectiveness of deep learning models in forecasting commodity prices: A case study on gold (Unpublished master's thesis). National College of Ireland, School of Computing

Yang, X. (2019). The prediction of gold price using ARIMA model. In Proceedings of the 2nd International Conference on Social Science, Public Health and Education (SSPHE 2018) (pp. 273–276). Atlantis Press. <https://doi.org/10.2991/ssphe-18.2019.66>

Yiyiing, W. (2023). Time Series Prediction Based on LSTM Neural Network for Gold Prices. *Advances in Economics, Management and Political Sciences*, 61, 192-198. <https://doi.org/10.54254/2754-1169/61/20231255>

ทรงศิริ แต้สมบัติ. (2539). เทคนิคการพยากรณ์เชิงปริมาณ. สำนักพิมพ์ฟิสิกส์เซ็นเตอร์.

นพัตสรณ์ รัตนสกุลพัฒน์, ชาญเดช เจริญวิริยะกุล, & วราพร ดำรงค์กุลสมบัติ. (2023). พฤติกรรมการลงทุนในทองคำแท่งของคนวัยทำงานในเขตกรุงเทพมหานคร. *مجلة التطوير والتنمية*, 7(3), 380–393.

ศิริลักษณ์ สุวรรณวงศ์. (2556). เทคนิคการพยากรณ์เชิงปริมาณ : การวิเคราะห์อนุกรมเวลา. นครปฐม: สำนักพิมพ์ มหาวิทยาลัยมหิดล.

สำนักงานนโยบายและยุทธศาสตร์การค้า. (2566). รายงานสถานการณ์รัสเซีย-ยูเครน ณ วันที่ 15 สิงหาคม 2566. กระทรวงพาณิชย์.

